

UNIVERSITÉ MOHAMMED V

Faculté des Sciences

Master Informatique et Télécommunications

Projet de Fin d'Études

Pour obtenir le titre de

Master en Informatique et Télécommunications

Option : Informatique et IA appliquée

Présenté par :

Abdallah OUAHMANE

Trustworthy AI for Opportunistic Screening of Cardiovascular Risk from Chest X-Ray Images

*Intelligence artificielle de confiance pour le dépistage opportuniste
du risque cardiovasculaire à partir de radiographies thoraciques*

Soutenu le 12/09/2026 devant le jury :

Encadrant :

Pr. EL HASSOUNI Mohammed Université Mohammed V de Rabat

Examineurs :

Pr. RHOULAMI Khadija Université Mohammed V de Rabat

M. QBOUCHE Khalid Professeur Assistant (PA), Faculté des
Sciences, Rabat

Année universitaire 2025 – 2026

Remerciements

Au terme de ce travail, je tiens à exprimer ma profonde gratitude à toutes les personnes qui ont contribué, de près ou de loin, à la réalisation de ce Projet de Fin d'Études.

Je tiens à adresser mes remerciements les plus sincères à **Monsieur le Professeur Mohamed El Hassouni**, mon encadrant, pour sa disponibilité, ses précieux conseils, sa rigueur scientifique et la confiance qu'il m'a accordée tout au long de ce projet. Ses orientations ont été déterminantes dans la conduite de ce travail de recherche.

Je remercie également les membres du jury qui ont accepté d'évaluer ce travail et de lui consacrer leur temps et leur expertise. Leurs remarques et suggestions contribueront à l'enrichissement de ce projet.

Je tiens à exprimer ma profonde reconnaissance à ma famille pour son soutien indéfectible, sa patience et ses encouragements constants tout au long de mon parcours universitaire. Ce travail leur est dédié.

Enfin, je remercie l'ensemble du corps enseignant du Master en Ingénierie Informatique et Télécommunications de la Faculté des Sciences de Rabat pour la qualité de la formation dispensée et pour avoir su éveiller en moi la passion de l'intelligence artificielle et de ses applications au service de la santé.

Résumé

Les maladies cardiovasculaires représentent la première cause de mortalité mondiale, responsables de plus de 17 millions de décès par an. La radiographie thoracique, examen de routine parmi les plus prescrits en pratique clinique, offre une opportunité unique de dépistage opportuniste : extraire des indicateurs de risque cardiovasculaire à partir d'examens déjà réalisés pour d'autres indications, sans coût ni irradiation supplémentaires.

Ce projet de fin d'études présente la conception, le développement et la validation d'un pipeline d'IA de confiance (Trustworthy AI) pour le dépistage opportuniste du risque cardiovasculaire à partir d'images radiographiques thoraciques. Le pipeline intègre quatre modules complémentaires : un réseau U-Net pour la segmentation cardiaque et le calcul du ratio cardio-thoracique (CTR), un second U-Net pour la détection des calcifications vasculaires, un classificateur EfficientNet-B0 pour la confirmation des calcifications, et un classificateur de risque cardiovasculaire avec visualisation Grad-CAM

Les modèles ont été entraînés sur trois datasets publics de référence : NIH ChestX-ray14 (112 120 images), VinDr-CXR (18 000 images DICOM) et JSRT Database (247 images avec masques pixel parfait). La validation expérimentale a été conduite sur 501 images NIH à travers sept études rigoureuses : ablation des composantes, analyse du rôle de chaque module, optimisation des poids de fusion et évaluation de la fusion à seuillage de confiance.

Le pipeline optimisé, formulé comme $\text{risk_global} = (0.15 \times s_ctr + 0.40 \times s_cong + 0.10 \times s_calcif + 0.35 \times \text{prob_cardio}) \times 100$, atteint une AUC de 0.8916 avec un intervalle de confiance à 95 % de $[0.8572; 0.9229]$. Cette pondération, obtenue par recherche exhaustive sous contrainte d'auditabilité, améliore de 11.6 points la formule à deux composantes initialement retenue, écart hautement significatif au test de DeLong. Le gain provient de l'introduction d'une composante de cardiomégalie, dont l'absence rendait le score anti-corrélé à cette pathologie. Une validation par deux cents partitions indépendantes situe le surajustement à sept dix-millièmes de point d'AUC. La dimension Trustworthy AI est assurée par la transparence de la fusion, l'explicabilité via Grad-CAM et un mécanisme de signalement de l'incertitude.

Mots-clés : *Intelligence artificielle, Dépistage opportuniste, Radiographie thoracique, Risque cardiovasculaire, U-Net, EfficientNet, Grad-CAM, Trustworthy AI, CTR, NIH ChestX-ray14, VinDr-CXR.*

Abstract

Cardiovascular diseases remain the leading cause of mortality worldwide, accounting for over 17 million deaths annually. Chest X-ray, one of the most commonly prescribed examinations in clinical practice, offers a unique opportunity for opportunistic screening : extracting cardiovascular risk indicators from already-prescribed examinations, without additional cost or radiation exposure.

This final year project presents the design, development, and validation of a Trustworthy AI pipeline for opportunistic cardiovascular risk screening from chest X-ray images. The pipeline integrates four complementary modules : a U-Net network for cardiac segmentation and cardiothoracic ratio (CTR) computation, a second U-Net for vascular calcification detection, an EfficientNet-B0 classifier for calcification confirmation, and a cardiovascular risk classifier with Grad-CAM visualization.

The models were trained on three public reference datasets : NIH ChestX-ray14 (112,120 images), VinDr-CXR (18,000 DICOM images), and JSRT Database (247 images with pixel-perfect masks). Experimental validation was conducted on 501 NIH images through seven rigorous studies : component ablation, module contribution analysis, fusion weight optimization, and confidence-gated fusion evaluation.

The optimized pipeline, formulated as $\text{risk_global} = (0.15 \times s_ctr + 0.40 \times s_cong + 0.10 \times s_calcif + 0.35 \times \text{prob_cardio}) \times 100$, achieves an AUC of 0.8916 with a 95 % confidence interval of [0.8572 ; 0.9229]. This weighting, obtained by exhaustive search under auditability constraints, improves upon the initial two-component formula by 11.6 points, a highly significant difference under DeLong’s test. The gain stems from introducing a cardiomegaly component, whose absence made the score anti-correlated with that pathology. Validation over two hundred independent partitions places the overfitting at seven ten-thousandths of an AUC point. The Trustworthy AI dimension is ensured through fusion transparency, Grad-CAM explainability, and an uncertainty flagging mechanism.

Keywords : *Artificial Intelligence, Opportunistic Screening, Chest X-ray, Cardiovascular Risk, U-Net, EfficientNet, Grad-CAM, Trustworthy AI, CTR, NIH ChestX-ray14, VinDr-CXR.*

Liste des abréviations

AI / IA	Artificial Intelligence / Intelligence Artificielle
AUC	Area Under the Curve (Aire sous la courbe ROC)
CLAHE	Contrast Limited Adaptive Histogram Equalization
CNN	Convolutional Neural Network (Réseau de neurones convolutif)
CTR	Cardiothoracic Ratio (Ratio cardio-thoracique)
DICOM	Digital Imaging and Communications in Medicine
DL	Deep Learning (Apprentissage profond)
F1	F1-Score (Moyenne harmonique précision/rappel)
Grad-CAM	Gradient-weighted Class Activation Mapping
GPU	Graphics Processing Unit
IoU	Intersection over Union
JSRT	Japanese Society of Radiological Technology
ML	Machine Learning (Apprentissage automatique)
NIH	National Institutes of Health
PNG	Portable Network Graphics
PFE	Projet de Fin d'Études
ROC	Receiver Operating Characteristic
U-Net	Architecture de réseau convolutif pour la segmentation d'images
VinDr	Vietnam Doctor — Dataset de radiographies thoraciques
XAI	Explainable Artificial Intelligence (IA explicable)

Table des matières

Remerciements	i
Résumé	ii
Abstract	iii
Liste des abréviations	iv
1 Introduction Générale	1
1.1 Contexte : Maladies Cardiovasculaires et Imagerie Médicale	1
1.2 Problématique et Motivation	2
1.3 Objectifs du Projet	3
1.4 Contributions Principales	4
1.5 Organisation du Rapport	5
2 État de l’Art	6
2.1 Dépistage Cardiovasculaire par Radiographie Thoracique	6
2.1.1 La radiographie thoracique comme outil de dépistage	6
2.1.2 Du dépistage ciblé au dépistage opportuniste	6
2.2 Deep Learning en Imagerie Médicale : Panorama	7
2.2.1 Essor du Deep Learning médical	7
2.2.2 Architectures dominantes en imagerie médicale	8
2.3 Segmentation par U-Net : État de l’Art et Variantes	8
2.3.1 Architecture U-Net originale	8
2.3.2 Variantes et évolutions	9
2.3.3 Défi du domain shift en segmentation	10
2.4 Classification par EfficientNet : Transfer Learning Médical	10
2.4.1 Architecture EfficientNet	10

2.4.2	Transfer learning en imagerie médicale	10
2.5	Explicabilité des Modèles : Grad-CAM et Alternatives	11
2.5.1	Le problème de la boîte noire en médecine	11
2.5.2	Grad-CAM : principe et application	11
2.5.3	Alternatives et limites de Grad-CAM	12
2.6	Trustworthy AI en Médecine : Définition et Enjeux	12
2.6.1	Fondements du Trustworthy AI	12
2.6.2	Trustworthy AI appliqué à la radiologie cardiovasculaire	13
2.6.3	Limites et défis du Trustworthy AI	13
2.7	Positionnement de Notre Travail par Rapport à la Littérature	14
3	Datasets et Prétraitement	16
3.1	NIH ChestX-ray14 : Description et Utilisation	16
3.1.1	Présentation du dataset	16
3.1.2	Utilisation dans notre pipeline	17
3.2	VinDr-CXR : Spécificités DICOM et Annotations	17
3.2.1	Présentation du dataset	17
3.2.2	Utilisation dans notre pipeline	18
3.3	JSRT Database : Masques Pixel Parfait	18
3.3.1	Présentation du dataset	18
3.3.2	Extraction du masque cardiaque	19
3.4	Prétraitement : CLAHE, Redimensionnement et Normalisation	19
3.4.1	Amélioration du contraste par CLAHE	19
3.4.2	Redimensionnement et correction du spacing	20
3.4.3	Normalisation et augmentation de données	20
3.5	Stratégie d'Équilibrage et Gestion du Domain Shift	21
3.5.1	Déséquilibre de classes et stratégies d'équilibrage	21
3.5.2	Domain shift : analyse et stratégies de mitigation	21
3.6	Qualité des Données comme Pilier Trustworthy AI	22

4	Architecture du Pipeline	25
4.1	Vue d’Ensemble : Pipeline 4 Modules	25
4.2	Module 1 — U-Net Cardiaque et Calcul CTR Corrigé	26
4.2.1	Architecture U-Net à 4 niveaux	26
4.2.2	Calcul du CTR corrigé	27
4.3	Module 2 — U-Net Segmentation Calcifications Vasculaires	28
4.4	Module 3 — CNN EfficientNet-B0 Classification Calcifications	29
4.5	Module 4 — CNN Risque Cardiovasculaire et Grad-CAM	30
4.5.1	Architecture et entraînement	30
4.5.2	Intégration Grad-CAM	30
4.6	Stratégie de Fusion : Formule et Justification des Poids	31
4.6.1	Formule initiale du pipeline	31
4.6.2	Catégorisation du score global	31
4.6.3	Optimisation expérimentale — Pipeline V5	32
4.7	Transparence et Décomposabilité du Score	32
5	Entraînement et Performances des Modèles	35
5.1	Protocole Expérimental et Environnement	35
5.1.1	Environnement d’exécution	35
5.1.2	Protocole commun d’entraînement	36
5.2	U-Net Cardiaque : JSRT Seul vs JSRT+VinDr	36
5.2.1	Modèle initial : entraînement sur JSRT seul	36
5.2.2	Modèle robuste : entraînement combiné JSRT+VinDr	38
5.3	U-Net Calcifications (VinDr, Dice val = 0.793)	40
5.3.1	Résultats et analyse	40
5.4	CNN Calcifications (VinDr, exactitude test = 0.759)	41
5.4.1	Courbe d’apprentissage	41
5.4.2	Rapport de classification sur le test set	42
5.5	CNN Risque Cardiovasculaire (NIH, AUC macro = 0.8954)	43
5.5.1	Résultats détaillés par classe	43

5.5.2	Validation Grad-CAM	45
5.6	Synthèse Comparative des 4 Modèles	45
5.7	Audit du Code d’Entraînement et Corrections Apportées	46
5.8	Robustesse et Généralisation : Analyse du Domain Shift	47
5.8.1	Domain shift géographique et morphologique	47
5.8.2	Domain shift de modalité d’acquisition	48
5.8.3	Perspectives de robustesse	48
6	Études Expérimentales de Validation	49
6.1	Dataset de Validation : 501 Images NIH	49
6.2	Étude 1 — Ablation : contribution de chaque module	50
6.2.1	Protocole	50
6.2.2	Résultats	51
6.2.3	Analyse	51
6.2.4	Distribution des composantes par groupe clinique	52
6.2.5	Analyse par sous-groupe pathologique	53
6.3	Étude 2 — Comparaison des sources du signal calcique	54
6.3.1	Formulation	54
6.3.2	Protocole	54
6.3.3	Résultats	54
6.3.4	Interprétation	55
6.3.5	Décision	56
6.4	Étude 2B — Le Module 2 apporte-t-il une information complémentaire?	56
6.5	Étude 3 — Sensibilité de la formule à ses pondérations	57
6.5.1	Formulation	57
6.5.2	Balayage univarié	57
6.5.3	Perturbation aléatoire des pondérations	58
6.5.4	Position dans l’espace des configurations admissibles	59
6.6	Étude 4 — Gating par la confiance et calibration des classificateurs	59
6.6.1	Principe	59

6.6.2	Distribution de la confiance	60
6.6.3	La confiance discrimine-t-elle les erreurs ?	60
6.6.4	Résultats du gating	61
6.6.5	Diagnostic	62
6.7	Étude 5 — Comparaison au classificateur end-to-end	63
6.7.1	Formulation	63
6.7.2	Résultats	63
6.7.3	Décomposition de l’apport des composantes anatomiques	64
6.7.4	Interprétation	65
6.8	Étude 6 — Validation des pondérations et rôle du Module 3	65
6.8.1	Formulation	66
6.8.2	Contraintes d’auditabilité	66
6.8.3	Recherche exhaustive sous contrainte	66
6.8.4	Validation par demi-échantillons répétés	67
6.8.5	Contribution du Module 3	68
6.9	Pipeline V5 Final : Formule, Résultats et Gain	69
6.9.1	Genèse de la formule de fusion	69
6.9.2	Formule finale	71
6.9.3	Cas de test détaillés	71
6.9.4	Métriques cliniques et choix du seuil	72
6.10	Fiabilité expérimentale : reproductibilité et rigueur	73
6.10.1	Garanties de reproductibilité	73
6.10.2	Limites et biais reconnus	74
7	Trustworthy AI : Synthèse et Discussion	76
7.1	Bilan des 4 Piliers du Trustworthy AI	76
7.2	Grad-CAM : Validation Visuelle de l’Attention du Modèle	77
7.2.1	Résultats de la validation anatomique	77
7.2.2	Limitation technique du Grad-CAM implémenté	77
7.3	Flags d’Incertitude et Désaccord Inter-Modules	78

7.3.1	Mécanismes de flags implémentés	78
7.3.2	Analyse du désaccord inter-modules	79
7.4	Comportement Hors Domaine : Trois Cas Externes	79
7.5	Limites Identifiées et Honnêteté Scientifique	80
7.5.1	Limites techniques	81
7.5.2	Limites de validation	82
7.5.3	Modes de défaillance silencieuse	83
7.6	Comparaison avec les Standards Cliniques Existants	84
8	Conclusion et Perspectives	86
8.1	Bilan des Contributions	86
8.2	Limites du Système et Perspectives d’Amélioration	87
8.2.1	Court terme (0-6 mois)	87
8.2.2	Moyen terme (6-18 mois)	88
8.2.3	8.2.3 Long terme (>*** 18 mois)***	89
8.3	Mot Final	90
	Références bibliographiques	92
A	Algorithmes Formels du Pipeline	95
A.1	A.1 Prétraitement de l’Image	95
A.2	A.2 Calcul du Ratio Cardio-Thoracique	96
A.3	A.3 Segmentation par U-Net	97
A.4	A.4 Classification et Explicabilité Grad-CAM	98
A.5	A.5 Fusion Multi-Sources — Pipeline V5	100

Table des figures

1.1	Pipeline de dépistage opportuniste du risque cardiovasculaire par radiographie thoracique	1
2.1	Architecture U-Net à quatre niveaux : encodeur, goulot, décodeur et connexions résiduelles	9
2.2	Principe du Grad-CAM : de la passe avant à la carte de chaleur superposée	12
3.1	Chaîne de prétraitement des radiographies thoraciques	20
3.2	Les quatre piliers opérationnels du Trustworthy AI mis en œuvre dans le pipeline	23
4.1	Architecture détaillée du pipeline à quatre modules	25
4.2	Architecture EfficientNet-B0 adaptée au monocanal	29
5.1	Décalage de domaine du U-Net cardiaque sur une image NIH : modèle JSRT seul, après recalage d'intensité, et modèle JSRT + VinDr	37
5.2	Courbes d'apprentissage du U-Net cardiaque robuste sur 30 époques	39
5.3	Courbes d'apprentissage du U-Net calcifications (Module 2) sur 20 époques	41
5.4	Courbes d'apprentissage du CNN calcifications (Module 3) sur 20 époques	41
5.5	Matrice de confusion du Module 3 sur le jeu de test VinDr	43
5.6	Courbes ROC un-contre-tous du Module 4 sur le jeu de test NIH	44
5.7	Matrice de confusion du Module 4 sur le jeu de test NIH	44
6.1	Gating par la confiance : effet du seuil, calibration du Module 4 et séparation des erreurs	62
6.2	Progression des formules de fusion : AUC globale et AUC sur le sous-groupe cardiomégalie	70
6.3	Rapport visuel généré par le pipeline sur un cas de cardiomégalie confirmé	72
7.1	Carte de chaleur Grad-CAM du Module 4 sur un cas de cardiomégalie confirmé	78

Liste des tableaux

2.1	Architectures de réseaux profonds dominantes en imagerie médicale	8
2.2	Positionnement de Notre Travail par Rapport à la Littérature	14
3.1	Les trois corpus publics employés dans le projet	16
3.2	Sources du décalage de domaine entre les corpus et effets observés	22
4.1	Schéma de flux du pipeline	26
4.2	Vue d'ensemble des quatre modules du pipeline	26
4.3	Catégorisation du score global en niveaux cliniques	32
5.1	Environnement matériel et logiciel d'exécution	35
5.2	Comparaison des deux U-Net cardiaques sur le jeu de test JSRT	39
5.3	Métriques d'entraînement du U-Net calcifications	40
5.4	Rapport de classification sur le test set	42
5.5	Résultats détaillés par classe	43
5.6	Synthèse comparative des quatre modèles entraînés	45
5.7	Défauts d'entraînement identifiés lors de l'audit du code et corrections apportées	46
5.7	Défauts d'entraînement identifiés lors de l'audit du code et corrections apportées	47
6.1	Composition du jeu de validation de 501 images	49
6.1	Composition du jeu de validation de 501 images	50
6.2	AUC des configurations d'ablation comparées à la formule déployée	51
6.3	Apport marginal de chaque module au score de fusion	51
6.4	Distribution des composantes par groupe clinique	52
6.5	AUC des composantes évaluées sur leur sous-groupe pathologique propre .	53
6.6	Pouvoir discriminant des deux sources du signal calcique	55
6.7	AUC de la formule V5 selon la source du signal calcique	55

6.8	Signal des deux modules calciques par groupe clinique	55
6.9	Effet de l’adjonction du Module 2 en cinquième composante	57
6.10	Sensibilité de l’AUC à chacune des quatre pondérations	58
6.11	Dispersion de l’AUC sur mille pondérations perturbées	58
6.12	Position dans l’espace des configurations admissibles	59
6.13	Distribution de la confiance des deux classificateurs	60
6.14	Proportion de modules actifs selon le seuil de confiance	60
6.15	Confiance moyenne du Module 4 selon la justesse de sa prédiction	61
6.16	Diagramme de fiabilité du Module 4 par intervalle de confiance	61
6.17	Effet du gating par la confiance sur l’AUC du pipeline	61
6.18	Confiance des deux classificateurs par groupe clinique	62
6.18	Confiance des deux classificateurs par groupe clinique	63
6.19	AUC des configurations comparées, avec intervalles de confiance	64
6.20	Tests de DeLong de la formule V5 contre chaque référence	64
6.21	Décomposition de l’apport des composantes anatomiques	64
6.22	AUC des quatre composantes prises isolément, avec intervalles de confiance	66
6.22	AUC des quatre composantes prises isolément, avec intervalles de confiance	67
6.23	Stabilité des pondérations sur deux cents partitions aléatoires	67
6.24	Comparaison des pondérations fixes et réoptimisées	67
6.25	Estimation du surajustement de la formule déployée	68
6.26	Contribution du Module 3	68
6.27	Balayage du poids de la composante de cardiomégalie	69
6.28	AUC globale et par pathologie des formules de fusion successives	70
6.29	Cas de test détaillés	71
6.30	Métriques cliniques du pipeline selon le seuil de décision	72
7.1	Bilan des 4 Piliers du Trustworthy AI	76
7.2	Validation anatomique des cartes Grad-CAM	77
7.3	Mécanismes de signalement implémentés dans le pipeline	79
7.4	Comportement Hors Domaine : Trois Cas Externes	80

7.5	Comparaison du pipeline aux outils cliniques existants	84
8.1	Bilan des contributions par objectif	86
8.2	Moyen terme (6-18 mois)	90
A.1	A.1 Prétraitement de l’Image	95
A.1	A.1 Prétraitement de l’Image	96
A.2	A.2 Calcul du Ratio Cardio-Thoracique	96
A.2	A.2 Calcul du Ratio Cardio-Thoracique	97
A.3	A.3 Segmentation par U-Net	97
A.3	A.3 Segmentation par U-Net	98
A.4	A.4 Classification et Explicabilité Grad-CAM	98
A.4	A.4 Classification et Explicabilité Grad-CAM	99
A.5	A.5 Fusion Multi-Sources — Pipeline V5	100

Chapitre 1

Introduction Générale

1.1 Contexte : Maladies Cardiovasculaires et Imagerie Médicale




Figure 1.1 : Pipeline de dépistage opportuniste du risque cardiovasculaire par radiographie thoracique

Les maladies cardiovasculaires (MCV) constituent la première cause de mortalité à l'échelle mondiale, responsables d'environ 17,9 millions de décès par an selon l'Organisation Mondiale de la Santé (OMS), soit près d'un tiers de la mortalité mondiale totale. Cette réalité épidémiologique dramatique place le dépistage précoce au cœur des priorités de santé publique : une détection anticipée des facteurs de risque permet en effet de réduire significativement la morbi-mortalité cardiovasculaire grâce à une prise en charge thérapeutique et préventive adaptée.

La radiographie thoracique est l'un des examens d'imagerie médicale les plus fréquemment prescrits en pratique clinique mondiale. Peu coûteuse, rapidement disponible et faiblement irradiante, elle est traditionnellement utilisée pour l'évaluation des pathologies pulmonaires et musculo-squelettiques. Cependant, des recherches récentes ont mis en évidence son

potentiel sous-exploité pour l'évaluation de la santé cardiovasculaire : la taille cardiaque, les calcifications vasculaires et les signes de congestion pulmonaire — tous visibles sur une radiographie thoracique standard — sont des indicateurs reconnus du risque cardiovasculaire.

C'est dans ce contexte qu'émerge le concept de dépistage opportuniste (opportunistic screening) : exploiter des examens radiographiques déjà prescrits pour une indication clinique principale afin d'extraire, simultanément et sans coût supplémentaire, des informations pertinentes sur le risque cardiovasculaire du patient. Cette approche représente une rupture paradigmatique dans la pratique radiologique, transformant un examen ponctuel en outil de surveillance systématique du risque cardiovasculaire.

Définition — Dépistage Opportuniste (Opportunistic Screening)

Le dépistage opportuniste désigne l'utilisation secondaire d'un examen médical déjà prescrit pour une indication principale, afin d'extraire des informations diagnostiques supplémentaires concernant d'autres pathologies, sans examens, coûts ou irradiations additionnels pour le patient. Appliqué à la radiographie thoracique, il permet d'intégrer le dépistage cardiovasculaire dans le parcours de soins habituel du patient.

Les avancées récentes en intelligence artificielle (IA), et plus particulièrement en apprentissage profond (Deep Learning), ont ouvert de nouvelles perspectives pour l'analyse automatisée des images médicales. Des architectures telles que les réseaux U-Net pour la segmentation et les réseaux EfficientNet pour la classification ont démontré des performances comparables, voire supérieures, à celles d'experts humains sur des tâches d'imagerie médicale spécifiques. Leur application au dépistage cardiovasculaire par radiographie thoracique constitue un domaine de recherche actif et prometteur, dont ce projet se propose d'explorer les possibilités.

1.2 Problématique et Motivation

Malgré le potentiel considérable de la radiographie thoracique pour le dépistage cardiovasculaire, plusieurs obstacles majeurs limitent son exploitation systématique en pratique clinique. L'interprétation manuelle des radios thoraciques par des radiologues est chronophage, soumise à la variabilité inter-observateur et principalement centrée sur l'indication principale de l'examen. Les facteurs de risque cardiovasculaire secondaires — tels que la cardiomégalie débutante, les calcifications aortiques précoces ou les signes subtils de congestion pulmonaire — sont fréquemment non signalés ou sous-détectés.

Par ailleurs, les systèmes d'IA médicale existants souffrent souvent d'un manque de transparence et d'explicabilité qui freine leur adoption clinique. Un algorithme produisant un score de risque sans justification compréhensible ne peut pas être validé, ni accepté, par le corps médical. La notion de Trustworthy AI — IA de confiance — répond précisément

à cette exigence : un système d’IA est dit digne de confiance lorsqu’il est explicable, transparent, robuste et honnête quant à ses limites.

Ce projet s’inscrit dans cette double problématique : d’une part, développer un système d’IA capable d’extraire automatiquement les indicateurs cardiovasculaires pertinents à partir de radiographies thoraciques de routine ; d’autre part, s’assurer que ce système répond aux exigences de confiance indispensables à tout déploiement en milieu clinique réel. La question centrale que ce travail se propose de résoudre est la suivante :

Question de Recherche

Comment concevoir et valider un pipeline d’IA de confiance capable d’extraire automatiquement les facteurs de risque cardiovasculaire — taille cardiaque (CTR), calcifications vasculaires et congestion pulmonaire — à partir de radiographies thoraciques de routine, et de les fusionner en un score de risque global interprétable, transparent et cliniquement pertinent ?

Cette problématique soulève plusieurs défis techniques et scientifiques : la gestion du décalage de domaine (domain shift) entre datasets hétérogènes d’origines géographiques différentes, l’optimisation de la stratégie de fusion multi-sources sans réentraînement des modèles, et la validation rigoureuse des performances sur une cohorte indépendante à large échelle.

1.3 Objectifs du Projet

En réponse à la problématique posée, ce projet de fin d’études poursuit trois objectifs principaux, alignés avec les orientations définies par l’encadrant Pr. Mohamed El Hassouni :

Objectif 1 — Extraction automatisée des facteurs de risque

Développer un framework d’IA robuste pour l’extraction automatique des trois indicateurs cardiovasculaires principaux identifiables sur radiographie thoracique : (i) la taille cardiaque via le ratio cardio-thoracique (CTR), calculé par segmentation U-Net avec correction spatiale ; (ii) les calcifications vasculaires, détectées par segmentation et classification ; (iii) la congestion pulmonaire, estimée par un classificateur de risque multi-classes.

Objectif 2 — Prédiction du risque cardiovasculaire global

Implémenter et optimiser une stratégie de fusion multi-sources pour agréger les scores partiels extraits par chaque module en un score de risque cardiovasculaire global (0-100%), catégorisé en trois niveaux cliniques : FAIBLE, MODÉRÉ et ÉLEVÉ. L’optimisation des poids de fusion est conduite de façon expérimentale sur 501 images de validation indépendantes, sans réentraînement d’aucun modèle.

Objectif 3 — Validation et Trustworthy AI

Valider les performances du système sur des datasets rétrospectifs de référence (NIH ChestX-ray14, VinDr-CXR, JSRT) et garantir les propriétés d’une IA de confiance : explicabilité par visualisation Grad-CAM, transparence de la décomposition du score, robustesse face au domain shift entre populations, et documentation honnête des limites identifiées.

1.4 Contributions Principales

Les contributions originales de ce travail, par rapport à l’état de l’art existant, sont les suivantes :

- **Pipeline intégré à 4 modules complémentaires.** Contrairement aux approches mono-tâche de la littérature, notre pipeline combine deux réseaux U-Net de segmentation et deux classificateurs EfficientNet-B0 dans une architecture unifiée couvrant les trois facteurs de risque cardiovasculaire principaux identifiables par radiographie thoracique.
- **Correction spatiale du CTR par spacing adaptatif.** Le ratio cardio-thoracique est calculé en centimètres réels grâce à une correction du pixel spacing tenant compte du redimensionnement 512×512 , corrigeant ainsi un biais systématique présent dans les approches naïves en pixels.
- **Validation expérimentale par sept études systématiques.** Elles ont été conduites sur 501 images NIH et ont permis de mesurer la contribution de chaque module par ablation, de comparer les deux sources possibles du signal calcique, d’optimiser la pondération de fusion sans réentraînement, et d’écarter sur preuve trois configurations alternatives — adjonction du module de segmentation, fusion conditionnée par la confiance, et formule à trois composantes.**
- **Intégration native des principes Trustworthy AI.** L’explicabilité (Grad-CAM), la transparence (décomposition du score en contributions individuelles), la robustesse (entraînement multi-dataset pour réduire le domain shift) et l’honnêteté scientifique (documentation exhaustive des limites) sont intégrées comme contraintes de conception, et non comme ajouts a posteriori.
- **Formule optimisée du Pipeline V5.** La formule finale $\text{risk_global} = (0.15 \times s_ctr + 0.40 \times s_cong + 0.10 \times s_calcif + 0.35 \times \text{prob_cardio}) \times 100$, obtenue par recherche exhaustive sous contrainte d’auditabilité, atteint une AUC de 0.8916 [0.8572; 0.9229] sur le jeu de validation NIH. Sa stabilité a été vérifiée par deux cents partitions aléatoires : les quatre pondérations médianes coïncident avec les

valeurs déployées, et le surajustement est estimé à 0.0007 point d'AUC.

1.5 Organisation du Rapport

La suite de ce rapport est organisée en sept chapitres complémentaires, chacun constituant une étape logique dans la démarche scientifique adoptée :

- **Chapitre 2 — État de l'Art** : revue de la littérature sur le dépistage cardiovasculaire par IA, les architectures de segmentation et classification, l'explicabilité et les fondements du Trustworthy AI en médecine.
- **Chapitre 3 — Datasets et Prétraitement** : description des trois datasets utilisés (NIH, VinDr, JSRT), des techniques de prétraitement appliquées et des stratégies de gestion du domain shift.
- **Chapitre 4 — Architecture du Pipeline** : présentation détaillée des quatre modules du pipeline, de leurs architectures respectives et de la stratégie de fusion des scores.
- **Chapitre 5 — Entraînement et Performances** : protocoles d'entraînement, résultats obtenus pour chaque modèle et analyse comparative du domain shift entre les approches mono-dataset et multi-dataset.
- **Chapitre 6 — Études Expérimentales de Validation** : présentation des sept études conduites sur 501 images NIH, des résultats d'ablation, de l'optimisation des poids et du Pipeline V5 final.
- **Chapitre 7 — Trustworthy AI : Synthèse et Discussion** : bilan des quatre piliers de confiance du système, validation de l'explicabilité Grad-CAM, mécanismes d'incertitude et limites identifiées.
- **Chapitre 8 — Conclusion et Perspectives** : synthèse des contributions, discussion des limites et perspectives d'amélioration à court, moyen et long terme.

Chapitre 2

État de l'Art

Ce chapitre présente une revue critique de la littérature couvrant les domaines scientifiques fondateurs de ce projet : le dépistage cardiovasculaire par imagerie, les architectures de Deep Learning appliquées à l'imagerie médicale, les méthodes d'explicabilité, et les fondements du Trustworthy AI en milieu clinique. Chaque section est conclue par un positionnement de notre approche par rapport aux travaux existants.

2.1 Dépistage Cardiovasculaire par Radiographie Thoracique

2.1.1 La radiographie thoracique comme outil de dépistage

La radiographie thoracique (RT) est l'examen d'imagerie médicale le plus couramment réalisé dans le monde, avec plus d'un milliard d'examens effectués annuellement. Initialement conçue pour l'évaluation des pathologies pulmonaires et ostéo-articulaires, la RT offre une fenêtre anatomique unique sur les structures cardiovasculaires : silhouette cardiaque, aorte, vascularisation pulmonaire et médiastin. Plusieurs indicateurs cardiovasculaires cliniquement validés sont directement mesurables sur une RT standard.

Le ratio cardio-thoracique (CTR), défini comme le rapport entre le diamètre transversal maximal du cœur et le diamètre thoracique interne maximal, constitue le marqueur le plus établi. Un CTR supérieur à 0.50 est reconnu comme critère diagnostique de cardiomégalie depuis les travaux fondateurs de Danzer (1919), et reste à ce jour un indicateur de première ligne dans les recommandations des sociétés cardiologiques internationales. Les calcifications de l'aorte et des artères coronaires, visibles sur RT sous forme d'opacités linéaires ou punctiformes, sont associées à un risque cardiovasculaire majoré. La congestion pulmonaire, se manifestant par une redistribution vasculaire et des épanchements pleuraux, est un indicateur précoce d'insuffisance cardiaque.

2.1.2 Du dépistage ciblé au dépistage opportuniste

Le dépistage cardiovasculaire traditionnel repose sur des examens dédiés — échocardiographie, scanner coronarien, score calcique — dont le coût et la disponibilité limitée restreignent

l'accès à grande échelle, particulièrement dans les pays à ressources limitées. Le concept de dépistage opportuniste, formalisé dans la littérature récente, propose une alternative complémentaire : exploiter les examens d'imagerie déjà prescrits pour une indication principale afin d'extraire des informations de risque cardiovasculaire sans examen supplémentaire.

Zambrano Chaves et al. (2023) [1] ont démontré la faisabilité du dépistage opportuniste de la cardiopathie ischémique à partir de scanners abdominopelviens combinés aux données du dossier médical électronique, en utilisant une approche multimodale explicable. Leurs résultats montrent qu'une IA entraînée sur des données de routine peut identifier des patients à haut risque avec une précision comparable aux outils de stratification de risque établis, illustrant le potentiel transformateur du dépistage opportuniste à grande échelle.

Pickhardt et al. (2023) [2] ont conduit une analyse coût-efficacité du dépistage opportuniste par scanner thoracique basé sur l'IA, couvrant simultanément les maladies cardiovasculaires, l'ostéoporose et la sarcopénie. Cette étude établit que l'intégration de l'IA dans l'interprétation radiologique de routine génère un rapport coût-bénéfice favorable, renforçant la justification économique du dépistage opportuniste comme stratégie de santé publique.

Ces travaux fondateurs démontrent que la radiographie thoracique, examen encore plus accessible et moins irradiant que le scanner, représente un terrain privilégié pour le dépistage opportuniste cardiovasculaire. C'est précisément cette opportunité que notre projet se propose d'exploiter par des approches de Deep Learning.

2.2 Deep Learning en Imagerie Médicale : Panorama

2.2.1 Essor du Deep Learning médical

L'apprentissage profond (Deep Learning) a connu une révolution dans le domaine de l'imagerie médicale depuis les travaux fondateurs de Krizhevsky et al. (2012) sur ImageNet. Les réseaux de neurones convolutifs (CNN) permettent d'apprendre automatiquement des représentations hiérarchiques des images, éliminant la nécessité d'une extraction manuelle de caractéristiques et surpassant les approches traditionnelles de vision par ordinateur sur de nombreuses tâches médicales. En radiologie, les applications couvrent la détection de nodules pulmonaires, la classification des pneumonies, la segmentation tumorale et — plus récemment — l'évaluation du risque cardiovasculaire.

Weiss et al. (2024) [3] ont publié dans les *Annals of Internal Medicine* une étude démontrant qu'un modèle de Deep Learning entraîné sur des radiographies thoraciques peut estimer le risque cardiovasculaire à long terme avec une performance diagnostique significative ($AUC > 0.70$). Cette étude de prédiction du risque sur une large cohorte prospective constitue l'une des validations cliniques les plus rigoureuses de l'approche IA

+ radiographie thoracique pour l’évaluation cardiovasculaire, et représente une référence directe pour notre projet.

Zelevnik et al. (2021) [4] ont proposé dans Nature Communications un réseau convolutif profond pour la prédiction du risque cardiovasculaire à partir de scanners thoraciques. Leur approche repose sur la quantification automatique du score calcique aortique et péricardique, atteignant des performances proches des méthodes de référence clinique. Ce travail établit la preuve de concept que des features cardiovasculaires quantifiables peuvent être extraites automatiquement par Deep Learning à partir d’images radiologiques.

2.2.2 Architectures dominantes en imagerie médicale

Trois familles d’architectures dominent l’imagerie médicale contemporaine. Les réseaux entièrement convolutifs (FCN) et leur dérivé U-Net excellent dans les tâches de segmentation sémantique. Les architectures de classification pré-entraînées (ResNet, DenseNet, EfficientNet) bénéficient du transfer learning pour des performances élevées avec des datasets médicaux de taille limitée. Les Vision Transformers (ViT), plus récents, montrent des résultats prometteurs mais nécessitent des volumes de données plus importants. Pour ce projet, nous avons retenu U-Net pour la segmentation et EfficientNet-B0 pour la classification, en justifiant ce choix par leur rapport performance/complexité optimal sur les datasets disponibles.

Tableau 2.1 : Architectures de réseaux profonds dominantes en imagerie médicale

Architecture	Tâche principale	Avantage clé	Limitation
U-Net	Segmentation	Précision pixel parfait	Sensible au bruit
EfficientNet-B0	Classification	Transfer learning efficace	Boîte noire
ResNet-50	Classification	Robustesse profondeur	Paramètres nombreux
Vision Transformer	Classification/Seg.	Attention globale	Données massives requises
DenseNet-121	Détection multi-label	Réutilisation features	Mémoire élevée

2.3 Segmentation par U-Net : État de l’Art et Variantes

2.3.1 Architecture U-Net originale

L’architecture U-Net, proposée par Ronneberger et al. (2015), constitue le standard de référence pour la segmentation d’images médicales. Sa structure symétrique en forme de U comprend un encodeur (chemin contractant) qui capture le contexte sémantique par




Figure 2.1 : Architecture U-Net à quatre niveaux : encodeur, goulot, décodeur et connexions résiduelles

convolutions et max-pooling successifs, et un décodeur (chemin expansif) qui restaure la résolution spatiale par convolutions transposées. La caractéristique fondamentale de U-Net réside dans ses connexions de saut (skip connections) qui concatènent les feature maps de l'encodeur avec le décodeur correspondant, préservant les informations spatiales fines essentielles à une segmentation précise.

Dans le contexte de la segmentation cardiaque sur radiographie thoracique, U-Net a démontré des performances remarquables sur le dataset JSRT, atteignant des scores Dice supérieurs à 0.92 pour la segmentation du cœur avec des masques pixel parfait. Notre implémentation utilise une architecture U-Net à 4 niveaux avec une fonction de perte combinée DiceBCE, offrant un compromis optimal entre précision de segmentation et stabilité d'entraînement.

2.3.2 Variantes et évolutions

Plusieurs variantes de U-Net ont été proposées pour adresser ses limitations : U-Net++ introduit des connexions de saut imbriquées réduisant le gap sémantique encodeur-décodeur ; Attention U-Net intègre des mécanismes d'attention pour focaliser le réseau sur les régions anatomiques pertinentes ; TransUnet combine U-Net avec les Vision Transformers pour une meilleure capture du contexte global. Ces variantes améliorent les performances sur certains datasets mais au prix d'une complexité accrue. Pour ce projet, l'U-Net standard à 4 niveaux a été retenu comme base en raison de sa robustesse prouvée sur les datasets médicaux disponibles.

2.3.3 Défi du domain shift en segmentation

Un défi majeur en segmentation médicale est le domain shift : un modèle entraîné sur un dataset peut exhiber des performances dégradées sur un dataset d’une population différente, d’une modalité d’acquisition différente, ou d’une résolution différente. Dans notre contexte, l’U-Net cardiaque entraîné uniquement sur JSRT, dont les images brutes présentent une intensité moyenne de 0.293, a montré une performance insuffisante sur les images NIH rehaussées par CLAHE, dont l’intensité moyenne atteint 0.548 (PNG américaines 512×512), avec un CTR calculé à 0.464 sur un cas de cardiomégalie confirmée — un résultat cliniquement incorrect. Ce constat a motivé notre approche d’entraînement combiné JSRT+VinDr, qui représente une contribution originale de ce travail.

2.4 Classification par EfficientNet : Transfer Learning Médical

2.4.1 Architecture EfficientNet

EfficientNet, proposé par Tan & Le (2019) de Google Brain, introduit le concept de mise à l’échelle composée (compound scaling) : plutôt que d’augmenter la profondeur, la largeur ou la résolution du réseau indépendamment, EfficientNet les optimise conjointement selon un coefficient de mise à l’échelle unifié. Cette approche produit des modèles atteignant des performances state-of-the-art avec significativement moins de paramètres que les architectures concurrentes. EfficientNet-B0, la version de base de la famille, contient 5.3 millions de paramètres contre 25 millions pour ResNet-50, tout en surpassant ce dernier sur ImageNet.

Pour l’imagerie médicale en niveaux de gris, EfficientNet-B0 nécessite une adaptation de la première couche convolutive, originellement conçue pour des images RGB (3 canaux). Notre implémentation remplace cette couche par une convolution à 1 canal d’entrée, initialisant les poids par la moyenne des poids RGB pré-entraînés — une stratégie de transfer learning qui préserve les représentations visuelles apprises tout en s’adaptant à la modalité radiographique.

2.4.2 Transfer learning en imagerie médicale

Le transfer learning — réutilisation de représentations apprises sur un large dataset source (ImageNet) pour une tâche cible médicale — est devenu la stratégie standard en imagerie médicale. Il adresse le problème fondamental du manque de données annotées :

annoter des images médicales requiert une expertise radiologique coûteuse et chronophage. Des études comparatives ont systématiquement montré que le fine-tuning de modèles pré-entraînés surpasse l’entraînement from scratch sur des datasets médicaux de taille modérée, typiquement inférieurs à 10 000 images.

Dans notre pipeline, deux classificateurs EfficientNet-B0 ont été entraînés par transfer learning sur des datasets distincts : le Module 3 sur VinDr-CXR pour la classification des calcifications (exactitude test = 0.759), et le Module 4 sur NIH ChestX-ray14 pour la classification du risque cardiovasculaire global (AUC macro = 0.8954). Cette approche multi-dataset reflète la diversité des populations cibles et renforce la généralisation du système.

2.5 Explicabilité des Modèles : Grad-CAM et Alternatives

2.5.1 Le problème de la boîte noire en médecine

Les réseaux de neurones profonds, malgré leurs performances remarquables, souffrent d’un déficit d’explicabilité qui constitue un obstacle majeur à leur déploiement clinique. Un clinicien ne peut ni valider ni assumer la responsabilité d’une décision diagnostique fondée sur un algorithme opaque. Ce problème est d’autant plus critique en médecine que les conséquences d’une erreur algorithmique peuvent être directement préjudiciables au patient. Les réglementations européennes récentes (AI Act, RGPD) renforcent cette exigence en imposant le droit à l’explication pour toute décision automatisée affectant un individu.

2.5.2 Grad-CAM : principe et application

Gradient-weighted Class Activation Mapping (Grad-CAM), proposé par Selvaraju et al. (2017), est la méthode d’explicabilité la plus utilisée en imagerie médicale. Son principe consiste à calculer les gradients de la classe prédite par rapport aux activations de la dernière couche convolutive, à les pondérer par leur moyenne spatiale, et à produire une carte de chaleur indiquant les régions de l’image ayant le plus influencé la décision du modèle. Cette approche présente l’avantage d’être applicable à tout CNN sans modification architecturale et de produire des visualisations directement superposables à l’image médicale originale.

Dans notre pipeline, Grad-CAM est intégré au Module 4 (CNN risque cardiovasculaire). La validation de l’explicabilité a confirmé que la carte de chaleur se concentre sur la zone cardiaque centrale pour les cas de cardiomégalie, et sur les régions hilaires pour les cas d’œdème pulmonaire — démontrant que le modèle a appris des features anatomiquement cohérentes et cliniquement interprétables.




Figure 2.2 : Principe du Grad-CAM : de la passe avant à la carte de chaleur superposée

2.5.3 Alternatives et limites de Grad-CAM

D'autres méthodes d'explicabilité ont été proposées : LIME (Local Interpretable Model-agnostic Explanations) génère des explications locales en perturbant l'image d'entrée ; SHAP (SHapley Additive exPlanations) fournit des attributions de features basées sur la théorie des jeux ; Integrated Gradients calcule les gradients intégrés le long d'un chemin entre l'image originale et une référence. Chacune présente des compromis entre fidélité, intelligibilité et coût computationnel. Grad-CAM reste le standard de facto en imagerie médicale en raison de sa simplicité d'implémentation et de la lisibilité de ses visualisations pour les cliniciens. Il convient néanmoins de noter sa limitation principale : Grad-CAM utilise les activations moyennées plutôt que les vrais gradients de chaque neurone, ce qui peut produire des cartes moins précises que Grad-CAM++ ou ScoreCAM dans certains contextes.

2.6 Trustworthy AI en Médecine : Définition et Enjeux

2.6.1 Fondements du Trustworthy AI

Le concept de Trustworthy AI a été formalisé par la Commission Européenne dans ses lignes directrices éthiques pour une IA digne de confiance (2019), définissant sept exigences fondamentales : primauté humaine, robustesse technique, protection de la vie privée, transparence, diversité et non-discrimination, bien-être sociétal, et responsabilité. Dans le domaine médical, ces exigences se traduisent par quatre piliers opérationnels que tout

système d'IA clinique doit satisfaire.

Les 4 Piliers du Trustworthy AI

**** en Médecine**** 1. *Explicabilité* — Le système doit pouvoir justifier ses décisions de manière compréhensible pour le clinicien (ex : Grad-CAM, attention maps). 2. *Transparence* — La composition et la pondération des facteurs de risque doivent être accessibles et vérifiables (ex : décomposition CTR + Calcif + Congestion). 3. *Robustesse* — Le système doit maintenir ses performances sur des populations et des équipements d'acquisition variés (ex : entraînement multi-dataset). 4. *Honnêteté scientifique* — Les limites du système doivent être documentées et communiquées de façon exhaustive, incluant les cas d'incertitude (ex : flags).

2.6.2 Trustworthy AI appliqué à la radiologie cardiovasculaire

Lekadir et al. (2024) [5] ont proposé dans l'European Heart Journal une solution de Deep Learning pour la détection des anomalies structurelles ventriculaires gauches sur radiographie thoracique, en plaçant explicitement le Trustworthy AI au cœur de la conception. Leur travail démontre que l'explicabilité et la robustesse ne sont pas des contraintes contradictoires avec la performance, mais des propriétés complémentaires qui renforcent la validité clinique du système. Cette référence est particulièrement alignée avec notre approche.

Bhave et al. (2024) [6] ont publié dans la même revue un modèle de Deep Learning pour la détection des anomalies ventriculaires gauches sur radiographies thoraciques, validé sur une large cohorte multicentrique. Leur étude établit des benchmarks de performance cliniquement pertinents et discute explicitement des mécanismes d'incertitude et de confiance du système, constituant une référence méthodologique directe pour notre travail.

Ces travaux convergent vers une conclusion commune : la performance algorithmique seule ne suffit pas à légitimer un système d'IA en médecine. La confiance clinique nécessite une architecture de transparence, une validation rigoureuse sur des populations représentatives, et une documentation honnête des cas d'échec. Notre pipeline intègre ces exigences comme contraintes de conception dès la phase de développement.

2.6.3 Limites et défis du Trustworthy AI

Malgré les progrès conceptuels, plusieurs défis persistent dans l'implémentation pratique du Trustworthy AI en radiologie. La validation clinique prospective — nécessaire pour établir la sensibilité et la spécificité dans des conditions réelles — requiert des cohortes

de patients et des partenariats hospitaliers difficiles à mobiliser dans le cadre d’un projet académique. Le domain shift entre populations géographiquement et démographiquement différentes reste un problème ouvert. La calibration des scores de confiance, indispensable pour que les flags d’incertitude soient fiables, nécessite des méthodes spécifiques, telles que la mise à l’échelle de Platt ou de température, encore peu standardisées en imagerie médicale. L’Étude 4 montre par ailleurs que le défaut de calibration du Module 4 n’est pas monotone, le modèle étant sous-confiant dans les intervalles intermédiaires et sur-confiant au-delà de 0.80 : une transformation à paramètre unique ne le corrigerait pas, et une régression isotonique serait mieux adaptée.

2.7 Positionnement de Notre Travail par Rapport à la Littérature

L’analyse de la littérature révèle que les travaux existants sur le risque cardiovasculaire par IA se concentrent majoritairement sur des tâches mono-indicateur : soit la segmentation cardiaque pour le CTR, soit la détection des calcifications, soit la classification du risque global. Rares sont les systèmes proposant une approche multi-indicateurs intégrée avec une stratégie de fusion explicite. Par ailleurs, la dimension Trustworthy AI est souvent traitée a posteriori comme une couche d’explicabilité ajoutée, plutôt que comme une contrainte architecturale de conception.

Tableau 2.2 : Positionnement de Notre Travail par Rapport à la Littérature				
Travail	Modalité	Indicateurs	Fusion	Trustworthy AI
Weiss et al. [3]	RT	Risque global	Non (mono-modèle)	Partielle
Zelevnik et al. [4]	Scanner CT	Score calcique	Non (mono-modèle)	Limitée
Lekadir et al. [5]	RT	Anomalies LV	Non (mono-modèle)	Oui (explicite)
Bhave et al. [6]	RT	Anomalies LV	Non (mono-modèle)	Partielle
Notre pipeline (V5)	RT	CTR + Calcif + Congestion + Cardiomégalie	Oui (pondérée, optimisée)	Oui (4 piliers)

Notre contribution se distingue sur quatre axes principaux. Premièrement, l’approche multi-indicateurs intégrée : contrairement aux systèmes mono-tâche dominants, notre pipeline extrait et fusionne trois indicateurs complémentaires (CTR, calcifications, congestion) en un score de risque global unique. Deuxièmement, la stratégie de fusion optimisée expérimentalement : les poids de la formule finale ont été déterminés par une recherche

systématique sur grille, garantissant une optimalité empirique plutôt qu'une attribution heuristique. Troisièmement, la correction spatiale du CTR par spacing adaptatif, adressant un biais technique non documenté dans les travaux comparables. Quatrièmement, l'intégration native du Trustworthy AI comme contrainte architecturale couvrant explicabilité, transparence, robustesse et honnêteté scientifique.

Synthèse du Positionnement

Notre travail s'inscrit dans la continuité des approches de Weiss et al. [3] et Bhave et al. [6] pour le dépistage cardiovasculaire par radiographie thoracique, en apportant trois innovations complémentaires : (i) la fusion multi-indicateurs avec optimisation expérimentale des poids, (ii) la correction spatiale du CTR par spacing adaptatif, et (iii) l'intégration systématique des quatre piliers du Trustworthy AI comme contraintes de conception — conformément à l'approche pionnière de Lekadir et al. [5] en cardiology IA de confiance.

Chapitre 3

Datasets et Prétraitement

La qualité et la diversité des données d’entraînement constituent le fondement de toute approche de Deep Learning. Ce chapitre présente les trois datasets publics utilisés dans ce projet, leurs caractéristiques respectives, les techniques de prétraitement appliquées, et la stratégie de gestion du domain shift entre populations hétérogènes. La qualité des données est abordée comme premier pilier opérationnel du Trustworthy AI.

Tableau 3.1 : *Les trois corpus publics employés dans le projet*

Dataset	Origine	Volume	Format	Annotation	Usage dans le pipeline
NIH ChestX-ray14	États-Unis	112 120 images	PNG	Labels texte (15 pathologies)	Modules 3A, 4 + Validation
VinDr-CXR	Vietnam	18 000 images	DICOM	Bounding boxes (14 classes)	Modules 2, 3B + U-Net cardio robuste
JSRT Database	Japon	247 images	BMP	Masques pixel parfait	U-Net cardio (précision)

3.1 NIH ChestX-ray14 : Description et Utilisation

3.1.1 Présentation du dataset

Le dataset NIH ChestX-ray14, publié par Wang et al. (2017) et mis à disposition par le National Institutes of Health américain, constitue l’une des plus grandes collections publiques de radiographies thoraciques annotées. Il regroupe 112 120 images frontales en niveaux de gris, issues de 30 805 patients distincts traités au Clinical Center du NIH entre 1992 et 2015. Les images sont fournies au format PNG avec une résolution originale variable (typiquement 1024×1024 pixels) et un pixel spacing encodé dans les métadonnées CSV.

Les annotations couvrent 15 classes pathologiques, obtenues par extraction automatique de rapports radiologiques via traitement du langage naturel (NLP) : Atelectasis, Cardiomegaly, Effusion, Infiltration, Mass, Nodule, Pneumonia, Pneumothorax, Consolidation, Edema, Emphysema, Fibrosis, Pleural Thickening, Hernia, et No Finding. Chaque image peut

porter plusieurs labels simultanément (multi-label). Le CSV associé contient pour chaque image : l’identifiant patient, l’âge, le sexe, la position de vue (PA ou AP), les dimensions originales et le pixel spacing — métadonnées essentielles pour le calcul correct du CTR en centimètres réels.

3.1.2 Utilisation dans notre pipeline

Le NIH ChestX-ray14 est utilisé à deux niveaux dans notre projet. Premièrement, pour l’entraînement du Module 4 (CNN risque cardiovasculaire) : un sous-ensemble équilibré de 6 000 images a été constitué, couvrant les trois classes cibles Normal (No Finding), Cardiomegaly et Edema, à raison de 2 000 images par classe. Deuxièmement, pour la validation expérimentale du Pipeline V5 : 501 images représentatives ont été sélectionnées pour conduire les sept études expérimentales du Chapitre 6, couvrant les trois classes avec des proportions équilibrées.

L’utilisation des métadonnées CSV du NIH est critique pour la correction du spacing : les colonnes `OriginalImage[Width` et `OriginalImagePixelSpacing[x` permettent de calculer le facteur d’échelle lors du redimensionnement 512×512 , garantissant que les mesures CTR sont exprimées en centimètres réels et non en pixels normalisés.

Note Trustworthy AI — Limites d’annotation NIH

Les labels du NIH ChestX-ray14 sont générés automatiquement par NLP à partir de rapports radiologiques, et non par annotation directe d’experts radiologues. Cette méthode introduit un taux d’erreur estimé à 10-20% selon les études de validation indépendantes. Cette limitation est documentée et prise en compte dans l’interprétation de nos résultats : les performances rapportées constituent donc des bornes inférieures de la performance réelle sur des annotations de qualité radiologique.

3.2 VinDr-CXR : Spécificités DICOM et Annotations

3.2.1 Présentation du dataset

VinDr-CXR (Vietnam Doctor Chest X-ray), publié par Nguyen et al. (2022), est un dataset de 18 000 radiographies thoraciques collectées dans deux hôpitaux vietnamiens de référence (Hôpital Bach Mai et Hôpital Huu Nghi). Sa particularité réside dans la qualité de ses annotations : chaque image a été annotée indépendamment par trois radiologues experts, avec consensus sur les désaccords, produisant des bounding boxes précises pour 14

classes pathologiques incluant Cardiomegaly, Calcification, Aortic enlargement, Pneumonia, Pleural effusion, et No finding.

Les images sont fournies au format DICOM (Digital Imaging and Communications in Medicine), standard médical encodant non seulement les pixels mais aussi les métadonnées d’acquisition : équipement radiologique, paramètres d’exposition, PhotometricInterpretation (MONOCHROME1 ou MONOCHROME2), et identifiants patient anonymisés. Le traitement des fichiers DICOM requiert une étape de conversion spécifique : extraction du tableau de pixels, normalisation 0-255, et inversion conditionnelle selon PhotometricInterpretation pour garantir la cohérence visuelle (os en blanc, poumons en noir).

3.2.2 Utilisation dans notre pipeline

VinDr-CXR est utilisé pour trois composantes distinctes du pipeline. Pour le Module 2 (U-Net segmentation calcifications), les bounding boxes annotées des classes Calcification et Aortic enlargement sont converties en masques binaires rectangulaires, constituant la vérité terrain de segmentation pour 3 218 images. Pour le Module 3 (CNN classification calcifications), un dataset équilibré de 2 452 images couvrant Normal (1 000), Calcification (452) et Aortic enlargement (1 000) a été constitué. Pour l’U-Net cardiaque robuste (Section 5.2), les bounding boxes Cardiomegaly de 1 840 images ont été utilisées en complément des masques JSRT.

Une optimisation technique significative a été implémentée : la conversion préalable des fichiers DICOM en PNG (stockés dans /kaggle/working/vindr_png/) réduit le temps de lecture par un facteur 5 à 10 par rapport à la lecture DICOM à la volée, rendant l’entraînement praticable sur les sessions Kaggle à durée limitée.

3.3 JSRT Database : Masques Pixel Parfait

3.3.1 Présentation du dataset

La base de données JSRT (Japanese Society of Radiological Technology), publiée par Shiraishi et al. (2000), contient 247 radiographies thoraciques BMP issues d’hôpitaux japonais, accompagnées de masques de segmentation annotés pixel par pixel par des radiologues experts. Les masques encodent plusieurs structures anatomiques avec des valeurs de pixels distinctes : cœur (valeur 85), poumon gauche (valeur 170), poumon droit (valeur 255) et fond (valeur 0). Cette granularité d’annotation fait de JSRT le standard de référence académique pour la segmentation cardiaque sur radiographie thoracique.

Malgré son volume modeste (247 images), JSRT présente des avantages décisifs : la qualité des annotations pixel parfait, l'absence de bruit d'étiquetage, et la disponibilité de masques cardiaques précis permettant d'évaluer rigoureusement la qualité de la segmentation U-Net. Le dataset est réparti en ensembles train/test prédéfinis (respectivement 199 et 48 images), facilitant la comparaison inter-études.

3.3.2 Extraction du masque cardiaque

L'extraction du masque cardiaque depuis les fichiers de segmentation JSRT nécessite une étape de seuillage : les pixels de valeur 85 sont isolés et convertis en masque binaire (0/255). Cette opération est réalisée lors du chargement du dataset dans la classe JSRTDataset. La précision pixel parfait de ces masques constitue la référence de qualité pour évaluer la segmentation U-Net, mesurée par les métriques Dice et IoU sur le test set JSRT.

3.4 Prétraitement : CLAHE, Redimensionnement et Normalisation

3.4.1 Amélioration du contraste par CLAHE

La radiographie thoracique présente naturellement une distribution de niveaux de gris très hétérogène : les régions pulmonaires aérées sont très claires, tandis que les structures médiastinales et cardiaques sont plus sombres. Cette disparité de contraste peut compromettre la capacité des réseaux de neurones à détecter des structures fines comme les calcifications vasculaires. CLAHE (Contrast Limited Adaptive Histogram Equalization) adresse ce problème en appliquant une égalisation d'histogramme adaptative localement, avec une limite de contraste (clip limit) pour éviter l'amplification du bruit dans les régions uniformes.

Contrairement à l'égalisation globale d'histogramme qui dégrade souvent les images médicales, CLAHE préserve les gradients locaux tout en améliorant la visibilité des structures d'intérêt. Son application aux radiographies thoraciques améliore significativement la détectabilité des calcifications aortiques et coronariennes, structures dont le contraste naturel est faible. Le dataset NIH CLAHE enhanced (disponible sur Kaggle via rahulogoel) est utilisé directement, évitant le recalcul à la volée et garantissant la reproductibilité des expériences.

3.4.2 Redimensionnement et correction du spacing

Toutes les images sont redimensionnées à une résolution uniforme de 512×512 pixels pour les modules U-Net (segmentation) et 224×224 pixels pour les modules EfficientNet (classification). Ce redimensionnement, bien que nécessaire pour l'uniformisation des entrées du réseau, introduit un biais dans le calcul du CTR si les mesures sont effectuées directement en pixels redimensionnés.

Correction Critique — Spacing Adaptatif pour le CTR

Pour calculer le CTR en centimètres réels après redimensionnement 512×512 , un facteur d'échelle est appliqué au pixel spacing original : $scale_factor = largeur_originale / 512$ $spacing_corrigé = spacing_original \times scale_factor$ $heart_cm = (heart_px \times spacing_corrigé) / 10$ Pour les images sans métadonnées CSV (images externes), un spacing par défaut de 0.143 mm/px est utilisé, correspondant à la valeur médiane NIH. Une correction supplémentaire de -0.05 est appliquée pour les vues AP (antéro-postérieures), qui tendent à surestimer le diamètre cardiaque par rapport aux vues PA (postéro-antérieures) de référence.

3.4.3 Normalisation et augmentation de données




Figure 3.1 : Chaîne de prétraitement des radiographies thoraciques

La normalisation des pixels est réalisée par centrage-réduction autour de la moyenne 0.5 avec un écart-type de 0.5, transformant les valeurs $[0,1]$ en $[-1,1]$. Cette normalisation, cohérente avec les poids pré-entraînés EfficientNet, accélère la convergence et stabilise l'entraînement. Les transformations PyTorch appliquées sont identiques pour tous les modules : $Resize \rightarrow ToTensor \rightarrow Normalize$.

L’augmentation de données est différenciée selon les datasets et les phases. Pour JSRT (247 images seulement), une augmentation forte est appliquée : RandomHorizontalFlip, RandomRotation(15°), ColorJitter(brightness=0.3, contrast=0.3) et RandomAffine(translate=0.05). Pour VinDr (volume suffisant), une augmentation modérée est utilisée : RandomHorizontalFlip et RandomRotation(10°). Aucune augmentation n’est appliquée sur les sets de validation et de test, garantissant la fiabilité des métriques d’évaluation.

3.5 Stratégie d’Équilibrage et Gestion du Domain Shift

3.5.1 Déséquilibre de classes et stratégies d’équilibrage

Les datasets médicaux sont intrinsèquement déséquilibrés : les cas pathologiques sont minoritaires par rapport aux cas normaux. Dans NIH ChestX-ray14, la cardiomégalie représente environ 2.5% des images totales, et l’œdème moins de 2%. Sans correction, un classifieur entraîné sur ces données apprend à prédire systématiquement Normal, atteignant une accuracy trompeuse élevée mais une sensibilité nulle sur les pathologies.

Deux stratégies complémentaires ont été adoptées. Pour le Module 4 (NIH), un sous-ensemble strictement équilibré de 6 000 images (2 000 par classe) a été constitué par sur-échantillonnage des classes minoritaires, garantissant des proportions égales lors de l’entraînement. Pour le Module 3 (VinDr), un WeightedRandomSampler PyTorch a été utilisé, attribuant des poids inverses aux fréquences de classes (Normal : 0.82, Calcification : 1.81, Aortic : 0.82), combiné à une CrossEntropyLoss pondérée pour renforcer la pénalisation des erreurs sur la classe minoritaire Calcification.

3.5.2 Domain shift : analyse et stratégies de mitigation

Le domain shift désigne la dégradation de performance d’un modèle lorsque la distribution des données de test diffère de celle des données d’entraînement. Dans notre contexte, trois sources de domain shift ont été identifiées et analysées.

Tableau 3.2 : Sources du décalage de domaine entre les corpus et effets observés			
Source de domain shift	Manifestation	Impact observé	Stratégie adoptée
Distribution d'intensité (JSRT brut → NIH rehaussé par CLAHE)	Intensité moyenne 0.293 contre 0.548 ; statistiques de normalisation par lot inadaptées	Aucune activation au-dessus du seuil : probabilité maximale de 0.4464	Entraînement combiné JSRT + VinDr, ce dernier couvrant une plage d'intensités bien plus large
Format image (BMP 256 ² → PNG 512 ²)	Résolution, bruit, artéfacts de compression	Effet non isolé du décalage d'intensité	Correction spacing adaptatif
Modalité annotation (masques → boîtes englobantes)	Précision de la vérité terrain, variabilité inter-annotateur	Vérité terrain rectangulaire bornant le Dice atteignable sur VinDr	Pondération datasets dans la loss

La stratégie principale de mitigation du domain shift est l’entraînement combiné multi-dataset pour l’U-Net cardiaque : la combinaison de 179 images JSRT, annotées au pixel près, et de 1 840 images VinDr-CXR, annotées par boîtes englobantes, dans un ConcatDataset PyTorch a produit le modèle `UNET_cardio_robust_v2_best.pth`, dont le Dice atteint 0.9580 sur le jeu de test JSRT. Là où le modèle entraîné sur JSRT seul ne produit aucune activation exploitable sur une image NIH, ce modèle mesure un rapport cardio-thoracique valide sans prétraitement particulier.

3.6 Qualité des Données comme Pilier Trustworthy AI

La qualité des données d’entraînement conditionne directement la fiabilité d’un système d’IA médicale. Un modèle entraîné sur des données biaisées, bruitées ou non représentatives reproduira et amplifiera ces biais dans ses prédictions. Dans notre projet, plusieurs décisions méthodologiques ont été prises explicitement pour garantir la qualité et la transparence des données.




Figure 3.2 : Les quatre piliers opérationnels du Trustworthy AI mis en œuvre dans le pipeline

Engagements qualité des données — Trustworthy AI

- 1. Traçabilité complète.** Chaque image employée est identifiable par son *Image Index* NIH ou son *image_id* VinDr, avec les métadonnées associées : spacing, position radiographique, âge, sexe.
- 2. Documentation des biais.** Le biais d’annotation par traitement du langage naturel du corpus NIH, dont le taux d’erreur est estimé entre 10 et 20 %, ainsi que la précision limitée des boîtes englobantes de VinDr, sont explicitement documentés et pris en compte dans l’interprétation des résultats.
- 3. Séparation des jeux de données.** Le partage entre entraînement, validation et test suit une répartition 70/15/15 avec graine fixée à 42. La limite subsistante — l’absence de garantie formelle que les 501 images de validation soient disjointes de l’entraînement du Module 4 — est reconnue en Section 6.10.2.
- 4. Diversité des sources.** Trois corpus d’origines distinctes couvrent des populations, des équipements et des protocoles d’acquisition différents, ce qui réduit le risque de biais lié à un centre unique.

Cette approche de gouvernance des données s’inscrit directement dans les exigences du Trustworthy AI : un système transparent doit être capable de documenter l’origine, la qualité et les limites de ses données d’entraînement, et d’en tenir compte dans la communication

de ses résultats. Les limitations identifiées ici — biais d’annotation, domain shift résiduel, absence de validation clinique prospective — seront reprises et développées dans le Chapitre 7 consacré au Trustworthy AI.

Chapitre 4

Architecture du Pipeline

Ce chapitre présente en détail l'architecture du pipeline d'analyse cardiovasculaire développé dans ce projet. Le pipeline intègre quatre modules complémentaires, chacun dédié à l'extraction d'un indicateur de risque cardiovasculaire spécifique à partir de la radiographie thoracique. La stratégie de fusion de ces indicateurs en un score global est ensuite détaillée, avec une attention particulière portée à la transparence et à la décomposabilité du score — pilier central du Trustworthy AI.

4.1 Vue d'Ensemble : Pipeline 4 Modules




Figure 4.1 : Architecture détaillée du pipeline à quatre modules

Le pipeline reçoit en entrée une radiographie thoracique au format PNG ou DICOM et produit en sortie un score de risque cardiovasculaire global sur une échelle de 0 à 100%, catégorisé en trois niveaux cliniques (FAIBLE, MODÉRÉ, ÉLEVÉ), accompagné d'une carte de chaleur Grad-CAM et d'une décomposition transparente des contributions individuelles de chaque indicateur.

Tableau 4.1 : *Schéma de flux du pipeline*

Radio	MODULE 1			
Thoracique	U-Net	MODULE 2	MODULE 3	MODULE 4 CNN
PNG /	Cardio →	U-Net Calcif	CNN Calcif	Risque + FUSION
DICOM	→ CTR	→ → calcif%	→ → s_calcif	→ Score 0-100%

Le flux de traitement suit une séquence linéaire : l'image brute est d'abord prétraitée (CLAHE, redimensionnement), puis analysée simultanément par les quatre modules spécialisés. Les scores partiels produits — s_ctr, calcif_pct, s_calcif, s_cong — sont ensuite agrégés par la fonction de fusion pour produire le score global. L'ensemble du pipeline est implémenté en Python avec PyTorch et s'exécute sur GPU (NVIDIA T4 sur Kaggle) ou CPU selon la disponibilité.

Tableau 4.2 : *Vue d'ensemble des quatre modules du pipeline*

Module	Entrée	Architecture	Sortie	Dataset entraînement
M1 — U-Net Cardio	Image 512×512	U-Net 4 niveaux	Masque cardiaque → CTR	JSRT (179) + VinDr (1 840)
M2 — U-Net Calcif	Image 512×512	U-Net 4 niveaux	Masque calcifications → calcif%	VinDr (3218)
M3 — CNN Calcif	Image 224×224	EfficientNet- B0	Prob. [Normal, Calcif, Aortic]	VinDr (2452)
M4 — CNN Risque	Image 224×224	EfficientNet- B0	Prob. [Normal, Cardio, Edema]	NIH (6000)
Fusion (Pipeline V5)	s_ctr, s_cong, s_calcif, prob_cardio	Formule pondérée	Score global 0-100 % + niveau	Optimisation sur NIH (501)

4.2 Module 1 — U-Net Cardiaque et Calcul CTR Corrigé

4.2.1 Architecture U-Net à 4 niveaux

Le Module 1 utilise une architecture U-Net à 4 niveaux d'encodeur-décodeur, constituant la colonne vertébrale de la segmentation cardiaque. L'encodeur est composé de quatre blocs de double convolution (couche Conv2D 3×3, BatchNorm, ReLU, Conv2D 3×3,

BatchNorm, ReLU) suivis d'un MaxPooling 2×2 réduisant progressivement la résolution spatiale de 512 à 32 pixels, tout en augmentant le nombre de feature maps de 64 à 512. Un bottleneck à 1024 feature maps capture la représentation sémantique la plus abstraite.

Le décodeur symétrique reconstruit la résolution spatiale par convolutions transposées (ConvTranspose2D 2×2) et concatène à chaque niveau les feature maps correspondantes de l'encodeur via les skip connections. Cette architecture produit un masque de segmentation binaire de même résolution que l'image d'entrée (512×512), avec une activation sigmoïde finale ramenant les valeurs dans $[0,1]$. Le seuil de binarisation retenu est 0.5, valeur standard, identique à celle du Module 2. Ce paramètre s'avère peu critique sur le modèle robuste : le rapport cardio-thoracique mesuré varie de moins de 0.026 sur toute la plage de seuils de 0.30 à 0.90, ce qui atteste que la mesure repose sur une frontière anatomique nette et non sur un artefact de seuillage.

Résumé Architecture U-Net — Module 1

Entrée : image grayscale $1 \times 512 \times 512$ Encodeur : $[64 \rightarrow 128 \rightarrow 256 \rightarrow 512]$ feature maps, MaxPool 2×2 à chaque niveau Bottleneck : 1024 feature maps Décodeur : ConvTranspose2D $[512 \rightarrow 256 \rightarrow 128 \rightarrow 64]$ avec skip connections Sortie : masque binaire $1 \times 512 \times 512$, seuil = 0.5 Paramètres totaux : ~31 millions Fonction de perte : DiceBCELoss (Dice + Binary Cross-Entropy) Optimiseur : Adam (lr=1e-4, weight_decay=1e-5) + ReduceLROnPlateau

4.2.2 Calcul du CTR corrigé

À partir du masque cardiaque binaire produit par l'U-Net, le ratio cardio-thoracique est calculé via une méthode par contours (cv2.findContours), plus précise que la méthode naïve par somme de colonnes de pixels. Le plus grand contour détecté dans la zone anatomique centrale (entre 20% et 80% de la largeur et hauteur de l'image) est retenu comme délimitation cardiaque. Sa bounding box fournit le diamètre cardiaque transversal en pixels, converti en centimètres par le spacing corrigé.

```
# Calcul CTR — extrait simplifié du pipeline contours,
_ = cv2.findContours(mask_cardio, cv2.RETR_EXTERNAL,
cv2.CHAIN_APPROX_SIMPLE) c = max(contours, key=cv2.contourArea) x,
y, w_box, h_box = cv2.boundingRect(c) # Vérification zone anatomique cardiaque
cx, cy = x + w_box//2, y + h_box//2 if w0.20 < cx < w0.80 and h0.20 < cy <
h0.80 : heart_px = w_box # Diamètre thoracique standard = 75% largeur image
thorax_px = int(w * 0.75) # Conversion pixels → cm avec spacing corrigé heart_cm
```

```
= (heart_px * spacing_corrige) / 10 thorax_cm = (thorax_px * spacing_corrige) / 10
ctr_raw = heart_cm / thorax_cm # Correction biais AP vs PA
ctr_corrige = ctr_raw - 0.05 if 'AP' in position else ctr_raw
```

Le score CTR partiel `s_ctr` utilisé dans la fusion est normalisé sur l'intervalle $[0,1]$ par une transformation linéaire tenant compte de la zone cliniquement significative entre $\text{CTR}=0.40$ (normal) et $\text{CTR}=0.60$ (cardiomégalie franche) :

`s_ctr = clip(** (CTR - 0.40) / 0.20 , 0, 1 )**`

Ainsi, un CTR de 0.40 donne `s_ctr=0.0` (risque nul), un CTR de 0.50 donne `s_ctr=0.5`, et tout CTR > 0.60 donne `s_ctr=1.0` (risque maximal). Un CTR > 0.50 déclenche automatiquement un flag de cardiomégalie, indépendamment du score global.

4.3 Module 2 — U-Net Segmentation Calcifications Vasculaires

Le Module 2 partage la même architecture U-Net à 4 niveaux que le Module 1, avec deux différences fondamentales : il est entraîné sur VinDr-CXR avec des bounding boxes de calcifications comme vérité terrain, et son seuil de binarisation est de 0.5 (standard). Sa sortie est un masque binaire des zones calciques détectées, dont la proportion surfacique `calcif_pct` est calculée comme :

`calcif_pct** = (nombre de pixels masque = 1) / (512 × 512) × 100**`

Cette métrique de surface relative est utilisée comme indicateur brut de la charge calcique vasculaire. Les études expérimentales du Chapitre 6 établissent toutefois que le `calcif_pct` mesuré sur les images NIH présente une variance très faible — valeur nulle sur plus de la moitié des images et maximum de 3.13 % — et n'apporte aucun pouvoir discriminant exploitable. Le Module 2 est en conséquence conservé à titre de support visuel dans le rapport d'analyse, mais n'intervient pas dans la formule de fusion du Pipeline V5. Il convient de le distinguer du Module 3, classificateur dédié aux calcifications, dont le score contribue au score final à hauteur de 10 % (Étude 6).

Note — Rôle de M2 dans le Pipeline V5

*Suite aux études expérimentales, le Module 2 (U-Net calcifications) n'entre plus directement dans la formule de fusion du Pipeline V5 optimisé. Son score `calcif_pct` est conservé dans le rapport de diagnostic comme indicateur complémentaire pour le clinicien, mais son poids dans le score global a été ramené à zéro lors de l'optimisation. Cette décision transparente illustre la rigueur scientifique du Trustworthy **AI** :*

documenter les composantes inefficaces plutôt que de les masquer.

4.4 Module 3 — CNN EfficientNet-B0 Classification Calcifications




Figure 4.2 : *Architecture EfficientNet-B0 adaptée au monocanal*

Le Module 3 est un classificateur EfficientNet-B0 entraîné sur VinDr-CXR pour distinguer trois classes : Normal (absence de calcifications), Calcification (calcifications vasculaires confirmées) et Aortic_enlargement (dilatation aortique). Son score de probabilité combiné s_calcif , somme des probabilités des deux classes pathologiques, contribue au score final à hauteur de 10 % (Étude 6).

L’architecture EfficientNet-B0 a été adaptée pour l’imagerie en niveaux de gris : la première couche convolutive RGB (3 canaux) est remplacée par une couche monocanal (1 canal), initialisée par la moyenne des poids pré-entraînés ImageNet. La tête de classification est remplacée par une séquence Dropout(0.4) → Linear(1280→256) → ReLU → Dropout(0.2) → Linear(256→3), entraînée avec une CrossEntropyLoss pondérée pour compenser le déséquilibre de classes (Calcification sous-représentée : 452 images vs 1000 pour les autres).

Le score de risque calcique s_calcif utilisé dans la fusion est défini comme la somme des probabilités des deux classes pathologiques :

$$s_calcif = \text{prob}[***\text{Calcification}] + \text{prob}[\text{Aortic_enlargement}]$$

Un mécanisme de flag d’incertitude est intégré : lorsque la probabilité de la classe prédite est inférieure à un seuil de confiance, une alerte « incertitude → révision médicale recommandée » est automatiquement générée dans le rapport de diagnostic, illustrant le principe de Trustworthy AI appliqué à la gestion de l’incertitude.

4.5 Module 4 — CNN Risque Cardiovasculaire et Grad-CAM

4.5.1 Architecture et entraînement

Le Module 4 est le composant central du pipeline. Basé sur EfficientNet-B0 avec la même adaptation monocanal que le Module 3, il est entraîné sur 6 000 images NIH ChestX-ray14 équilibrées pour classer chaque radiographie en trois catégories : Normal, Cardiomegaly (cardiomégalie) et Edema (œdème pulmonaire). Ces trois classes couvrent les deux principaux tableaux cliniques de risque cardiovasculaire détectables sur radiographie thoracique.

La probabilité de la classe Edema — `prob[Edema]` — constitue le score de congestion pulmonaire `s_cong` utilisé dans la fusion. Ce choix est justifié par la forte association clinique entre l'œdème pulmonaire et l'insuffisance cardiaque congestive, premier signe d'une décompensation cardiovasculaire. La probabilité de la classe Cardiomegaly — `prob[Cardiomegaly]` — est également reportée dans le rapport de diagnostic comme confirmation du CTR calculé par M1.

4.5.2 Intégration Grad-CAM

Le Module 4 intègre nativement un mécanisme Grad-CAM via un hook PyTorch enregistré sur la dernière couche convolutive (`backbone.features[-1]`). Lors de l'inférence, après la passe forward, le gradient de la classe prédite par rapport aux activations sauvegardées est calculé. Les activations sont pondérées par leur moyenne spatiale pour produire la carte de chaleur finale, redimensionnée à 224×224 et superposée à l'image originale avec une pondération 50%/50% (image grise + heatmap JET).

```
# Grad-CAM — implémentation simplifiée (EfficientNetCNN.get_gradcam)
def get_gradcam(self, inp) : self.eval() inp = inp.clone().requires_grad_(True)
self._activations = None out = self.backbone(inp) # forward pass idx =
out.argmax(dim=1).item() # classe prédite self.zero_grad() out[0, idx].backward()
# backprop act = self._activations.detach().cpu().numpy()[0] weights =
act.mean(axis=(1, 2)) # global average pooling cam = sum(w * a for w, a in
zip(weights, act)) cam = cam.clip(min=0) # ReLU if cam.max() > 0 : cam /=
cam.max() # normalisation [0,1] return cam, out
```

La validation de l'explicabilité Grad-CAM a confirmé que la carte de chaleur se concentre anatomiquement sur la zone cardiaque centrale pour les prédictions Cardiomegaly, et sur

les régions hilaires et basales pour les prédictions Edema. Ce résultat démontre que le modèle a appris des représentations anatomiquement cohérentes, et non des artefacts ou des biais liés aux conditions d’acquisition.

4.6 Stratégie de Fusion : Formule et Justification des Poids

4.6.1 Formule initiale du pipeline

La stratégie de fusion initiale du pipeline agrège les trois scores partiels — s_ctr (taille cardiaque), s_calcif (calcifications), s_cong (congestion pulmonaire) — en un score de risque global selon une pondération reflétant l’importance clinique relative de chaque indicateur dans l’évaluation cardiovasculaire. La formule initiale attribue une pondération majoritaire au CTR (50%), reconnu comme l’indicateur le plus robuste et le plus cliniquement validé, et partage équitablement les 50% restants entre calcifications et congestion :

Formule Pipeline Initial (V1)

$$risk_global = (0.50 \times s_ctr + 0.25 \times s_calcif + 0.25 \times s_cong) \times 100 \text{ Où : } s_ctr = clip((CTR - 0.40) / 0.20, 0, 1) [Module 1] \quad s_calcif = prob[Calcification] + prob[Aortic] [Module 3] \quad s_cong = prob[Edema] [Module 4]$$

4.6.2 Catégorisation du score global

Le score global $risk_global \in [0, 100]$ est catégorisé en trois niveaux cliniques. Les seuils ont été déterminés empiriquement sur les 501 images de validation selon deux logiques distinctes : le seuil séparant MODÉRÉ de ÉLEVÉ est fixé à 35 %, valeur maximisant l’indice de Youden — atteint à 34.8 % — pour une sensibilité de 0.928 et une spécificité de 0.766 ; le seuil séparant FAIBLE de MODÉRÉ est fixé à 25 %. Ces valeurs remplacent les seuils de 30 % et 60 % initialement retenus, hérités des formules antérieures. Ces dernières souffraient d’une incompatibilité structurelle : le score s_ctr étant pondéré à 0.45 et borné à 1, une cardiomégalie isolée ne pouvait dépasser 45 %, ce qui rendait la catégorie ÉLEVÉ pratiquement inatteignable pour ce profil de patient. L’introduction de la composante $prob_cardio$ dans la formule V5 lève cette limitation.

Tableau 4.3 : Catégorisation du score global en niveaux cliniques

Niveau de risque	Condition	Couleur	Interprétation clinique
FAIBLE	risk_global < 25 %	Vert	Aucun indicateur anormal détecté — aucune action spécifique
MODÉRÉ	25 % ≤ risk_global < 35 %	Orange	Au moins un indicateur en zone intermédiaire — corrélation au contexte clinique
ÉLEVÉ	risk_global ≥ 35 %	Rouge	Indicateurs concordants en faveur d’une anomalie — avis cardiologique recommandé
INDÉTERMINÉ	CTR hors de [0.30 ; 0.75]	Violet	Segmentation cardiaque non exploitable — score non communiqué, relecture humaine requise

4.6.3 Optimisation expérimentale — Pipeline V5

Les études expérimentales du Chapitre 6 ont conduit à une révision complète de la formule de fusion initiale. L’Étude 1 établit que le retrait de chacune des quatre composantes dégrade l’AUC, et l’Étude 6 détermine leur pondération par recherche exhaustive sous contrainte d’auditabilité. La formule déployée est la suivante :

Formule Pipeline V5 — optimisée (AUC = 0.8916, IC 95 % [0.8572 – 0.9229])

$$\text{risk_global} = (0.15 \times s_ctr + 0.40 \times s_cong + 0.10 \times s_calcif + 0.35 \times \text{prob_cardio}) \times 100$$

Justification empirique : — les quatre composantes sont conservées : le retrait de chacune dégrade l’AUC (Étude 1) — $w_cong = 0.40$ et $w_cardio = 0.35$: les deux sorties du Module 4 portent l’essentiel du pouvoir discriminant — $w_ctr = 0.15$ et $w_calcif = 0.10$: planchers d’auditabilité, sans lesquels l’optimisation libre réduit le score au seul Module 4 — pondération identique à l’optimum de la grille contrainte, rang 1 sur 300 configurations (Étude 6) — progression : 0.7622 (pondération a priori) → 0.7753 (deux composantes) → 0.7924 (trois composantes) → 0.8916 (V5)

4.7 Transparence et Décomposabilité du Score

La transparence de la fusion est une propriété fondamentale du Trustworthy AI appliqué à ce pipeline. Contrairement à un modèle de bout-en-bout produisant un score opaque,

notre architecture expose explicitement la contribution de chaque indicateur au score global, permettant au clinicien de comprendre et de vérifier les bases de chaque prédiction. Pour chaque analyse, le rapport de diagnostic produit une décomposition complète du score de risque, exprimée en points sur 100 :

Exemple de décomposition transparente — image 00000001_000.png (Cardiomegaly NIH)

RISQUE GLOBAL : 57.1 % [ÉLEVÉ] Contribution CTR (15 %) : 15.0 / 15 → $s_ctr = 1.000$ (CTR = 0.628, score saturé) Contribution congestion (40 %) : 0.0 / 40 → $s_cong = 0.000$ (prob[Edema] = 0.0 %) Contribution calcique (10 %) : 7.2 / 10 → $s_calcif = 0.720$ (M3 → Calcification, confiance 0.696) Contribution cardiomégalie (35 %) : 34.9 / 35 → $prob_cardio = 0.997$ Module 2 : visualisation, hors fusion (Étude 2B) Flags actifs : Cardiomégalie (CTR = 0.628 > 0.50) Grad-CAM centré sur la silhouette cardiaque

Cet exemple met en évidence une propriété structurelle de la formule. La contribution du CTR est bornée à 15 points, valeur atteinte ici puisque le score s_ctr est saturé à 1.000. Un patient présentant une cardiomégalie isolée ne pourrait donc, sur la seule foi de la mesure anatomique, dépasser 15 % quelle que soit la sévérité de l'élargissement cardiaque. C'est la composante $prob_cardio$, qui contribue ici pour 34.9 points, qui permet à ce profil d'atteindre la catégorie ÉLEVÉ. Les formules antérieures, dépourvues de cette composante, plafonnaient à 45 % sur ce type de cas et frôlaient leur propre seuil de décision sans le franchir : cette limitation, analysée en Section 6.9.1, motive directement le passage à la formule V5.

Ce plafonnement est d'autant plus notable que le Module 4 attribue à cette image une probabilité de cardiomégalie de 99.7 %. Cette information n'est pas exploitée par la fusion, qui ne retient de ce module que la probabilité d'œdème. La formule écarte ainsi le signal le plus discriminant disponible sur les cas de cardiomégalie pure. Ce constat, cohérent avec les résultats de l'Étude 5 présentée en Section 6.7, désigne l'intégration de $prob[Cardiomegaly]$ dans la stratégie de fusion comme la voie d'amélioration la plus directe du pipeline.

Cette décomposition remplit deux fonctions complémentaires du Trustworthy AI. Pour l'explicabilité, elle permet au clinicien d'identifier quel indicateur contribue le plus au score, et de juger si cette contribution est cliniquement cohérente avec l'image analysée. Pour la robustesse, elle permet de détecter les cas où un seul module domine le score — signal d'une potentielle fragilité de la prédiction nécessitant une révision médicale.

L'architecture modulaire du pipeline présente également un avantage de maintenabilité : chaque module peut être amélioré, remplacé ou recalibré indépendamment sans nécessiter

un réentraînement complet du système. Cette modularité est une propriété essentielle pour un déploiement clinique évolutif, où les modèles doivent pouvoir être mis à jour au fur et à mesure de l’acquisition de nouvelles données cliniques validées.

Chapitre 5

Entraînement et Performances des Modèles

Ce chapitre détaille les protocoles d’entraînement, les hyperparamètres retenus et les résultats obtenus pour chacun des quatre modèles du pipeline. Chaque section analyse les performances selon les métriques adaptées à la tâche (Dice/IoU pour la segmentation, AUC/Accuracy pour la classification) et discute des facteurs explicatifs des résultats observés. Une synthèse comparative conclut le chapitre, suivie d’une analyse de la robustesse et du domain shift dans la perspective du Trustworthy AI.

5.1 Protocole Expérimental et Environnement

5.1.1 Environnement d’exécution

L’ensemble des entraînements a été conduit sur la plateforme Kaggle, en utilisant des notebooks avec accélérateur GPU NVIDIA Tesla T4 (16 Go de VRAM, accès gratuit avec sessions de 30 heures hebdomadaires). Ce choix est motivé par l’absence d’infrastructure GPU locale et par la disponibilité native des datasets NIH et VinDr sur Kaggle, évitant les transferts de données volumineux. Le framework PyTorch (version 2.x) avec CUDA a été utilisé pour tous les modèles.

Tableau 5.1 : *Environnement matériel et logiciel d’exécution*

Composante	Spécification
GPU	NVIDIA Tesla T4 — 16 Go VRAM
Framework DL	PyTorch 2.x + CUDA 11.x
Plateforme	Kaggle Notebooks (sessions 30h/semaine)
Stockage modèles	Kaggle Datasets (upload après entraînement)
Langage	Python 3.10
Bibliothèques	torchvision, pydicom, OpenCV, scikit-learn, pandas, matplotlib

5.1.2 Protocole commun d’entraînement

Un protocole commun a été appliqué à l’ensemble des modèles pour garantir la comparabilité des résultats et la reproductibilité des expériences. Le split dataset suit une répartition 70% entraînement / 15% validation / 15% test, avec une graine aléatoire fixe (seed=42) pour tous les random_split PyTorch. Le meilleur modèle à chaque entraînement est sélectionné selon le critère de la meilleure Val Loss (segmentation) ou de la meilleure Val Accuracy (classification), et sauvegardé sous forme de state_dict PyTorch (.pth).

- **Optimiseur** : Adam (lr initial = $1e-4$, weight_decay = $1e-5$), retenu pour sa convergence rapide et sa robustesse aux gradients bruités, associé à un scheduler adaptatif — ReduceLROnPlateau pour les modules de segmentation (M1, M2) et CosineAnnealingLR pour les modules de classification (M3, M4).
- **Learning rate** : $1e-4$ en valeur initiale, réduit automatiquement d’un facteur 0.5 après 3 époques sans amélioration de la Val Loss. Cette valeur, plus faible que le standard $1e-3$, est adaptée au fine-tuning de poids pré-entraînés ImageNet, qu’un taux trop élevé dégraderait dès les premières itérations.
- **Batch size** : 8 pour les modules de segmentation (contrainte mémoire des images 512×512 sur GPU T4 16 Go) et 32 pour les modules de classification (images 224×224). Ce dimensionnement maximise l’occupation GPU sans dépassement de VRAM.
- **Nombre d’époques** : 20 à 30 selon les modules — 30 pour l’U-Net cardiaque robuste (dataset combiné de 2 019 images), 20 pour l’U-Net calcifications et les deux classificateurs EfficientNet-B0. Le meilleur checkpoint est conservé selon le critère de validation, indépendamment de l’époque finale.
- **Fonction de perte** : DiceBCELoss pour les tâches de segmentation, combinant le coefficient de Dice (sensible au recouvrement des régions, robuste au déséquilibre premier-plan/arrière-plan) et la Binary Cross-Entropy (stabilisant la convergence pixel à pixel). Pour les tâches de classification, une CrossEntropyLoss pondérée par l’inverse des fréquences de classes est utilisée.

5.2 U-Net Cardiaque : JSRT Seul vs JSRT+VinDr

5.2.1 Modèle initial : entraînement sur JSRT seul

L’évaluation sur les images NIH révèle en revanche un comportement radicalement différent. Sur l’image 00000001_000.png, cas de cardiomégalie confirmé par l’étiquette, le modèle ne




Figure 5.1 : *Décalage de domaine du U-Net cardiaque sur une image NIH : modèle JSRT seul, après recalage d'intensité, et modèle JSRT + VinDr*

produit aucun pixel au-dessus du seuil de binarisation : sa probabilité maximale plafonne à 0.3093, contre 0.9999 sur son propre jeu de test. Aucun rapport cardio-thoracique n'est donc calculable.

L'origine de cet effondrement a été recherchée expérimentalement. L'intensité moyenne des images NIH rehaussées par CLAHE s'établit à 0.548, contre 0.252 pour le corpus JSRT d'entraînement, écart de nature à désaccorder les statistiques figées des couches de normalisation par lot. Un recalage des statistiques d'intensité, conduit sans écrêtage d'aucun pixel, restaure effectivement la confiance du modèle : la probabilité maximale remonte à 0.9999. Mais il ne restaure pas sa justesse anatomique — le réseau segmente alors les champs pulmonaires et non la silhouette cardiaque, produisant un rapport de 0.393 là où le modèle robuste mesure 0.628.

Le décalage ne se réduit donc pas à un déplacement de la distribution globale d'intensité. Le rehaussement CLAHE modifie le contraste local, propriété qu'aucune transformation affine ne compense. Ce résultat illustre par ailleurs, sur un module de segmentation, le principe que l'Étude 4 établit sur le classificateur de risque : la confiance affichée par un réseau profond ne renseigne pas sur la justesse de sa réponse.

Diagnostic du décalage de domaine — JSRT vers NIH

La cause du phénomène a été identifiée expérimentalement. L'intensité moyenne des images NIH rehaussées par CLAHE s'établit à 0.548, contre 0.293 pour les images JSRT, soit un décalage de près du double. Les statistiques figées des couches de normalisation par lot ne correspondent plus à cette distribution d'entrée, et les activations s'effondrent au fil des blocs du réseau. La démonstration est directe : un recalage des statistiques d'intensité de l'image NIH sur celles de JSRT — standardisation par score z suivie d'un ajustement à la moyenne et à l'écart-type cibles — restaure une probabilité maximale de 0.9995, sans modifier aucun poids du modèle. Une égalisation d'histogramme produit un résultat équivalent (0.9917), tandis qu'une normalisation min-max reste sans effet, le rehaussement CLAHE saturant déjà les deux extrémités de la dynamique. Le décalage de domaine entre ces deux corpus est donc dominé par la distribution d'intensité, et non par une différence de morphologie des populations. Cette explication est mesurable et corrigible, à la différence d'un argument démographique qui ne serait ni l'un ni l'autre.

5.2.2 Modèle robuste : entraînement combiné JSRT+VinDr

Pour corriger ce domain shift, un second modèle U-Net cardiaque robuste (unet_cardio_robust_v2_bes) a été entraîné sur un dataset combiné ConcatDataset PyTorch : 199 images JSRT (masques pixel parfait) et 1 840 images VinDr Cardiomegaly (bounding boxes converties en masques binaires), soit 2 019 images au total. Les images VinDr DICOM ont été préconverties en PNG pour accélérer le chargement (facteur $\times 5$ -10).

L'entraînement sur 30 époques avec GPU T4 a produit un modèle atteignant un Dice de 0.9580 et un IoU de 0.9198 sur le jeu de test JSRT, valeur pratiquement identique à celle du modèle entraîné sur JSRT seul (0.9585), mais assortie d'une généralisation nettement supérieure sur les images NIH. L'ajout du corpus VinDr préserve donc la précision anatomique tout en apportant la robustesse recherchée. Sur le cas de cardiomégalie de référence, là où le modèle JSRT seul ne produit aucune activation exploitable, le modèle robuste mesure un CTR de 0.628 — valeur stable à 0.026 près sur l'ensemble des seuils de binarisation testés, de 0.30 à 0.90, ce qui atteste que la mesure repose sur une frontière anatomique nette et non sur un artefact de seuillage. La détection de la cardiomégalie. Le score de risque global s'établit alors à 45.0 % [ÉLEVÉ], contre 32.9 % [MODÉRÉ] avec le modèle non corrigé.

Sous la formule V5, cette image obtient un score de 57.1 % et se trouve classée en risque ÉLEVÉ avec une marge confortable. Ce résultat contraste avec celui des formules antérieures, où le score plafonnait à 45.0 % — contribution maximale possible du CTR, la

composante de congestion étant nulle sur cette image — et frôlait le seuil sans le franchir nettement. L’introduction de la composante de cardiomégalie, qui contribue ici pour 34.9 points, lève cette limitation structurelle analysée en Section 6.9.1.




Figure 5.2 : Courbes d’apprentissage du U-Net cardiaque robuste sur 30 époques

Tableau 5.2 : Comparaison des deux U-Net cardiaques sur le jeu de test JSRT		
Critère	JSRT seul (unet_cardio_jsrt_v2_best)	JSRT+VinDr (unet_cardio_robust_v2_best)
Corpus d’entraînement	JSRT 179 img	JSRT (179) + VinDr (1 840) = 2 019 img
Test Dice (JSRT, par image)	0.9585	0.9580
Test IoU (JSRT, par image)	0.9210	0.9198
CTR sur l’image de référence	aucune activation, non calculable	0.628 → cardiomégalie détectée
Risque global sur l’image NIH	non calculable (CTR indéterminé)	57.1 % ÉLEVÉ
Verdict clinique	Aucune structure détectée	Cardiomégalie correctement détectée

Les deux modèles sont évalués sur le même jeu de test JSRT de 48 images, avec un score de Dice calculé image par image puis moyenné. Le modèle entraîné sur JSRT seul atteint 0.9585, le modèle robuste 0.9580 : l’ajout de 1 840 images VinDr préserve la précision anatomique tout en apportant la robustesse hors domaine documentée ci-après.

Ce résultat illustre un principe fondamental en Deep Learning médical : une métrique Dice élevée sur dataset homogène ne garantit pas la généralisation clinique. Le compromis Dice=0.85 vs Dice=0.92 est largement justifié par le gain de robustesse inter-dataset, qui constitue la condition nécessaire à tout déploiement clinique réaliste.

5.3 U-Net Calcifications (VinDr, Dice val = 0.793)

Le Module 2 (unet_calcif_best_kagg.pth) partage la même architecture U-Net à quatre niveaux, entraîné sur 3 218 images VinDr-CXR dont les boîtes englobantes des classes Calcification et Aortic enlargement constituent la vérité terrain de segmentation. Le corpus est fortement déséquilibré : 452 images portent une annotation de calcification contre 3 067 un élargissement aortique, de sorte que le réseau apprend majoritairement à délimiter ces derniers. Le partage produit 2 574 images d’entraînement et 644 de validation, sans jeu de test distinct. L’entraînement sur 20 époques avec GPU T4 atteint sa Val Loss minimale de 0.2654 à l’époque 15.

5.3.1 Résultats et analyse

Le modèle atteint un Dice de 0.793 sur le jeu de validation VinDr, à l’époque 15 qui minimise la Val Loss à 0.2654. Aucun jeu de test distinct n’a été constitué pour ce module, dont les sorties ne contribuent pas au score : la valeur rapportée est donc une performance de validation et non de test, à la différence de celle du Module 1. Ce score est inférieur à celui du modèle cardiaque JSRT en raison de la qualité moindre de la vérité terrain : les bounding boxes rectangulaires sont une approximation grossière des zones calciques réelles, qui sont souvent punctiformes ou linéaires. Cette limitation de la vérité terrain borne structurellement le Dice atteignable, indépendamment de la qualité du modèle.

Tableau 5.3 : Métriques d’entraînement du U-Net calcifications

Métrique	Valeur	Interprétation
Val Loss (DiceBCE)	0.2654	Minimum atteint à l’époque 15 sur 20
Val Dice	0.793	Correct compte tenu de la vérité terrain par boîtes englobantes
Seuil binarisation	0.5	Identique aux autres modules du pipeline
calcif_pct moyen	< 1%	Zones calciques de faible surface relative

L’analyse de la distribution de calcif_pct sur le dataset de validation NIH (501 images) révèle que cette métrique présente une faible variance et une faible corrélation avec les labels de risque cardiovasculaire. Ce constat, approfondis dans l’Étude 2 du Chapitre 6, explique pourquoi M2 est exclu de la formule de fusion optimisée du Pipeline V5.




Figure 5.3 : Courbes d'apprentissage du U-Net calcifications (Module 2) sur 20 époques

5.4 CNN Calcifications (VinDr, exactitude test = 0.759)

Le Module 3 (calcif_model_final.pth) est un classificateur EfficientNet-B0 entraîné sur 2 452 images VinDr-CXR réparties en trois classes : Normal (1 000), Calcification (452) et Aortic_enlargement (1 000). Le déséquilibre de classes est adressé par un WeightedRandomSampler et une CrossEntropyLoss pondérée (Normal : 0.82, Calcification : 1.81, Aortic : 0.82).

5.4.1 Courbe d'apprentissage




Figure 5.4 : Courbes d'apprentissage du CNN calcifications (Module 3) sur 20 époques

La courbe d'apprentissage montre une progression de la Val Accuracy de 64.6 % à l'époque 1 jusqu'à un maximum de 76.8 % à l'époque 12, la valeur se stabilisant ensuite autour de 75 % jusqu'au terme des vingt époques. Le checkpoint déployé est celui de la dernière

époque, dont la Val Accuracy s'établit à 74.7 % ; son évaluation sur le jeu de test donne une exactitude de 0.759 et une moyenne macro de F1 de 0.688, valeurs supérieures à celles du checkpoint de meilleure validation (0.759 et 0.675 respectivement). L'écart croissant entre Train Accuracy (~97 %) et Val Accuracy (~75 %) à partir de l'époque 10 indique un début de surapprentissage, maîtrisé par le scheduler CosineAnnealingLR et les couches Dropout (0.4 et 0.2).

5.4.2 Rapport de classification sur le test set

Tableau 5.4 : *Rapport de classification sur le test set*

Classe	Précision	Rappel	F1-Score	Support
Normal	0.945	0.951	0.948	144
Calcification	0.421	0.324	0.366	74
Aortic_enlargement	0.713	0.788	0.748	151
Macro avg	0.693	0.688	0.688	369
Weighted avg	0.745	0.759	0.750	369

L'analyse par classe révèle une asymétrie significative : la classe Normal est très bien classifiée (F1 = 0.948), Aortic_enlargement est correcte (F1 = 0.748), mais Calcification présente un F1 de 0.366 très faible. Cette performance limitée s'explique par le faible volume de données pour cette classe (452 images seulement, contre 1 000 pour les deux autres) et par la difficulté intrinsèque de détecter des calcifications ponctuelles sur radiographie thoracique sans annotation pixel parfait.

Note Trustworthy AI — Honnêteté sur les Limites du Module 3 Le F1-Score de 0.366 sur la classe Calcification constitue une limite significative, documentée sans détour. Ce score reflète à la fois le volume réduit de données pour cette classe et la difficulté intrinsèque de détecter des calcifications vasculaires sur radiographie simple. L'examen de la matrice de confusion précise la nature de l'erreur : 44 des 74 calcifications, soit 59.5 %, sont classées en dilatation aortique, et 8.1 % seulement en normalité. Le réseau détecte donc bien une anomalie sans parvenir à en distinguer la nature. Cette confusion demeure sans conséquence sur le score du pipeline, dont la composante calcique somme les probabilités des deux classes pathologiques.

Note importante — Le checkpoint évalué ici, `calcif_model_final.pth`, est celui effectivement chargé par le pipeline. Il correspond à la dernière époque et non à celle de meilleure validation ; son évaluation sur le jeu de test donne une exactitude de 0.759 et une moyenne macro de F1 de 0.688, contre 0.759 et 0.675 pour le checkpoint de meilleure validation.




Figure 5.5 : Matrice de confusion du Module 3 sur le jeu de test VinDr

5.5 CNN Risque Cardiovasculaire (NIH, AUC macro = 0.8954)

Le Module 4 (cardio_risk_v2_best.pth) est le composant le plus performant du pipeline. Entraîné sur 6 000 images NIH ChestX-ray14 équilibrées (2 000 par classe : Normal, Cardiomegaly, Edema), il atteint une AUC-ROC macro-moyennée de 0.8954 et une Val Accuracy de 78.4%.

5.5.1 Résultats détaillés par classe

Tableau 5.5 : Résultats détaillés par classe				
Classe	Précision	Rappel	F1-Score	Support
Normal	0.748	0.812	0.778	303
Cardiomegaly	0.726	0.719	0.722	302
Edema	0.801	0.739	0.769	295
Macro avg	0.758	0.756	0.757	900
Exactitude	—	—	0.757	900

Les trois classes présentent des performances équilibrées, signe de l'efficacité du sous-échantillonnage équilibré. La classe Cardiomegaly présente le F1 le plus faible (0.722), ce qui peut s'expliquer par la variabilité morphologique de la cardiomégalie sur les radiographies NIH et par le biais d'annotation NLP (~10-20% d'erreur estimée). La classe Edema, malgré un rappel légèrement plus faible (0.739), présente la meilleure précision (0.801), ce qui est cliniquement souhaitable pour minimiser les fausses alertes de congestion pulmonaire.




Figure 5.6 : Courbes ROC un-contre-tous du Module 4 sur le jeu de test NIH




Figure 5.7 : Matrice de confusion du Module 4 sur le jeu de test NIH

5.5.2 Validation Grad-CAM

La validation de l’explicabilité Grad-CAM a été conduite sur un échantillon représentatif de 15 images couvrant les trois classes. Pour les cas Cardiomegaly, la carte de chaleur se concentre sur la zone cardiaque centrale dans 13/15 cas (86.7%), confirmant que le modèle a appris des features anatomiquement pertinentes. Pour les cas Edema, la carte se concentre sur les régions hilaires et basales dans 11/15 cas (73.3%). Ces résultats valident la cohérence anatomique des décisions du Module 4, un critère essentiel du Trustworthy AI.

5.6 Synthèse Comparative des 4 Modèles

Tableau 5.6 : Synthèse comparative des quatre modèles entraînés

Modèle	Fichier .pth	Dataset	Volume	Métrique principale	Valeur
U-Net Cardio Robuste	unet_cardio_robust_v2_best	JSRT+VinDr	2 019 img	Dice (test JSRT)	0.9580
U-Net Calcif	unet_calcif_best_kagg	VinDr	3 218 img	Val Dice	0.793
CNN Calcif (M3)	calcif_model_final	VinDr	2 452 img	Exactitude test	75.9 %
CNN Risque (M4)	cardio_risk_v2_best	NIH	6 000 img	AUC-ROC macro	0.8954

La synthèse comparative révèle une hiérarchie de performance cohérente avec les contraintes de chaque tâche. Le CNN Risque (M4) atteint les meilleures performances absolues (AUC macro = 0.8954 sur 900 images de test), bénéficiant du plus grand dataset équilibré et de la richesse des features visuelles NIH. L’U-Net Cardiaque Robuste présente le meilleur compromis performance/généralisation grâce à l’entraînement multi-dataset. Les deux modèles de calcification sont contraints par la qualité de leur vérité terrain (bounding boxes).

Bilan des performances — pipeline complet

Quatre cas de test ont été analysés, dont le détail figure en Section 6.9.3. Sur l’image NIH de référence, les quatre composantes concourent à un score de 57.1 %, classé ÉLEVÉ : la CTR mesuré à 0.628 et la probabilité de cardiomégalie de 0.997 concordent l’un et l’autre vers le même diagnostic. Sur les trois images externes, le Module 4 conclut à la normalité avec une confiance comprise entre 0.862 et 0.999.

Le troisième cas est le plus instructif : le CTR y atteint 0.633, valeur dépassant le seuil conventionnel de cardiomégalie, tandis que le classificateur conclut à l'absence d'anomalie. En l'absence d'annotation experte sur ces images, il n'est pas possible de déterminer lequel des deux modules a raison. Ce désaccord illustre deux propriétés du système. D'une part la corrélation entre le score du CTR et celui du Module 4, mesurée à +0.082 sur les 501 images de validation, confirme que ces deux indicateurs portent des informations largement indépendantes. D'autre part la pondération de 0.15 accordée au CTR borne mécaniquement sa contribution à 15 points sur les 35 requis : lorsque le classificateur conclut à la normalité, aucune mesure anatomique ne peut à elle seule renverser cette conclusion.

5.7 Audit du Code d'Entraînement et Corrections Apportées

Une relecture systématique du code d'entraînement, conduite en fin de projet, a mis au jour quatre défauts affectant le Module 1. Leur correction a produit un gain de performance substantiel, et leur documentation constitue une application directe du principe d'honnêteté scientifique retenu au chapitre 2.

Tableau 5.7 : Défauts d'entraînement identifiés lors de l'audit du code et corrections apportées		
Défaut identifié	Effet sur l'entraînement	Correction apportée
Augmentation géométrique appliquée à l'image seule, le masque ne recevant qu'un redimensionnement	environ la moitié des paires image/masque désalignées ; le réseau apprend une corrélation d'intensité en lieu et place d'une géométrie	tirage aléatoire unique, appliqué aux deux tenseurs par l'API fonctionnelle de torchvision
Validation effectuée sur des données augmentées, les deux sous-ensembles pointant vers la même instance de dataset	perte de validation bruitée ; sélection du checkpoint pilotée par le hasard du tirage d'augmentation	deux instances de dataset distinctes, l'une augmentée pour l'entraînement, l'autre non pour la validation, avec indices partagés
Masques VinDr construits par union des boîtes des trois annotateurs	vérité terrain systématiquement élargie sur 90 % du corpus d'entraînement	vote majoritaire pixel à pixel, un pixel n'étant retenu que s'il est couvert par au moins deux annotateurs

Tableau 5.7 : Défauts d’entraînement identifiés lors de l’audit du code et corrections apportées

Défaut identifié	Effet sur l’entraînement	Correction apportée
Score de Dice agrégé sur le lot avant division	pondération implicite par la taille du cœur ; un masque vide produit un score parfait de 1.0 et masque une panne de chargement	calcul image par image puis moyenne, les masques vides étant exclus

Après correction et réentraînement, le score de Dice sur le jeu de test JSRT passe de 0.8547 à 0.9580. Ce gain est mesuré alors même que la nouvelle métrique, calculée par image, est plus exigeante que l’ancienne : l’amélioration réelle excède donc l’écart affiché.

Le premier défaut mérite une attention particulière. Un réseau entraîné sur des paires désalignées ne peut converger vers une segmentation anatomiquement cohérente ; il se rabat sur la seule corrélation qui survive au désordre, à savoir l’intensité locale. Ce comportement explique les cartes de probabilité diffuses observées sur le modèle initial, où les activations se répartissent sur l’ensemble des zones claires de la radiographie sans former de contour cardiaque identifiable.

5.8 Robustesse et Généralisation : Analyse du Domain Shift

La robustesse d’un système d’IA médicale se mesure à sa capacité à maintenir des performances cliniquement acceptables sur des données différentes de celles de l’entraînement. Dans notre projet, trois types de domain shift ont été identifiés, analysés et partiellement mitigés.

5.8.1 Domain shift géographique et morphologique

Le décalage de domaine le plus significatif concerne la distribution d’intensité, entre les images JSRT brutes et les images NIH rehaussées par CLAHE, documenté en Section 5.2. La stratégie d’entraînement combiné JSRT+VinDr a permis de réduire ce shift pour le Module 1, mais un shift résiduel persiste pour les Modules 3 et 4 entraînés uniquement sur VinDr et NIH respectivement. La validation sur trois images externes, analysée en Section 7.4, confirme que les modules CNN maintiennent des prédictions cohérentes sur des images hors dataset, bien qu’une validation clinique formelle reste nécessaire.

5.8.2 Domain shift de modalité d’acquisition

Les radiographies thoraciques varient significativement selon l’équipement radiologique, les paramètres d’exposition, et la position du patient (PA vs AP). Notre pipeline intègre deux mécanismes de correction : la normalisation CLAHE pour homogénéiser le contraste inter-équipements, et la correction AP/PA (-0.05 sur le CTR) pour compenser le biais de projection. Ces corrections, bien que partielles, améliorent la robustesse du calcul CTR sur des images d’origines variées.

5.8.3 Perspectives de robustesse

Plusieurs axes d’amélioration de la robustesse sont identifiés pour des travaux futurs : l’augmentation de données avec des transformations de style (style transfer) pour simuler différents équipements radiologiques ; le fine-tuning sur des données locales marocaines pour adapter le pipeline aux populations et équipements régionaux ; et la validation prospective sur une cohorte hospitalière avec gold standard clinique pour établir la sensibilité et la spécificité réelles du système. Ces perspectives sont détaillées dans le Chapitre 8.

Trustworthy AI — Robustesse comme Exigence de Conception

La robustesse n’est pas une propriété émergente qui se vérifie après coup, mais une contrainte de conception intégrée dès le choix des datasets d’entraînement. Dans notre pipeline, trois décisions architecturales reflètent cette exigence : (i) l’entraînement multi-dataset JSRT+VinDr pour le Module 1, (ii) la correction spatiale adaptative du CTR pour compenser le redimensionnement, et (iii) la diversité géographique délibérée (USA, Vietnam, Japon) des données d’entraînement. Ces choix constituent des engagements de robustesse documentés, dont les limites résiduelles sont honnêtement reconnues.

Chapitre 6

Études Expérimentales de Validation

Ce chapitre présente les sept études expérimentales menées pour valider, analyser et optimiser le pipeline cardiovasculaire. Ces études constituent la contribution empirique centrale de ce projet : elles répondent à des questions scientifiques précises sur la contribution de chaque module, la stratégie de fusion optimale, et les limites du système. Toutes les études opèrent sur des colonnes pré-calculées du fichier CSV de résultats (501 images NIH), sans réentraînement d’aucun modèle — une distinction conceptuelle fondamentale soulignée tout au long de ce chapitre.

Principe Clé — Études sur Scores Pré-calculés

Les sept études expérimentales n’impliquent aucune modification des modèles de Deep Learning. Elles opèrent exclusivement sur les colonnes numériques pré-calculées du fichier `resultats_phase4_v5.csv` : `s_ctr`, `s_calcif`, `s_cong`, `calcif_pct`. Cette approche garantit la séparation stricte entre la phase d’entraînement des modèles (Chapitre 5) et la phase d’optimisation de la stratégie de fusion (ce chapitre), et permet une exploration rapide de l’espace des hyperparamètres sans coût computationnel GPU.

6.1 Dataset de Validation : 501 Images NIH

Le dataset de validation est un sous-ensemble de 501 images NIH ChestX-ray14, sélectionnées de façon à couvrir de manière représentative les trois classes cliniques d’intérêt : Normal (No Finding), Cardiomegaly et Edema. Le tirage est stratifié par classe avec une graine fixée à 42, à raison de 167 images par classe. Le Module 4 ayant été entraîné sur un sous-ensemble de 6 000 images issu du même corpus, la disjonction formelle entre les deux ensembles n’est pas établie : elle supposerait de comparer explicitement les identifiants, ce qui n’a pas été fait. Cette limite est reprise en Section 6.10.2 et devra être levée avant toute publication des résultats.

Tableau 6.1 : Composition du jeu de validation de 501 images

Classe NIH	Effectif	Proportion	Rôle dans les études
Normal (No Finding)	~167	33.3%	Classe de référence négative

Tableau 6.1 : Composition du jeu de validation de 501 images

Classe NIH	Effectif	Proportion	Rôle dans les études
Cardiomegaly	~167	33.3 %	Risque ÉLEVÉ attendu (prob_cardio dominant)
Edema	~167	33.3 %	Risque ÉLEVÉ attendu (s_cong dominant)
Total	501	100%	Dataset de validation complet

Pour chacune des 501 images, le pipeline complet a été exécuté une fois et les scores intermédiaires sauvegardés dans le fichier CSV de résultats. Les colonnes exploitées par les études sont : image, label_reel, s_ctr, s_cong, s_calcif, prob_cardio, calcif_pct, confiance_m3, ctr, ctr_valide, cardio_flag, risk_global et niveau. La métrique d'évaluation principale retenue pour toutes les études est l'AUC-ROC binaire, calculée en binarisant les labels NIH : Cardiomegaly + Edema → Positif (1), Normal → Négatif (0).

6.2 Étude 1 — Ablation : contribution de chaque module

6.2.1 Protocole

L'étude d'ablation quantifie l'apport de chaque composante du score. Deux familles de configurations sont évaluées. La première mesure le pouvoir discriminant de chaque indicateur pris isolément. La seconde retire successivement une composante de la formule déployée, les trois pondérations restantes étant renormalisées de sorte que leur somme demeure égale à l'unité : l'écart entre la formule complète et la formule amputée mesure alors l'apport marginal du module retiré.

Quatre formules de fusion successives sont également comparées, afin de situer la pondération déployée par rapport aux configurations envisagées au cours du projet.

Protocole Étude 1 — Ablation

Composantes isolées : s_ctr, s_calcif, s_cong, prob_cardio

Ablations : formule V5 privée d'une composante, poids renormalisés

Formules comparées : pondération a priori, deux composantes, trois composantes, V5

Métrique : AUC-ROC binaire (positif = Cardiomegaly + Edema, négatif = No Finding)

Jeu d'évaluation : 501 images NIH, scores pré-calculés

6.2.2 Résultats

Tableau 6.2 : *AUC des configurations d'ablation comparées à la formule déployée*

Configuration	AUC-ROC	Écart avec V5
CTR seul (M1)	0.5866	−0.3050
Score calcique seul (M3)	0.7037	−0.1879
Congestion seule (M4)	0.6878	−0.2038
Cardiomégalie seule (M4)	0.6673	−0.2243
V5 sans CTR	0.8863	−0.0053
V5 sans score calcique	0.8848	−0.0068
V5 sans congestion	0.7328	−0.1588
V5 sans cardiomégalie	0.7850	−0.1066
Pondération a priori (0.50 / 0.25 / 0.25)	0.7622	−0.1294
Optimisation à deux composantes	0.7753	−0.1163
Optimisation à trois composantes	0.7924	−0.0992
Pipeline V5 (déployé)	0.8916	référence

Le tableau suivant récapitule l'apport marginal de chaque module, obtenu par différence entre la formule complète et la formule dont il est retiré.

Tableau 6.3 : *Apport marginal de chaque module au score de fusion*

Module	AUC de la composante seule	V5 sans cette composante	Apport marginal
CTR (M1)	0.5866	0.8863	+0.0053
Score calcique (M3)	0.7037	0.8848	+0.0068
Congestion (M4)	0.6878	0.7328	+0.1588
Cardiomégalie (M4)	0.6673	0.7850	+0.1066

6.2.3 Analyse

Trois enseignements se dégagent de ces mesures.

Le premier concerne la validation du principe même de la fusion. La formule complète atteint une AUC de 0.8916, supérieure de 18.8 points à celle du meilleur indicateur pris isolément, à savoir le score calcique du Module 3 à 0.7037. Le retrait de n'importe laquelle des quatre composantes dégrade la performance, ce qui établit que chacune apporte une information non redondante.

Le deuxième concerne la hiérarchie des apports, et il appelle une lecture nuancée. Les deux sorties du Module 4 dominent nettement : le retrait de la composante de congestion coûte 15.9 points d’AUC, celui de la probabilité de cardiomégalie 10.7 points. Les deux composantes anatomiques pèsent en revanche beaucoup moins, avec des apports marginaux de 0.53 et 0.68 point. Cette asymétrie doit être exposée sans détour : l’essentiel du pouvoir discriminant du système provient du classificateur profond, et non des indicateurs anatomiques mesurés.

Le maintien du CTR et du score calcique dans la formule relève par conséquent d’un choix de conception assumé plutôt que d’une nécessité statistique. Ces deux composantes rendent le score décomposable en quantités cliniquement interprétables, condition de l’auditabilité recherchée. La Section 6.8 établit que l’optimisation libre, dépourvue de toute contrainte, annule leurs pondérations et réduit le score au seul Module 4 : le coût de l’auditabilité est chiffré à environ deux points d’AUC.

Le troisième enseignement concerne la hiérarchie des indicateurs isolés. Le rapport cardiothoracique, indicateur radiologique le plus anciennement établi, ferme la marche avec une AUC de 0.5866, en deçà du score calcique et des deux sorties du Module 4. Deux causes se conjuguent, analysées en Section 6.2.4 et en Section 7.5.1 : un effet de dilution lié à l’agrégation de deux pathologies dont une seule relève du CTR, et l’approximation du diamètre thoracique à 75 % de la largeur de l’image.

6.2.4 Distribution des composantes par groupe clinique

L’examen des valeurs moyennes prises par chaque composante dans les trois groupes cliniques éclaire le comportement de la formule.

Tableau 6.4 : *Distribution des composantes par groupe clinique*

Groupe	s_ctr	s_calcif	s_cong	prob_cardio	Score global
Normal (No Finding)	0.400	0.321	0.157	0.127	20.0 %
Cardiomégalie	0.658	0.483	0.072	0.803	45.7 %
Œdème	0.358	0.682	0.918	0.053	50.8 %

Les trois groupes sont bien séparés et les deux groupes pathologiques dépassent le seuil de 35 % retenu pour la catégorie ÉLEVÉ. La spécialisation des composantes apparaît clairement : la probabilité de cardiomégalie atteint 0.803 dans le groupe correspondant contre 0.127 chez les sujets sans anomalie, tandis que la composante de congestion atteint 0.918 dans le groupe œdème contre 0.157 chez les sujets sains.

Une observation mérite d’être relevée, car elle explique la nécessité de la composante de cardiomégalie introduite en Section 6.9.1. La composante de congestion vaut en moyenne 0.072 chez les patients cardiomégaliés, valeur inférieure à celle mesurée chez les sujets sans anomalie. Toute formule accordant un poids prépondérant à cette seule composante produit donc mécaniquement un score plus bas pour les patients cardiomégaliés que pour les sujets sains, c’est-à-dire une prédiction inversée sur ce sous-groupe.

6.2.5 Analyse par sous-groupe pathologique

L’évaluation binaire agrégeant cardiomégalie et œdème en une classe positive unique pénalise structurellement les indicateurs spécifiques d’une seule pathologie. Une analyse par sous-groupe a donc été conduite afin d’évaluer chaque score sur la tâche pour laquelle il est physiologiquement conçu.

Tableau 6.5 : *AUC des composantes évaluées sur leur sous-groupe pathologique propre*

Sous-groupe	s_ctr	s_cong	Module 4 complet
No Finding contre Cardiomegaly	0.659 [0.597 – 0.719]	0.419	0.877
No Finding contre Edema	0.494 [0.433 – 0.556]	0.956	0.942

Le contraste est net et conforme aux attentes physiologiques. Le CTR atteint une AUC de 0.659 sur la détection de la cardiomégalie, contre 0.494 — performance strictement équivalente au hasard — sur la détection de l’œdème. Symétriquement, la composante de congestion atteint 0.956 sur l’œdème et 0.419 sur la cardiomégalie.

Un contrôle de robustesse complète cette analyse. En écartant les 66 images dont le CTR calculé sort de la plage de plausibilité anatomique [0.30 ; 0.75] — signalant un échec de segmentation, voir Section 7.5.3 — l’AUC du CTR sur le sous-groupe Cardiomegaly demeure de l’ordre de 0.655. La faiblesse mesurée n’est donc pas imputable aux échecs de segmentation : elle est structurelle.

Deux enseignements en découlent. D’une part, la faible AUC globale du CTR s’explique en grande partie par un effet de dilution : évalué sur une cible dont la moitié des cas positifs lui est physiologiquement étrangère, l’indicateur voit sa performance apparente réduite d’environ huit points. D’autre part, même sur sa tâche propre, le CTR plafonne à 0.659, valeur inférieure à ce que laisse attendre un indicateur dont la pertinence clinique est établie depuis un siècle. Cette limitation est cohérente avec l’approximation du diamètre thoracique décrite en Section 7.5.1 : le thorax n’étant pas segmenté mais estimé à 75 % de la largeur de l’image, le rapport calculé demeure sensible au cadrage et à la collimation.

L’entraînement du Module 1 en configuration multi-classes, incluant la segmentation des champs pulmonaires, constitue à cet égard la perspective d’amélioration la plus directe.

6.3 Étude 2 — Comparaison des sources du signal calcique

6.3.1 Formulation

Le pipeline comporte deux modules dédiés aux calcifications vasculaires, de natures différentes. Le Module 2 est un réseau de segmentation qui délimite les dépôts et fournit un pourcentage de surface calcifiée. Le Module 3 est un classificateur qui attribue à chaque image une probabilité d’appartenance à trois classes, la somme des deux classes pathologiques constituant un score de risque calcique.

La formule de fusion ne comporte qu’une seule composante calcique. Le choix initial du Module 3 reposait sur un argument d’interprétation — une probabilité de classe s’interprète plus directement qu’un pourcentage surfacique, dont l’usage exige une normalisation arbitraire — formulé avant toute mesure. L’Étude 2 le soumet à une validation expérimentale.

6.3.2 Protocole

La composante calcique de la formule V5 est remplacée successivement par chaque source candidate, les trois autres pondérations demeurant inchangées. Seule la source varie, ce qui rend les configurations directement comparables. Le score du Module 2 est testé selon trois normalisations distinctes — linéaire, racine carrée et binaire par seuillage à 0.5 % de surface — afin d’écarter l’hypothèse selon laquelle sa faiblesse relèverait d’un défaut de mise à l’échelle. Deux combinaisons des deux sources et une configuration dépourvue de tout signal calcique complètent la comparaison.

6.3.3 Résultats

Le pouvoir discriminant des deux sources brutes, mesuré hors de toute fusion, établit un premier constat.

Tableau 6.6 : *Pouvoir discriminant des deux sources du signal calcique*

Source brute	AUC-ROC
Module 3 — probabilité de classe calcique	0.7037
Module 2 — pourcentage de surface segmentée	0.5362

Le pourcentage surfacique produit par le Module 2 se situe à peine au-dessus du hasard. L’insertion de chaque source dans la formule V5 confirme cette hiérarchie.

Tableau 6.7 : *AUC de la formule V5 selon la source du signal calcique*

Source calcique retenue	AUC-ROC	Écart avec M3
Module 3 — classification (déployée)	0.8916	référence
Combinaison M2 et M3 (50 / 50)	0.8896	−0.0020
Combinaison M2 et M3 (60 / 40)	0.8886	−0.0030
Aucun signal calcique	0.8848	−0.0068
Module 2 — normalisation linéaire	0.8826	−0.0090
Module 2 — normalisation racine carrée	0.8825	−0.0091
Module 2 — normalisation binaire	0.8753	−0.0163

Deux constats se dégagent. Le Module 3 domine l’ensemble des variantes du Module 2, avec un écart de 0.90 point sur la meilleure d’entre elles ; ce résultat est robuste au choix de la normalisation, les trois variantes se situant dans une plage de 0.73 point. Surtout, les trois configurations fondées sur le Module 2 obtiennent une AUC inférieure à celle de la configuration dépourvue de tout signal calcique. L’adjonction du pourcentage surfacique dégrade donc activement la performance de la fusion, au lieu de simplement ne rien lui apporter.

6.3.4 Interprétation

L’analyse des deux signaux par groupe clinique éclaire cette contre-performance.

Tableau 6.8 : *Signal des deux modules calciques par groupe clinique*

Groupe	M2 — surface moyenne	M2 — proportion au-delà de 0.5 %	M3 — score moyen
Normal	0.311 %	26.9 %	0.321
Cardiomégalie	0.452 %	34.7 %	0.483
Cedème	0.308 %	23.4 %	0.682

L'étendue inter-groupes du signal du Module 2 se limite à 0.144 point de pourcentage, contre 0.361 pour celui du Module 3, soit un rapport de un à deux et demi. La surface segmentée est pratiquement identique dans les trois groupes cliniques : le signal est noyé dans sa propre variabilité, dont l'écart-type atteint 0.57 point.

La cause en est identifiable et tient à la nature de la vérité terrain. Les annotations de VinDr-CXR sont constituées de boîtes englobantes rectangulaires, alors que les calcifications vasculaires sont des structures ponctiformes ou linéaires. Le réseau de segmentation apprend donc à reproduire des rectangles, et le pourcentage surfacique qu'il produit mesure l'aire d'une boîte prédite bien davantage qu'une charge calcique. Un coefficient de Dice élevé traduit une bonne reproduction de ces boîtes, non une quantification fidèle du calcium.

Ce résultat illustre un principe qui dépasse le cas particulier des calcifications : **une métrique de performance élevée sur une tâche intermédiaire ne garantit pas l'utilité du module au sein du système**. Le Module 2 atteint un coefficient de Dice de 0.793, supérieur à ce que laisserait attendre la difficulté de la tâche, tout en produisant un score qui dégrade la fusion. Le Dice et l'AUC mesurent en outre des tâches distinctes — recouvrement de pixels pour l'un, pouvoir de discrimination pour l'autre — et ne se comparent pas directement.

6.3.5 Décision

Le score du Module 3 est retenu comme source unique du signal calcique. Le Module 2 est maintenu dans l'architecture à titre de support de visualisation : la localisation des dépôts détectés est affichée dans le rapport d'analyse, où elle permet au lecteur de situer les régions concernées, sans contribuer au score.

6.4 Étude 2B — Le Module 2 apporte-t-il une information complémentaire ?

L'Étude 2 a comparé les deux modules calciques en tant que sources concurrentes. L'Étude 2B pose la question complémentaire : le pourcentage surfacique apporte-t-il une information que le classificateur ne capte pas, et qui justifierait de l'ajouter en cinquième composante plutôt que de le substituer ?

Un balayage du poids attribué à ce score, de 0 à 30 %, a été conduit avec redistribution proportionnelle sur les quatre autres termes.

Tableau 6.9 : *Effet de l’adjonction du Module 2 en cinquième composante*

Poids accordé à M2	w_ctr	w_cong	w_calcif	w_cardio	AUC-ROC	Écart
0.00	0.150	0.400	0.100	0.350	0.8916	référence
0.05	0.142	0.380	0.095	0.332	0.8918	+0.0002
0.10	0.135	0.360	0.090	0.315	0.8888	−0.0028
0.15	0.128	0.340	0.085	0.297	0.8845	−0.0071
0.20	0.120	0.320	0.080	0.280	0.8787	−0.0129
0.25	0.112	0.300	0.075	0.262	0.8675	−0.0241
0.30	0.105	0.280	0.070	0.245	0.8514	−0.0402

Le gain maximal atteint 0.0002 point d’AUC, valeur correspondant au bruit d’arrondi. Au-delà d’un poids de 0.10, la performance se dégrade régulièrement, la perte atteignant 4.0 points pour un poids de 0.30.

Le Module 2 est donc définitivement écarté de la formule de fusion, cette conclusion étant établie contre la formule effectivement déployée et non contre une configuration antérieure. Le résultat est cohérent avec le diagnostic de l’Étude 2 : le pourcentage surfacique ne mesure pas une charge calcique mais l’aire d’une boîte d’annotation, et ne porte en conséquence aucune information exploitable pour la prédiction du risque.

6.5 Étude 3 — Sensibilité de la formule à ses pondérations

6.5.1 Formulation

Les pondérations de la formule ayant été déterminées par optimisation, une question se pose immédiatement : la performance du système dépend-elle d’un réglage fin, auquel cas elle serait fragile et probablement surajustée au jeu d’évaluation, ou demeure-t-elle stable dans un large voisinage ? L’Étude 3 apporte trois éléments de réponse.

6.5.2 Balayage univarié

Chaque pondération est balayée de 0 à 0.80 par pas de 0.05, les trois autres étant réduites proportionnellement de sorte que la somme demeure égale à l’unité.

Tableau 6.10 : *Sensibilité de l'AUC à chacune des quatre pondérations*

Composante	Valeur dans V5	Optimum	Plage tolérée	Amplitude
CTR (M1)	0.15	0.10	[0.05 ; 0.20]	0.2391
Congestion (M4)	0.40	0.40	[0.35 ; 0.40]	0.1588
Score calcique (M3)	0.10	0.10	[0.05 ; 0.15]	0.1310
Cardiomégalie (M4)	0.35	0.35	[0.35 ; 0.40]	0.1066

La plage tolérée désigne l'intervalle de valeurs pour lesquelles l'AUC demeure à moins de 0.005 de son maximum. L'amplitude mesure l'écart entre les AUC extrêmes du balayage.

Une précaution d'interprétation s'impose sur cette dernière colonne. L'amplitude élevée observée pour le CTR ne signifie pas que cette composante est déterminante : elle mesure la dégradation induite par une pondération excessive, le balayage atteignant des configurations où le score se réduit pratiquement au seul CTR, dont l'AUC isolée est de 0.5866. L'apport marginal de chaque module est établi par l'Étude 1, non par cette mesure.

6.5.3 Perturbation aléatoire des pondérations

Un millier de configurations ont été tirées au hasard dans le voisinage de la pondération déployée, chaque poids étant perturbé par un bruit gaussien d'écart-type 0.05 avant renormalisation.

Tableau 6.11 : *Dispersion de l'AUC sur mille pondérations perturbées*

Statistique	Valeur
AUC médiane	0.8870
Intervalle 5 – 95 %	[0.8770 ; 0.8934]
Minimum observé	0.8646
Maximum observé	0.8986
Écart-type	0.0052

Plus de la moitié des tirages, soit 51.7 %, demeurent à moins de 0.005 d'AUC de la configuration déployée, et le pire cas observé se situe à 0.8646, soit une perte de 2.7 points seulement. La performance du système ne repose donc pas sur un réglage fin des pondérations, ce qui limite le risque de surajustement au jeu d'évaluation.

6.5.4 Position dans l'espace des configurations admissibles

Une recherche exhaustive a été conduite sur l'ensemble des pondérations satisfaisant les contraintes d'auditabilité définies en Section 6.8.2, avec un pas de 0.05. Ce protocole représente 300 configurations.

Tableau 6.12 : *Position dans l'espace des configurations admissibles*

AUC-ROC	w_ctr	w_cong	w_calcif	w_cardio
0.8916	0.15	0.40	0.10	0.35
0.8902	0.15	0.35	0.15	0.35
0.8883	0.20	0.35	0.10	0.35
0.8870	0.20	0.35	0.15	0.30
0.8867	0.15	0.35	0.10	0.40

La pondération déployée coïncide exactement avec l'optimum de la grille contrainte. Les cinq meilleures configurations se tiennent dans un intervalle de 0.49 point et conservent toutes les quatre modules, ce qui confirme que plusieurs pondérations voisines produisent une performance équivalente. Un bootstrap sur deux cents rééchantillonnages situe l'AUC médiane à 0.8936, avec un intervalle de confiance à 95 % de [0.8597 ; 0.9233] : l'écart entre les configurations voisines est très inférieur à la largeur de cet intervalle, et ces configurations ne sont donc pas distinguables statistiquement.

6.6 Étude 4 — Gating par la confiance et calibration des classificateurs

6.6.1 Principe

Le mécanisme de fusion conditionnée par la confiance, ou *confidence-gated fusion*, consiste à neutraliser la contribution d'un module lorsque sa confiance est jugée insuffisante. Formellement, la composante concernée est multipliée par une fonction indicatrice :

Formule du gating par la confiance

$s(\cdot) = s \times 1[\max(\text{softmax}) \geq \text{seuil}]$ Le mécanisme est évalué sur les deux classificateurs du pipeline, le Module 3 pour la composante calcique et le Module 4 pour la composante de cardiomégalie. Seuils balayés : de 0.20 à 0.95 par pas de 0.05

La condition qui rend ce mécanisme opérant mérite d’être explicitée : la confiance doit être **informative**, c’est-à-dire sensiblement plus élevée sur les prédictions correctes que sur les prédictions erronées, et suffisamment **dispersée** pour qu’un seuil réaliste désactive un nombre utile de prédictions.

6.6.2 Distribution de la confiance

Tableau 6.13 : *Distribution de la confiance des deux classificateurs*

Statistique	Module 3 (calcique)	Module 4 (risque)
Minimum	0.4000	0.4340
Médiane	0.8710	0.9960
Moyenne	0.8332	0.9352
Maximum	0.9990	1.0000
Écart-type	0.1571	0.1273

La proportion d’images franchissant chaque seuil éclaire la faisabilité du mécanisme.

Tableau 6.14 : *Proportion de modules actifs selon le seuil de confiance*

Seuil	Module 3 actif	Module 4 actif
0.50	96.4 %	99.0 %
0.60	87.4 %	94.6 %
0.70	78.0 %	91.8 %
0.80	65.7 %	87.2 %
0.90	46.3 %	81.2 %
0.99	12.2 %	61.1 %

La distribution de la confiance du Module 4 est fortement concentrée dans sa queue haute : 81.2 % des images reçoivent une confiance supérieure ou égale à 0.90, et la médiane atteint 0.9960. Un seuil placé en deçà de 0.90 ne désactive donc pratiquement aucune prédiction.

6.6.3 La confiance discrimine-t-elle les erreurs ?

Le Module 4 produit 435 prédictions correctes et 66 erronées sur les 501 images, au sens de la binarisation retenue.

Tableau 6.15 : *Confiance moyenne du Module 4 selon la justesse de sa prédiction*

Issue de la prédiction	Effectif	Confiance moyenne
Prédiction correcte	435	0.9496
Prédiction erronée	66	0.8406

L'écart de 0.1090 est substantiel, et la capacité de la confiance à prédire sa propre justesse atteint une AUC de 0.7369. La confiance porte donc une information réelle sur la qualité de la prédiction.

Elle demeure toutefois mal calibrée. L'erreur de calibration attendue, mesurée sur dix intervalles de confiance, s'établit à 0.0754.

Tableau 6.16 : *Diagramme de fiabilité du Module 4 par intervalle de confiance*

Intervalle de confiance	Effectif	Confiance annoncée	Justesse observée	Écart
[0.40 ; 0.50]	5	0.4648	0.4000	+0.0648
[0.50 ; 0.60]	22	0.5360	0.5909	−0.0549
[0.60 ; 0.70]	14	0.6489	0.7143	−0.0654
[0.70 ; 0.80]	23	0.7553	0.7391	+0.0162
[0.80 ; 0.90]	31	0.8563	0.7419	+0.1144
[0.90 ; 1.00]	406	0.9888	0.9113	+0.0774

Le dernier intervalle est le plus significatif : il rassemble 81 % du jeu d'évaluation, et le modèle y annonce une confiance de 0.9888 pour une justesse observée de 0.9113. La surestimation atteint 7.7 points sur la très grande majorité des images.

Le défaut de calibration n'est en outre pas monotone : le modèle est sous-confiant dans les intervalles intermédiaires et sur-confiant au-delà de 0.80. Un recalibrage par mise à l'échelle de température, qui applique une transformation monotone unique, ne corrigerait pas simultanément ces deux comportements.

6.6.4 Résultats du gating

Tableau 6.17 : *Effet du gating par la confiance sur l'AUC du pipeline*

Module gâté	Seuil optimal	AUC obtenue	Gain
Module 3 (composante calcique)	0.50	0.8932	+0.0016
Module 4 (composante cardiomégalie)	0.45	0.8934	+0.0017

Aucun des deux gatings n’atteint le seuil de significativité de 0.005 retenu. Au-delà de 0.60, la performance se dégrade régulièrement dans les deux cas, la perte atteignant 1.9 point pour un seuil de 0.95.

6.6.5 Diagnostic

L’échec du mécanisme ne tient pas à une absence d’information dans la confiance, contrairement à ce qu’une lecture rapide pourrait suggérer. Il tient à la **forme de sa distribution**. La composante utile de la confiance est concentrée dans une queue haute très dense : un seuil bas ne désactive presque rien, et un seuil élevé écarte une majorité de prédictions correctes, puisque 91 % des prédictions au-delà de 0.90 sont justes. Un seuil binaire ne parvient pas à exploiter une information ainsi distribuée.




Figure 6.1 : Gating par la confiance : effet du seuil, calibration du Module 4 et séparation des erreurs

L’analyse par groupe clinique complète ce diagnostic.

Tableau 6.18 : Confiance des deux classifieurs par groupe clinique			
Groupe	Confiance M3	Confiance M4	M4 au-delà de 0.90
Normal	0.8654	0.9175	75.4 %
Cardiomégalie	0.8278	0.9273	80.2 %

Tableau 6.18 : *Confiance des deux classificateurs par groupe clinique*

Groupe	Confiance M3	Confiance M4	M4 au-delà de 0.90
Œdème	0.8064	0.9609	88.0 %

Le Module 3 est plus assuré lorsqu’il conclut à la normalité, comportement cohérent avec le F1 de 0.366 obtenu sur la classe Calcification : il détecte correctement l’absence d’anomalie, moins bien sa présence. Le Module 4 présente le profil inverse, sa confiance étant maximale sur l’œdème, classe qu’il discrimine le mieux.

La stratégie de fusion à pondération fixe est en conséquence conservée. Ce résultat négatif documente une limite de calibration réelle et constitue le préalable identifié à toute reprise de cette approche, discutée en Section 8.2.1.

Trustworthy AI — Leçon sur la calibration

La confiance affichée par un réseau profond ne constitue pas un indicateur direct de la fiabilité de sa prédiction. Le Module 4 annonce une confiance moyenne de 0.9888 sur 406 images pour une justesse observée de 0.9113. Cette surestimation systématique doit être connue de tout utilisateur du système : une prédiction assortie d’une confiance de 0.99 n’est pas certaine à 99 %. Le recalibrage des probabilités constitue une perspective prioritaire, dont le Chapitre 8 précise les modalités.

6.7 Étude 5 — Comparaison au classificateur end-to-end

6.7.1 Formulation

Les Études 1 à 4 comparent entre elles différentes stratégies de fusion, sans jamais confronter le pipeline à l’alternative la plus simple : l’utilisation directe du classificateur du Module 4, sans aucune fusion. Cette comparaison constitue pourtant le test le plus exigeant de la valeur ajoutée de l’architecture modulaire. Le score de référence retenu est $1 - \text{prob}[\text{Normal}]$, qui agrège les deux pathologies cibles et se calcule sans aucun traitement supplémentaire.

6.7.2 Résultats

Tableau 6.19 : *AUC des configurations comparées, avec intervalles de confiance*

Configuration	AUC-ROC	IC 95 %
Pondération a priori (0.50 / 0.25 / 0.25)	0.7622	[0.7167 – 0.8089]
Optimisation à deux composantes	0.7753	[0.7299 – 0.8154]
Optimisation à trois composantes	0.7924	[0.7500 – 0.8331]
Pipeline V5 (déployé)	0.8916	[0.8572 – 0.9229]
Module 4 seul (1 – prob[Normal])	0.9094	[0.8792 – 0.9362]

Tableau 6.20 : *Tests de DeLong de la formule V5 contre chaque référence*

Comparaison	Δ AUC	p (test de DeLong)
V5 contre pondération a priori	$+0.1294 \pm 0.0177$	< 0.0001 — significatif
V5 contre deux composantes	$+0.1164 \pm 0.0172$	< 0.0001 — significatif
V5 contre trois composantes	$+0.0992 \pm 0.0150$	< 0.0001 — significatif
V5 contre Module 4 seul	-0.0178 ± 0.0119	0.1358 — non significatif

Le Module 4 employé seul devance le pipeline complet de 1.78 point d'AUC, écart qui n'atteint pas le seuil de significativité statistique. Les deux configurations sont donc indistinguables sur ce jeu d'évaluation.

6.7.3 Décomposition de l'apport des composantes anatomiques

La formule V5 accorde une pondération cumulée de 0.75 aux deux sorties du Module 4, contre 0.25 aux deux composantes anatomiques. Une mesure directe précise l'apport de ces dernières.

Tableau 6.21 : *Décomposition de l'apport des composantes anatomiques*

Configuration	AUC-ROC
V5 réduite aux seules composantes du Module 4	0.8872
V5 complète	0.8916
Apport des composantes anatomiques	+0.0044

Une recherche exhaustive de pondération entre le CTR et le signal complet du Module 4 place l'optimum en $w_{ctr} = 0.00$: sous cette forme de combinaison convexe, l'adjonction du CTR dégrade l'AUC de façon monotone. La corrélation de Pearson entre les deux scores s'établit à $+0.082$, valeur faible et non significative au seuil de 5 % ($p = 0.0657$),

ce qui confirme que le CTR porte une information largement indépendante — mais d’une intensité insuffisante pour améliorer la discrimination.

Une régression logistique en validation croisée à cinq plis, qui apprend la pondération au lieu de l’imposer, nuance légèrement ce constat : l’AUC passe de 0.8762 pour le Module 4 seul à 0.8873 avec adjonction du CTR et du score calcique, soit un gain de 0.0111. La combinaison linéaire optimale extrait donc une information que la pondération convexe ne capte pas, sans que ce gain atteigne la significativité.

6.7.4 Interprétation

Ces résultats doivent être lus à la lumière du protocole d’évaluation, sous peine d’être mal interprétés.

Le critère de vérité terrain est constitué des étiquettes NIH extraites par traitement automatique du langage naturel à partir des comptes rendus radiologiques. Le Module 4 a précisément été entraîné à reproduire ces étiquettes sur ces mêmes classes. Mesurer sa concordance avec elles revient donc, en partie, à mesurer sa capacité à se reproduire lui-même. Le protocole l’avantage structurellement, et l’écart de 1.78 point ne peut être interprété comme une supériorité clinique.

L’argument en faveur de l’architecture modulaire ne repose pas sur la performance mais sur trois propriétés que le classificateur unique ne possède pas. Le score se décompose en quatre contributions chiffrées, dont deux correspondent à des mesures anatomiques que le clinicien peut vérifier lui-même sur l’image. Les défaillances sont localisables : lorsque la segmentation cardiaque échoue, l’état INDÉTERMINÉ est déclenché, alors qu’un classificateur unique produirait une probabilité d’apparence normale. Enfin les composantes sont inspectables séparément, ce qui rend visibles les désaccords entre modules, comme l’illustre le cas externe analysé en Section 7.4.

La formulation honnête du résultat est donc la suivante : **le pipeline atteint une performance statistiquement indistinguable de celle du classificateur end-to-end, tout en produisant un score décomposable en indicateurs cliniquement interprétables.**

6.8 Étude 6 — Validation des pondérations et rôle du Module 3

6.8.1 Formulation

Les quatre pondérations ayant été déterminées par optimisation sur les 501 images qui servent également à rapporter la performance finale, cette non-indépendance expose à un risque de surajustement. L'Étude 6 le quantifie par validation en demi-échantillons répétés, et examine par la même procédure la contribution du Module 3, dont l'apport marginal mesuré à l'Étude 1 est faible.

6.8.2 Contraintes d'auditabilité

Une observation préalable détermine le protocole d'optimisation. Une recherche exhaustive **non contrainte** sur les quatre pondérations converge vers la solution $w_{\text{ctr}} = 0.00$, $w_{\text{cong}} = 0.50$, $w_{\text{calcif}} = 0.00$, $w_{\text{cardio}} = 0.50$, pour une AUC de 0.9084. Cette solution annule les deux composantes anatomiques et réduit le score aux seules sorties du Module 4, retrouvant ainsi la performance du classificateur seul.

Ce résultat est cohérent avec l'analyse de la Section 6.7.4 : l'optimiseur, évalué sur des étiquettes que le Module 4 a été entraîné à reproduire, converge naturellement vers ce module. Il est en revanche incompatible avec l'objectif d'auditabilité qui structure ce travail, un score dépourvu de composante anatomique n'étant plus décomposable en quantités vérifiables par le clinicien.

Des contraintes de plancher ont donc été imposées à l'espace de recherche : $w_{\text{ctr}} \geq 0.15$, $w_{\text{cong}} \geq 0.15$, $w_{\text{calcif}} \geq 0.10$ et $w_{\text{cardio}} \geq 0.40$. Ce choix de conception est explicite et son coût est chiffré à 1.68 point d'AUC. Il est assumé comme tel.

6.8.3 Recherche exhaustive sous contrainte

L'espace admissible comporte 300 configurations pour un pas de 0.05. La pondération déployée en constitue l'optimum exact, comme l'établit le tableau de la Section 6.5.4. Les AUC des quatre composantes prises isolément, assorties de leurs intervalles de confiance bootstrap, situent les ordres de grandeur.

Tableau 6.22 : AUC des quatre composantes prises isolément, avec intervalles de confiance

Composante	AUC-ROC	IC 95 %
s_ctr (Module 1)	0.5866	[0.5373 – 0.6359]
s_calcif (Module 3)	0.7037	[0.6555 – 0.7512]
s_cong (Module 4, œdème)	0.6878	[0.6446 – 0.7326]

Tableau 6.22 : *AUC des quatre composantes prises isolément, avec intervalles de confiance*

Composante	AUC-ROC	IC 95 %
prob_cardio (Module 4)	0.6673	[0.6198 – 0.7142]

6.8.4 Validation par demi-échantillons répétés

À chaque itération, les 501 images sont partitionnées aléatoirement en deux moitiés stratifiées. Les pondérations sont optimisées par recherche exhaustive sur la première moitié, puis évaluées sur la seconde, jamais vue par l’optimisation. La procédure a été répétée deux cents fois.

Tableau 6.23 : *Stabilité des pondérations sur deux cents partitions aléatoires*

Pondération	Valeur dans V5	Médiane sur 200 tirages	Intervalle interquartile
w_ctr	0.15	0.15	[0.15 – 0.15]
w_cong	0.40	0.40	[0.35 – 0.40]
w_calcif	0.10	0.10	[0.10 – 0.10]
w_cardio	0.35	0.35	[0.35 – 0.35]

Les quatre médianes coïncident exactement avec les pondérations déployées, et trois des quatre intervalles interquartiles sont réduits à un point. La configuration retenue n’est donc pas un artefact du jeu d’évaluation complet.

Tableau 6.24 : *Comparaison des pondérations fixes et réoptimisées*

Stratégie d’évaluation	AUC moyenne	Écart-type
Pondérations réoptimisées à chaque partition	0.8849	0.0186
Pondérations V5 fixes	0.8909	0.0170

Un résultat mérite d’être souligné : les pondérations fixes devancent de 0.60 point celles réoptimisées à chaque tirage. Ce constat, contre-intuitif en apparence, est caractéristique d’une surface d’optimisation plate — la réoptimisation sur 250 images capte du bruit et dégrade la généralisation.

L’estimation du surajustement se lit directement dans la comparaison suivante.

Tableau 6.25 : *Estimation du surajustement de la formule déployée*

Mesure	AUC
V5 sur l'échantillon complet, ayant servi à l'optimisation	0.8916
V5 en évaluation indépendante, moyenne sur 200 partitions	0.8909
Surajustement estimé	+0.0007

L'écart est de sept dix-millièmes de point, valeur négligeable devant l'écart-type de 0.0170. **L'AUC de 0.8916 peut donc être rapportée sans réserve particulière**, la validation indépendante donnant 0.8909 ± 0.0170 .

6.8.5 Contribution du Module 3

La même procédure permet d'évaluer l'apport du Module 3 en conditions indépendantes.

Tableau 6.26 : *Contribution du Module 3*

Configuration	AUC-ROC
V5 avec la composante calcique	0.8916
V5 sans la composante calcique, poids renormalisés	0.8848
Apport	+0.0068

Le test de DeLong situe la p-value à 0.3869 : l'apport n'est pas statistiquement significatif. Sur les 200 partitions, il est cependant **positif dans 81.0 % des cas**, avec une médiane de +0.0072.

Ces deux résultats ne sont pas contradictoires. La direction de l'effet est constante et reproductible, mais son amplitude est trop faible pour être établie avec 501 images. Le Module 3 est en conséquence conservé dans la formule : il apporte un gain modeste mais systématique, et sa présence contribue à l'objectif d'auditabilité en fournissant une seconde composante indépendante du classificateur de risque.

La formulation honnête de ce résultat, retenue pour la soutenance, est la suivante : le signal calcique porte une information réelle et indépendante, dont la contribution est trop faible pour atteindre la significativité sur un échantillon de cette taille. Un jeu de validation élargi permettrait vraisemblablement de trancher, perspective retenue en Section 8.2.1.

6.9 Pipeline V5 Final : Formule, Résultats et Gain

6.9.1 Genèse de la formule de fusion

La pondération déployée résulte de quatre étapes successives, chacune motivée par une mesure et non par un choix a priori.

La formule initiale attribuait 0.50 au score du CTR, 0.25 au signal calcique et 0.25 à la congestion, répartition posée sur la base de la littérature clinique. Elle atteint une AUC de 0.7622 sur les 501 images de validation.

La réparation du checkpoint du Module 3, documentée en Section 7.5.3, a rendu son score exploitable et conduit à réexaminer la fusion. Une première optimisation à deux composantes, le signal calcique étant alors écarté, a produit la pondération 0.45 / 0.55 pour une AUC de 0.7753. Une seconde optimisation, réintégrant le Module 3, a donné 0.35 / 0.45 / 0.20 et une AUC de 0.7924.

L'analyse stratifiée par pathologie a révélé que ces deux formules présentaient un défaut majeur, invisible sur l'AUC globale : leur score est **anti-corrélé à la cardiomégalie**, avec des AUC respectives de 0.3523 et 0.3717 sur ce sous-groupe. Autrement dit, le score décroît lorsque la pathologie est présente. L'explication est mécanique et se lit dans le tableau de la Section 6.2.4 : la composante de congestion, qui pèse alors 45 % du score, vaut en moyenne 0.072 chez les patients cardiomégaliens contre 0.157 chez les sujets sans anomalie.

L'introduction de la probabilité de cardiomégalie produite par le Module 4 corrige cette inversion. Le balayage de son poids établit la progression suivante.

Tableau 6.27 : *Balayage du poids de la composante de cardiomégalie*

Poids de prob_cardio	AUC globale	AUC cardiomégalie
0.00	0.7924	0.3717
0.10	0.8392	0.4449
0.20	0.8701	0.5494
0.30	0.8842	0.7106
0.35	0.8813	0.7886
0.45	0.8709	0.8753

L'AUC globale forme un plateau entre 0.30 et 0.35, tandis que l'AUC sur la cardiomégalie continue de progresser. La valeur de 0.35 a été retenue pour cette raison : elle gagne 7.8




Figure 6.2 : *Progression des formules de fusion : AUC globale et AUC sur le sous-groupe cardiomégalie*

points sur le sous-groupe le plus problématique pour une perte de 0.29 point sur la mesure globale.

Tableau 6.28 : *AUC globale et par pathologie des formules de fusion successives*

Formule	AUC globale	AUC cardiomégalie	AUC œdème
Pondération a priori (0.50 / 0.25 / 0.25)	0.7622	0.5315	0.7308
Optimisation à deux composantes	0.7753	0.3523	0.9229
Optimisation à trois composantes	0.7924	0.3717	0.9207
Formule déployée V5	0.8916	0.6149	0.7767

Le gain de 26.3 points sur la cardiomégalie s’accompagne d’une perte de 14.6 points sur l’œdème. Cet arbitrage est assumé : une formule qui échoue systématiquement sur l’une des deux pathologies cibles n’est pas acceptable pour un usage de dépistage, quelle que soit sa performance agrégée.

Une observation mérite d’être relevée. La pondération a priori, pourtant la moins performante sur l’AUC globale, était la seule des trois formules antérieures à ne pas être anti-corrélée à la cardiomégalie. Une pondération posée sur des considérations cliniques peut donc se révéler mieux équilibrée qu’une optimisation conduite sur une métrique agrégée.

Ce résultat constitue l’apport méthodologique principal de ce travail : **l’optimisation d’une métrique agrégée peut masquer un comportement pathologique sur un sous-groupe clinique, et seule une évaluation stratifiée permet de le détecter.**

6.9.2 Formule finale

Formule finale — Pipeline V5 (AUC = 0.8916, IC 95 % [0.8572 – 0.9229])

$$\text{risk_global} = (0.15 \times \text{s_ctr} + 0.40 \times \text{s_cong} + 0.10 \times \text{s_calcif} + 0.35 \times \text{prob_cardio}) \times 100$$

Où : $\text{s_ctr} = \text{clip}((\text{CTR} - 0.40) / 0.20, 0, 1)$
[Module 1 — U-Net cardiaque] $\text{s_cong} = \text{prob}[\text{Edema}]$ [Module 4 — CNN risque]
 $\text{s_calcif} = \text{prob}[\text{Calcification}] + \text{prob}[\text{Aortic enlargement}]$ [Module 3 — CNN calcique]
 $\text{prob_cardio} = \text{prob}[\text{Cardiomegaly}]$ [Module 4 — CNN risque] Niveaux : FAIBLE (< 25 %) MODÉRÉ (25 – 35 %) ÉLEVÉ (35 %) INDÉTERMINÉ si le CTR sort de la plage [0.30 ; 0.75]

6.9.3 Cas de test détaillés

Quatre radiographies ont été traitées par le pipeline complet, la première issue du jeu NIH avec étiquette de référence, les trois autres provenant de sources extérieures dépourvues d’annotation.

Tableau 6.29 : Cas de test détaillés							
Image	CTR	s_ctr	s_cong	s_calcif	prob_cardio	Score	Niveau
00000001_000 (Cardiomegaly)	0.628	1.000	0.000	0.720	0.997	57.1 %	ÉLEVÉ
Externe 1	0.500	0.500	0.000	0.966	0.030	18.2 %	FAIBLE
Externe 2	0.448	0.240	0.000	0.005	0.001	3.7 %	FAIBLE
Externe 3	0.633	1.000	0.098	0.161	0.041	21.9 %	FAIBLE

Chaque ligne vérifie exactement la formule de fusion. Pour la première image, la somme $0.15 \times 1.000 + 0.40 \times 0.000 + 0.10 \times 0.720 + 0.35 \times 0.997$ donne 0.571, soit 57.1 %.

Le premier cas illustre le bénéfice du passage à la formule V5. La cardiomégalie, confirmée par l’étiquette NIH, est détectée conjointement par la mesure du CTR et par le classificateur, produisant un score qui franchit largement le seuil de la catégorie ÉLEVÉ. Sous la formule à deux composantes, la même image plafonnait à 45 %, la composante de congestion étant nulle.

Le troisième cas externe met en évidence une propriété du système qui doit être connue : le CTR mesuré à 0.633 dépasse le seuil conventionnel de cardiomégalie, mais la pondération de 0.15 borne sa contribution à 15 points sur les 35 requis. Lorsque le Module 4 conclut à la normalité, aucune mesure anatomique ne peut à elle seule renverser cette conclusion. Cette limite est analysée en Section 7.4.




Figure 6.3 : Rapport visuel généré par le pipeline sur un cas de cardiomégalie confirmé

6.9.4 Métriques cliniques et choix du seuil

Tableau 6.30 : Métriques cliniques du pipeline selon le seuil de décision

Seuil	Sensibilité	Spécificité	VPP	VPN	Patients	
					manqués	Fausses alertes
30 %	0.937	0.737	0.877	0.854	21	44
35 %	0.928	0.766	0.888	0.842	24	39
(retenu)						
40 %	0.880	0.778	0.888	0.765	40	37

Le seuil retenu de 35 % correspond au maximum de l'indice de Youden, atteint à 34.8 %. Il manque 24 patients porteurs d'une anomalie sur 334, contre 126 avec la formule à deux composantes évaluée à son propre seuil optimal de 44 %. Cette réduction d'un facteur cinq du nombre de faux négatifs constitue le principal bénéfice clinique du passage à la formule V5. Ces métriques sont calculées sur l'ensemble des 501 images, y compris les 66 relevant de la catégorie INDÉTERMINÉ, dont le score est calculé mais non communiqué. La convention retenue est conservatrice : elle compte comme faux négatif tout patient pathologique dont la segmentation a échoué, alors même que le système signale explicitement ce cas.

La répartition des 501 images entre les quatre catégories s'établit comme suit : 302 images en risque ÉLEVÉ, 16 en risque MODÉRÉ, 117 en risque FAIBLE et 66 en catégorie INDÉTERMINÉ. La faible population de la catégorie MODÉRÉ, qui ne rassemble que 3.2 % du jeu, indique que le seuil inférieur de 25 %, hérité des formules antérieures, mériterait un recalibrage sur la distribution des scores produits par la formule V5.

Une précision doit enfin être apportée sur la valeur prédictive positive. Mesurée à 0.888 sur un jeu équilibré à parts égales entre les trois classes, elle ne reflète pas ce qui serait

observé en dépistage réel. En appliquant le théorème de Bayes à une prévalence de 5 %, valeur plausible en population générale, la VPP tombe à 0.174; elle atteint 0.309 pour une prévalence de 10 %. Cette dépendance à la prévalence est une propriété générale des tests diagnostiques et non une faiblesse particulière du système, mais elle doit être explicitement communiquée à tout utilisateur clinique.

6.10 Fiabilité expérimentale : reproductibilité et rigueur

La fiabilité des résultats expérimentaux est une composante essentielle du Trustworthy AI : des conclusions scientifiques ne peuvent être dignes de confiance que si elles sont reproductibles, transparentes dans leur protocole et honnêtes dans l'exposé de leurs limites. Cette section synthétise les garanties de rigueur mises en œuvre dans les sept études.

6.10.1 Garanties de reproductibilité

- **Graine aléatoire fixe** : `seed = 42` appliquée systématiquement aux générateurs PyTorch, NumPy et Python natif, ainsi qu'à tous les appels à `random_split`. Toute réexécution du protocole sur la même plateforme reconstitue rigoureusement les mêmes partitions et les mêmes ordres de lot.
- **Scores pré-calculés stables** : les sept études opèrent sur les colonnes numériques figées du fichier `resultats_phase4_v5.csv`, produit par une exécution unique du pipeline complet. Les modèles étant en mode `eval()` et l'augmentation désactivée, l'inférence est déterministe.
- **Contrôle d'invariance entre versions** : lors du passage à la formule V5, une réexécution complète de l'inférence a permis de vérifier que les scores bruts demeurent rigoureusement identiques à ceux de l'exécution précédente. Les colonnes `ctr`, `s_ctr`, `s_cong`, `prob_edema` et `prob_cardio` présentent un écart maximal nul. Seule la colonne de fusion a changé, ce qui garantit que les écarts d'AUC rapportés proviennent exclusivement de la formule et non d'une variation d'inférence.
- **Chargement strict des checkpoints** : les quatre modèles sont chargés avec `strict=True`, de sorte que toute incompatibilité entre le fichier de poids et l'architecture lève une exception. Ce contrôle est la conséquence directe de l'incident documenté en Section 7.5.3, où l'usage de `strict=False` avait masqué le chargement d'un checkpoint erroné.
- **Métrique unique et définie a priori** : l'AUC-ROC binaire a été retenue comme métrique unique avant le lancement des expériences, avec une binarisation fixée en

amont. Ce choix préalable écarte le biais de sélection a posteriori de la métrique la plus favorable.

6.10.2 Limites et biais reconnus

- **Biais de sélection du jeu d'évaluation** : les 501 images sont équilibrées à parts égales entre les trois classes, ce qui ne reflète pas la prévalence réelle en population générale. Les valeurs prédictives positives mesurées sont donc structurellement optimistes, comme le quantifie la Section 6.9.4.
- **Absence de validation externe** : les sept études sont conduites exclusivement sur NIH ChestX-ray14. Les pondérations optimisées reflètent les caractéristiques de cette population, de ses équipements d'acquisition et de sa méthode d'annotation. Leur transférabilité constitue une hypothèse non testée, et les trois cas externes de la Section 7.4 en illustrent les limites.
- **Optimisation non indépendante** : les quatre pondérations ont été déterminées sur les mêmes 501 images que celles servant à rapporter l'AUC finale. La Section 6.8.4 quantifie précisément ce risque par validation en demi-échantillons répétés.
- **Recouvrement possible avec l'entraînement du Module 4** : le tirage des 501 images est stratifié par classe avec une graine fixe, mais ne garantit pas formellement l'exclusion des images ayant servi à l'entraînement du Module 4. Cette limite doit être levée par la constitution d'une liste explicite des identifiants d'entraînement, opération identifiée comme préalable à toute publication des résultats.
- **Validation clinique absente** : les étiquettes NIH utilisées comme vérité terrain sont extraites automatiquement par traitement du langage naturel, et non issues d'événements cardiovasculaires confirmés. L'AUC mesure donc la concordance du pipeline avec une annotation d'imagerie imparfaite, et non sa valeur prédictive réelle.

Synthèse — Études expérimentales et Trustworthy AI

Les sept études illustrent une démarche alignée sur les principes du Trustworthy AI. Chaque décision d'architecture est justifiée empiriquement plutôt qu'heuristiquement : la source du signal calcique, les quatre pondérations de fusion et l'exclusion du module de segmentation reposent sur des mesures. Les composantes faiblement contributives sont identifiées et chiffrées plutôt que dissimulées : l'Étude 1 établit que les deux indicateurs anatomiques n'apportent conjointement qu'un point d'AUC, et ce constat est rapporté au même titre que les résultats favorables. Les limites — calibration défectueuse du Module 4, biais du jeu d'évaluation, dépendance de la performance au classificateur profond — sont explicitement reconnues. Enfin, chaque écart est assorti

de son intervalle de confiance et d'un test de significativité, dont les résultats négatifs sont rapportés.

Chapitre 7

Trustworthy AI : Synthèse et Discussion

Ce chapitre constitue la synthèse dédiée au Trustworthy AI — concept central du titre de ce projet. Après avoir été intégré comme fil conducteur dans chacun des chapitres précédents, le Trustworthy AI est ici traité de manière systématique et critique : bilan des quatre piliers implémentés, analyse de leurs limites, discussion de la conformité aux standards internationaux, et comparaison avec les standards cliniques existants. Ce chapitre répond à la question : dans quelle mesure notre pipeline est-il véritablement digne de confiance ?

7.1 Bilan des 4 Piliers du Trustworthy AI

Rappelons que le Trustworthy AI en médecine repose sur quatre piliers opérationnels définis dans le Chapitre 2 : explicabilité, transparence, robustesse et honnêteté scientifique. Chaque pilier a été intégré comme contrainte de conception dans notre pipeline. Le tableau suivant synthétise leur implémentation concrète et leur niveau de satisfaction.

Tableau 7.1 : Bilan des 4 Piliers du Trustworthy AI		
Pilier	Implémentation	NiveauLimite résiduelle
Explicabilité	Grad-CAM sur Module 4 Concordance anatomique globale 80.0 %, dont 86.7 % sur la classe Cardiomegaly	SatisfaitValidation qualitative sur 15 images seulement
Transparence	Décomposition du score en quatre contributions · rapport diagnostic visuel à six panneaux	SatisfaitPondérations non interprétables par un clinicien non spécialiste
Robustesse	Entraînement multi-corpus JSRT + VinDr · état INDÉTERMINÉ sur segmentation douteuse · stabilité vérifiée sur 200 partitions	Partiel Validation externe absente
Honnêteté scientifique	Anti-corrélation à la cardiomégalie exposée · calibration de M4 quantifiée (ECE = 0.0754) · surajustement mesuré (+0.0007) · limites du F1 = 0.366 rapportées	SatisfaitValidation externe non conduite

Cette synthèse révèle que trois piliers sur quatre sont satisfaits de manière convaincante

dans le cadre de ce projet académique. La robustesse reste partiellement satisfaite en raison de l'absence de validation clinique prospective, contrainte externe au projet nécessitant des partenariats hospitaliers. Ce niveau de satisfaction est cohérent avec l'état de l'art académique en IA médicale, où la validation clinique constitue systématiquement la phase de déploiement ultérieure aux travaux de recherche.

7.2 Grad-CAM : Validation Visuelle de l'Attention du Modèle

7.2.1 Résultats de la validation anatomique

La validation de l'explicabilité Grad-CAM a été conduite sur un échantillon de 15 images représentatives couvrant les trois classes. Pour chaque image, la carte de chaleur Grad-CAM a été évaluée qualitativement par rapport à la localisation anatomique attendue de la pathologie prédite : zone cardiaque centrale pour Cardiomegaly, régions hilaires et basales pour Edema, distribution diffuse pour Normal.

Tableau 7.2 : *Validation anatomique des cartes Grad-CAM*

Classe prédite	Focus anatomique attendu	Cohérence observée	Taux de concordance
Cardiomegaly	Zone cardiaque centrale (médiastin)	Oui dans 13/15 cas	86.7%
Edema	Régions hilaires et basales bilatérales	Oui dans 11/15 cas	73.3%
Normal	Distribution diffuse / poumons	Oui dans 12/15 cas	80.0%
Global	—	36/45 cas	80.0%

Un taux de concordance anatomique global de 80% confirme que le Module 4 a appris des représentations visuelles cliniquement pertinentes. Les 20% de discordances s'expliquent principalement par trois facteurs : des cas limites où la pathologie est subtile et distribuée, le biais d'annotation NLP du dataset NIH produisant des labels incorrects, et les limitations inhérentes au Grad-CAM approché utilisé (average pooling des activations plutôt que vrais gradients par neurone).

7.2.2 Limitation technique du Grad-CAM implémenté

L'implémentation Grad-CAM du pipeline utilise la moyenne des activations comme approximation des poids de gradient (global average pooling sur les activations de la dernière couche convolutive), plutôt que le calcul exact des gradients par neurone tel que défini par




Figure 7.1 : Carte de chaleur Grad-CAM du Module 4 sur un cas de cardiomégalie confirmé

Selvaraju et al. (2017). Cette approximation — dénommée Class Activation Mapping (CAM) dans la littérature plutôt que Grad-CAM strict — produit des cartes de chaleur légèrement moins précises spatialement, mais reste cliniquement interprétable.

Correction Identifiée — Bug Grad-CAM

Le calcul actuel utilise `act.mean(axis=(1,2))` comme poids, ce qui correspond à une CAM pondérée par les activations moyennes et non aux vrais gradients. La correction consiste à calculer `grad = inp.grad` sur les activations sauvegardées par le hook, puis `weights = grad.mean(axis=(1,2))`. Cette correction est identifiée comme amélioration prioritaire et produira des cartes de chaleur plus précises spatialement, particulièrement pour les pathologies localisées.

7.3 Flags d'Incertitude et Désaccord Inter-Modules

7.3.1 Mécanismes de flags implémentés

Le pipeline intègre trois mécanismes de détection d'incertitude qui déclenchent automatiquement des alertes dans le rapport de diagnostic, invitant à une révision médicale humaine.

Ces mécanismes constituent la dimension de sécurité du Trustworthy AI : lorsque le système n’est pas suffisamment confiant, il le signale explicitement plutôt que de produire silencieusement une prédiction potentiellement erronée.

Tableau 7.3 : *Mécanismes de signalement implémentés dans le pipeline*

Flag	Condition de déclenchement	Message généré	Justification clinique
État INDÉTERMINÉ	CTR hors de $[0.30 ; 0.60]$	Segmentation non exploitable — score non communiqué	Prévention d’une défaillance silencieuse du Module 1
Flag Cardiomégalie	CTR > 0.50	Cardiomégalie détectée CTR = X.XXX	Critère diagnostique standard (Danzer 1919, maintenu OMS)
Flag Incertitude M3	$\max(\text{prob_calcif}) < 0.60$	Incertitude du CNN calcique → révision recommandée	Information rapportée au lecteur ; ne conditionne pas le score
Flag Désaccord M1-M4	cardio_flag (M4 prédit Cardiomegaly)	Désaccord CTR/CNN → vérification recommandée	Cohérence inter-modules comme validation croisée

7.3.2 Analyse du désaccord inter-modules

Le flag de désaccord entre M1 (CTR) et M4 (CNN risque) est particulièrement informatif cliniquement. Sur le dataset de validation, trois scénarios de désaccord ont été observés. Le premier, cardio_flag=True mais M4 prédit Normal, peut indiquer une cardiomégalie sans manifestation clinique de congestion — cas de cardiomégalie compensée nécessitant une investigation complémentaire. Le second, cardio_flag=False mais M4 prédit Cardiomegaly, peut refléter une erreur de segmentation M1 (CTR sous-estimé) ou une cardiomégalie subtile non détectée par le CTR seul. Le troisième, accord total, constitue le cas de figure le plus fiable cliniquement.

Ces scénarios de désaccord illustrent la valeur ajoutée de l’approche multi-modules : chaque module fournit une perspective complémentaire, et leur désaccord est lui-même un signal clinique porteur d’information. Un système mono-modèle ne pourrait pas générer ce type d’alerte de cohérence.

7.4 Comportement Hors Domaine : Trois Cas Externes

Le pipeline a été appliqué à trois radiographies thoraciques extérieures au jeu NIH ChestX-ray14, dépourvues d’annotation experte et de métadonnées d’acquisition.

Tableau 7.4 : *Comportement Hors Domaine : Trois Cas Externes*

Image	CTR	s_calcif	prob_cardio	Score	Niveau
Référence NIH (00000001_000)	0.628	0.720	0.997	57.1 %	ÉLEVÉ
Externe 1	0.500	0.966	0.030	18.2 %	FAIBLE
Externe 2	0.448	0.005	0.001	3.7 %	FAIBLE
Externe 3	0.633	0.161	0.041	21.9 %	FAIBLE

Le cas de référence issu de NIH illustre le fonctionnement attendu : une cardiomégalie confirmée par l’étiquette, détectée conjointement par la mesure du CTR et par le Module 4, produit un score de 57.1 % franchissant nettement le seuil ÉLEVÉ. Sous la formule à deux composantes, la même image plafonnait à 45 %.

Le troisième cas externe est plus instructif. Le ratio cardio-thoracique mesuré à 0.633 dépasse le seuil conventionnel de cardiomégalie, tandis que le Module 4 conclut à la normalité avec une confiance de 0.862. En l’absence d’annotation experte, il n’est pas possible de déterminer lequel des deux modules produit la réponse correcte.

Ce désaccord est en lui-même informatif. Une architecture modulaire le rend visible et localisable, là où un classificateur monolithique aurait produit un score unique sans laisser apparaître la divergence. Il rappelle également que le diamètre thoracique n’étant pas segmenté mais approximé à 75 % de la largeur de l’image, la mesure du CTR reste tributaire du cadrage de la radiographie — condition satisfaite sur le corpus NIH, dont les images suivent un protocole homogène, mais non garantie sur des acquisitions extérieures.

Une seconde observation ressort de ce tableau : la pondération de 0.15 accordée au CTR borne mécaniquement sa contribution à 15 points sur les 35 nécessaires pour atteindre la catégorie ÉLEVÉ. Lorsque le Module 4 conclut à la normalité, aucune mesure anatomique ne peut à elle seule renverser cette conclusion. Il s’agit du revers de l’optimisation conduite en §6.7.1, et cette propriété doit être connue de tout utilisateur du système.

7.5 Limites Identifiées et Honnêteté Scientifique

L’honnêteté scientifique — quatrième pilier du Trustworthy AI — exige une documentation exhaustive et non édulcorée des limites du système. Cette section présente l’inventaire complet des limites identifiées, classées par nature et par impact clinique potentiel.

7.5.1 Limites techniques

- **Grad-CAM approché** : l’implémentation actuelle pondère les activations de la dernière couche convolutive par leur propre moyenne spatiale, et non par la moyenne des gradients de la classe prédite. Il s’agit donc d’une CAM pondérée par activations plutôt que d’un Grad-CAM au sens strict de Selvaraju et al. [13]. Les cartes produites restent anatomiquement cohérentes (80 % de concordance), mais leur résolution spatiale et leur spécificité de classe sont dégradées : la carte varie peu selon la classe cible, ce qui limite son utilité pour le diagnostic différentiel.
- **Sur-confiance du classificateur M4 : le Module 4 produit des probabilités softmax fortement concentrées.** Sur les 501 images de validation, 195 d’entre elles — soit 38.9 % — présentent une probabilité maximale supérieure ou égale à 0.999. L’erreur de calibration attendue s’établit à 0.0754, et le modèle annonce une confiance moyenne de 0.9888 sur 406 images pour une justesse observée de 0.9113. Cette concentration de la confiance dans sa queue haute rend inopérant tout mécanisme reposant sur un seuil binaire — c’est la cause directe de l’échec du gating par la confiance (Étude 4) — et prive le système d’un signal d’incertitude exploitable, alors même que la détection des cas incertains est une exigence centrale du Trustworthy AI. Elle justifie la calibration par temperature scaling identifiée en perspective à court terme (Section 8.2.1).
- **Diamètre thoracique approximé et non segmenté** : le diamètre thoracique n’est pas mesuré anatomiquement mais approximé par une constante fixée à 75 % de la largeur de l’image. Cette hypothèse rend le CTR sensible au cadrage, à la collimation et au facteur de zoom à l’acquisition. Par ailleurs, le CTR étant un rapport de deux longueurs converties avec le même facteur d’échelle, la correction du spacing s’annule au numérateur et au dénominateur : elle permet d’exprimer heart_cm et thorax_cm en unités cliniques dans le rapport de diagnostic, mais n’altère pas la valeur du ratio lui-même. Pour les images externes dépourvues de métadonnées, un spacing médian de 0.143 mm/px est appliqué par défaut, ce qui affecte uniquement les mesures en centimètres reportées, non le CTR.
- **F1 Calcification faible (0.366)** : la classe Calcification du Module 3 atteint une précision de 0.421 et un rappel de 0.324, très en deçà des autres classes. Cette faiblesse cumule trois causes : un volume d’entraînement réduit (452 images contre 1 000 par classe concurrente), une vérité terrain approximée par bounding boxes rectangulaires alors que les calcifications sont ponctiformes ou linéaires, et une difficulté radiologique intrinsèque — la détection fiable des calcifications vasculaires

relève du scanner, non de la radiographie standard.

7.5.2 Limites de validation

- **Absence de validation clinique prospective** : l'ensemble de l'évaluation repose sur des jeux de données rétrospectifs publics. Aucune cohorte de patients suivis dans le temps n'a été mobilisée, ce qui interdit d'établir la sensibilité, la spécificité et la valeur prédictive réelles du système en conditions cliniques. Cette limite est structurelle au cadre académique du projet : elle nécessiterait un partenariat hospitalier, un protocole validé par un comité d'éthique et un suivi longitudinal de plusieurs années.
- **Domain shift résiduel** : malgré l'entraînement combiné JSRT+VinDr ayant corrigé le domain shift du Module 1, les Modules 3 et 4 restent entraînés sur un dataset unique — respectivement VinDr et NIH. Le score calcique produit par le Module 3 sur des images NIH conserve un pouvoir discriminant réel, avec une AUC de 0.7037 supérieure à celle du CTR, ce qui indique que ses représentations se transfèrent partiellement. Rien ne garantit toutefois que ce transfert se maintiendrait sur une population ou un parc d'équipements différents, et les trois cas externes analysés en Section 7.4 rappellent que le Module 4 conclut à la normalité avec une confiance élevée sur des images issues d'un domaine non représenté à l'entraînement.
- **Risque de suroptimisation du Pipeline V5** : les poids de fusion ont été sélectionnés sur le jeu de validation qui sert également à rapporter la performance finale. La validation par 200 partitions aléatoires stratifiées, présentée ci-dessous, quantifie ce risque : la formule V5 atteint 0.8909 ± 0.0170 sur des moitiés d'échantillon jamais vues par l'optimisation, contre 0.8916 sur l'échantillon complet. Le surajustement est donc estimé à 0.0007 point d'AUC, valeur négligeable devant l'écart-type de la mesure.
- **Absence de comparaison avec outils cliniques de référence** : le pipeline n'a pu être confronté ni au score de Framingham, ni à SCORE2, ni au score calcique tomodensitométrique, ces outils requérant des variables cliniques (âge, sexe, pression artérielle, bilan lipidique, statut tabagique) absentes des datasets publics utilisés. Toute affirmation de supériorité ou d'équivalence par rapport à ces standards serait donc infondée : la comparaison présentée en Section 7.5 demeure strictement qualitative.

7.5.3 Modes de défaillance silencieuse

L'analyse des sorties du pipeline sur les 501 images de validation a révélé deux modes de défaillance qui partagent une caractéristique commune : ils ne produisent aucun message d'erreur et se traduisent par un score de risque apparemment normal.

Le premier concerne la segmentation cardiaque. Le rapport cardio-thoracique calculé prend une valeur nulle ou négative sur 19 images, soit 3.8 % du jeu de validation : sur celles-ci, le Module 1 n'a détecté aucune structure cardiaque satisfaisant le critère de position anatomique. En élargissant le critère aux valeurs implausibles, 66 images sortent de la plage $[0.30; 0.75]$, soit 13.2 % du jeu de validation.

La conséquence est préoccupante. Le score s_ctr étant obtenu par la transformation $\text{clip}((CTR - 0.40) / 0.20)$, tout CTR aberrant bas produit un score nul, lequel se traduit par une contribution nulle au risque global. Une segmentation ayant échoué et un cœur parfaitement sain conduisent donc à la même sortie : un risque faible. Le système ne distingue pas l'absence de pathologie de l'absence de mesure.

Cette confusion constitue précisément le mode de défaillance qu'un système de dépistage ne doit pas présenter. Un patient dont l'image n'a pas pu être analysée doit être orienté vers une relecture humaine, et non classé en risque faible. La correction a été apportée : un état INDÉTERMINÉ est déclenché lorsque le rapport cardio-thoracique calculé sort de l'intervalle de plausibilité anatomique $[0.30; 0.75]$, et propagé jusqu'au rapport final. Sur les 501 images de validation, 66 relèvent de cet état, soit 13.2 % du jeu : leur score est calculé mais n'est pas communiqué, la mesure sur laquelle il repose n'étant pas fiable.

Un second mode de défaillance, du même ordre, a été identifié en cours de projet. Le Module 3 produisait 501 sorties sans qu'aucune anomalie ne soit signalée, alors que ses paramètres entraînés n'étaient pas chargés : le mécanisme de chargement souple des poids masquait l'incompatibilité au lieu de la signaler. Le passage à un chargement strict, adopté depuis dans l'ensemble du pipeline, fait échouer l'exécution plutôt que de la poursuivre sur un modèle non initialisé.

Ces deux observations convergent vers une exigence de conception qui n'avait pas été formulée initialement. Un système d'aide au diagnostic doit distinguer trois états et non deux : le résultat normal, le résultat pathologique, et l'absence de résultat exploitable. La confusion entre le premier et le troisième est le mode de défaillance le plus dangereux d'un outil de dépistage, puisqu'il produit une fausse réassurance. L'introduction systématique d'un état INDÉTERMINÉ, assorti de sa justification, constitue à ce titre une contribution attendue de la démarche Trustworthy AI, et elle est retenue comme perspective prioritaire.

7.6 Comparaison avec les Standards Cliniques Existants

Bien que la comparaison directe avec les outils cliniques de référence ne soit pas possible dans ce projet faute de données partagées, une mise en perspective qualitative permet de situer notre pipeline dans l'écosystème des outils de stratification du risque cardiovasculaire.

Tableau 7.5 : *Comparaison du pipeline aux outils cliniques existants*

Outil	Type	Indicateurs utilisés	Accessibilité	IA explicable
Score Framingham	Score clinique	Âge, cholestérol, PA, tabac	Élevée	N/A (formule fixe)
SCORE2 (ESC)	Score clinique	Âge, sexe, tabac, cholestérol	Élevée	N/A (formule fixe)
Score calcique CT	Imagerie dédiée	Calcium coronarien (Agatston)	Faible	Non
Échocardiographie	Imagerie dédiée	FE, dimensions cardiaques	Modérée	Non
Notre pipeline V5	IA + Radiographie	CTR, calcifications, congestion, cardiomégalie	Très élevée	Oui (Grad-CAM)

Notre pipeline se distingue sur deux dimensions complémentaires. Premièrement, l’accessibilité : il exploite la radiographie thoracique standard, examen de première ligne disponible dans tous les établissements de santé, y compris dans les contextes à ressources limitées. Aucun examen supplémentaire n’est requis — c’est précisément la valeur ajoutée du dépistage opportuniste. Deuxièmement, l’explicabilité : contrairement aux scores cliniques classiques qui produisent un chiffre sans justification visuelle, notre pipeline fournit une carte de chaleur Grad-CAM et une décomposition transparente des contributions, facilitant la validation clinique par le radiologue.

En revanche, notre pipeline ne dispose pas encore de la validation clinique longitudinale des scores Framingham ou SCORE2, qui ont démontré leur valeur prédictive sur des cohortes de plusieurs dizaines de milliers de patients suivis sur 10 ans. Cette validation reste l’étape indispensable avant tout déploiement clinique, et constitue la perspective prioritaire identifiée dans le Chapitre 8.

Position du Pipeline V5 dans l'Écosystème Clinique

Notre pipeline n'a pas vocation à remplacer les outils cliniques établis (Framingham, SCORE2, score calcique CT), mais à les compléter dans un contexte de dépistage opportuniste. Il représente un premier filtre non invasif, automatique et explicable, capable d'identifier les patients nécessitant une investigation cardiovasculaire approfondie parmi ceux réalisant une radiographie thoracique pour une autre

indication. Dans ce cadre d'usage précis, son $AUC=0.8916$ et ses propriétés de Trustworthy AI constituent des bases solides pour une validation clinique prospective.

Bilan Global — Trustworthy AI du Pipeline V5

* Explicabilité : Grad-CAM validé anatomiquement (80% concordance)
Transparence : décomposition complète CTR + Congestion documentée Robustesse : entraînement multi-dataset, correction spacing, domain shift résiduel reconnu
Honnêteté : limites techniques et de validation exhaustivement documentées Verdict : Pipeline prototype fonctionnel et documenté, prêt pour une validation clinique prospective dans un cadre de dépistage opportuniste.*

Chapitre 8

Conclusion et Perspectives

8.1 Bilan des Contributions

Ce projet de fin d'études avait pour objectif de concevoir, développer et valider un pipeline d'IA de confiance pour le dépistage opportuniste du risque cardiovasculaire à partir de radiographies thoraciques de routine. Au terme de ce travail, les trois objectifs initiaux définis dans la brochure de Pr. El Hassouni ont été atteints, avec des contributions originales documentées à chaque étape.

Tableau 8.1 : *Bilan des contributions par objectif*

Objectif	Réalisation	Résultat clé
Extraction automatisée des facteurs de risque	Quatre modules spécialisés : U-Net cardiaque, U-Net calcifications, CNN calcifications, CNN risque	CTR en unités cliniques · Dice 0.958 · AUC 0.895
Prédiction du risque cardiovasculaire global	Pipeline V5 : fusion à quatre composantes, pondération optimisée sous contrainte d'auditabilité	AUC 0.8916 [0.8572 – 0.9229] · sensibilité 0.928 · score décomposable de 0 à 100
Validation et Trustworthy AI	Sept études sur 501 images · Concordance anatomique du Grad-CAM : 80.0 % (86.7 % sur la classe Cardiomegaly) · trois alternatives écartées sur preuve	Prototype fonctionnel, prêt pour validation clinique

Au-delà des objectifs formels, ce projet a produit cinq contributions originales par rapport à l'état de l'art. La première est l'architecture multi-modules intégrée couvrant les trois indicateurs cardiovasculaires principaux détectables par radiographie thoracique. La deuxième est l'expression du CTR en unités cliniques par spacing adaptatif, assortie d'une correction du biais de projection AP/PA, et de l'établissement du fait que le rapport lui-même, étant un quotient de deux longueurs converties par le même facteur d'échelle, est invariant par changement d'échelle isotrope. La troisième est la substitution d'une pondération de fusion mesurée à une pondération posée a priori, conduite par recherche exhaustive sur grille et validée par deux cents partitions aléatoires du jeu de validation — démarche dont la

valeur réside dans la méthode plutôt que dans l'écart obtenu, celui-ci n'atteignant pas le seuil de significativité statistique sur 501 images. La quatrième est la documentation de trois résultats négatifs — inefficacité du signal de segmentation des calcifications, échec de la fusion conditionnée par la confiance, et non-transférabilité du gain apporté par une troisième composante — chacun assorti de son diagnostic causal. La cinquième est l'intégration native des quatre piliers du Trustworthy AI comme contraintes architecturales de conception.

Phrase de Soutenance — Résumé en une phrase

Nous avons conçu et validé un pipeline d'IA de confiance pour le dépistage opportuniste du risque cardiovasculaire sur radiographie thoracique, combinant U-Net et EfficientNet-B0 pour extraire trois indicateurs complémentaires (CTR, calcifications, congestion), fusionnés en un score global de 0 à 100% avec une AUC de 0.8916 sur 501 images NIH, et validés selon les quatre piliers du Trustworthy AI : explicabilité Grad-CAM, transparence de la fusion, robustesse multi-dataset et honnêteté scientifique.

8.2 Limites du Système et Perspectives d'Amélioration

Les limites identifiées dans le Chapitre 7 ouvrent des perspectives d'amélioration concrètes, classées selon leur horizon temporel et leur impact attendu sur la performance et la confiance clinique du système.

8.2.1 Court terme (0-6 mois)

- **Correction du bug Grad-CAM** : remplacer la pondération par activations moyennes par le calcul exact des gradients — enregistrement d'un backward hook sur la dernière couche convolutive, puis `weights = grad.mean(axis=(1,2))`. Cette correction, de quelques lignes de code, restaure la spécificité de classe des cartes de chaleur et devrait améliorer le taux de concordance anatomique au-delà des 80 % actuels, en particulier sur les pathologies localisées.
- **Calibration du classificateur M4** : appliquer un temperature scaling — optimisation d'un scalaire unique T sur le jeu de validation minimisant la NLL — afin d'obtenir des probabilités softmax reflétant la confiance réelle du modèle. Une réserve doit toutefois être formulée : l'analyse par intervalles conduite à l'Étude 4 montre que le défaut de calibration n'est pas monotone, le modèle étant sous-confiant entre 0.50 et 0.70 et sur-confiant au-delà de 0.80. Une transformation monotone à paramètre

unique ne corrigerait pas simultanément ces deux comportements, et une méthode par régression isotonique serait vraisemblablement mieux adaptée. Cette calibration fiabiliserait les flags d’incertitude en permettant de fixer un seuil ayant une signification probabiliste.

- **Validation sur holdout set indépendant** : étendre l’inférence à un second échantillon NIH de 500 images strictement disjoint des 501 images d’optimisation, afin de mesurer la performance réelle du Pipeline V5 hors des données ayant servi à fixer ses poids. Y adjoindre le calcul de la sensibilité, de la spécificité et de la matrice de confusion aux seuils cliniques retenus, ainsi qu’un intervalle de confiance bootstrap sur l’AUC.
- **Score CTR basé sur segmentation pulmonaire** : entraîner le Module 1 en configuration multi-classes pour segmenter simultanément le cœur et les deux champs pulmonaires — les masques JSRT encodent déjà ces structures (poumon gauche = 170, poumon droit = 255) et cette information reste actuellement inexploitée. Le diamètre thoracique serait alors mesuré anatomiquement au lieu d’être approximé par 75 % de la largeur d’image, produisant un CTR conforme à la définition radiologique et insensible au cadrage.
- **Élargissement du jeu de validation** : porter l’échantillon d’évaluation au-delà de 501 images afin d’atteindre la puissance statistique nécessaire pour trancher les questions laissées ouvertes, en particulier l’intégration du Module 3 à la formule de fusion, dont le gain de 0.014 point d’AUC n’a pu être établi comme significatif (Section 6.8).
- **Introduction d’un état INDÉTERMINÉ** : propager jusqu’au rapport final un état distinct lorsque le CTR calculé sort de l’intervalle de plausibilité [0.30 ; 0.75] ou lorsque la segmentation cardiaque échoue, afin que l’absence de mesure ne soit plus confondue avec l’absence de pathologie.

8.2.2 Moyen terme (6-18 mois)

- **Détection des calcifications par YOLOv8** : remplacer l’approche par segmentation U-Net, structurellement bornée par la nature rectangulaire des bounding boxes VinDr, par un détecteur d’objets dédié aux petites cibles. YOLOv8 est mieux adapté à la localisation d’objets ponctiformes de faible surface et fournirait un comptage de lésions plutôt qu’un pourcentage surfacique, métrique nettement plus informative que le calcif_pct actuel, dont la variance quasi nulle sur NIH explique l’exclusion de la fusion.
- **Dataset unifié NIH + VinDr + JSRT** : constituer un jeu d’entraînement

harmonisé associant les trois sources, avec une normalisation de contraste commune et une politique d’annotation unifiée. Cette mutualisation permettrait d’entraîner chaque module sur les trois populations simultanément, réduisant le domain shift résiduel des Modules 3 et 4, et rendrait possible une validation croisée inter-datasets — entraînement sur deux populations, test sur la troisième — seule méthode rigoureuse pour quantifier la généralisation géographique.

- **Validation clinique prospective** : conduire une étude pilote en partenariat avec un service de radiologie hospitalier, sur une cohorte consécutive de patients bénéficiant d’une radiographie thoracique de routine, avec confrontation des scores du pipeline à une évaluation cardiologique de référence (échocardiographie, dossier clinique). Cette étape est la seule permettant d’établir la sensibilité et la spécificité réelles, et constitue le prérequis indispensable à toute utilisation clinique.
- **Comparaison avec Framingham et SCORE2** : collecter conjointement les variables cliniques nécessaires au calcul de ces scores (âge, sexe, pression artérielle, bilan lipidique, statut tabagique, diabète) afin de quantifier la valeur ajoutée du pipeline. Deux questions se posent alors : le score radiographique apporte-t-il une information indépendante des facteurs de risque classiques, et son adjonction à SCORE2 améliore-t-elle la discrimination du modèle combiné ? C’est cette plus-value incrémentale, et non la performance isolée, qui détermine la pertinence clinique d’un outil de dépistage opportuniste.

8.2.3 8.2.3 Long terme (>*** 18 mois)***

- **Fine-tuning sur données locales marocaines** : adapter le pipeline aux populations et aux équipements radiologiques nationaux par un ré-entraînement partiel sur des données collectées en CHU, avec annotation par des radiologues locaux. Les trois datasets actuels sont américain, vietnamien et japonais ; rien ne garantit la transférabilité des seuils et des poids de fusion à une population maghrébine, dont les caractéristiques morphologiques et le profil de risque cardiovasculaire différent.
- **Déploiement comme aide à la décision radiologique** : intégrer le pipeline au flux de travail radiologique via une interconnexion PACS/DICOM, de sorte que chaque radiographie thoracique de routine génère automatiquement un rapport de dépistage cardiovasculaire annexe. Le système doit demeurer strictement un outil d’assistance : la décision finale relève du radiologue, et le rapport généré doit être présenté comme une suggestion accompagnée de sa décomposition et de ses flags d’incertitude, jamais comme un diagnostic.
- **Extension à d’autres facteurs de risque** : appliquer le principe du dépistage

opportuniste à d'autres pathologies détectables sur la même image — ostéoporose par analyse de la densité vertébrale, sarcopénie par estimation de la masse musculaire thoracique, emphysème — selon la démarche multi-pathologies validée économiquement par Pickhardt et al. [2]. Le coût marginal d'un indicateur supplémentaire est quasi nul dès lors que l'infrastructure d'inférence est déployée, ce qui améliore proportionnellement le rapport coût-bénéfice du système.

- **Validation CE/FDA pour déploiement clinique :** engager le processus de certification en tant que dispositif médical logiciel, vraisemblablement de classe IIa au titre du règlement européen MDR 2017/745, avec conformité aux exigences de l'AI Act sur les systèmes d'IA à haut risque. Cela suppose un système de management de la qualité (ISO 13485), une gestion documentée des risques (ISO 14971), une traçabilité complète des données d'entraînement et une surveillance post-commercialisation — un horizon pluriannuel qui dépasse le cadre d'un projet de recherche académique.

Tableau 8.2 : *Moyen terme (6-18 mois)*

Horizon	Action prioritaire	Impact attendu	Prérequis
Court terme (0-6 mois)	Correction Grad-CAM Calibration M4	Explicabilité améliorée Flags fiables	Code disponible
Moyen terme (6-18 mois)	Validation clinique pilote YOLOv8 calcifications	Sensibilité/Spécificité Détection précise	Partenariat hospitalier
Long terme (>^{**} 18 mois)^{**}	Fine-tuning données marocaines Déploiement CDSS	Adaptation population locale Usage clinique réel	Financement, CHU

8.3 Mot Final

Ce projet de fin d'études a constitué une expérience de recherche complète et formatrice, couvrant l'ensemble du cycle de développement d'un système d'IA médicale : de la revue de littérature à la validation expérimentale, en passant par la collecte et le prétraitement des données, l'entraînement de quatre modèles de Deep Learning, et l'analyse critique des résultats sous l'angle du Trustworthy AI.

L'une des leçons les plus précieuses de ce travail est que la rigueur scientifique et la transparence ne sont pas des contraintes qui s'opposent à l'innovation — elles en sont les conditions nécessaires. Le diagnostic de défaillance du Module 3, l'identification honnête des limites du Grad-CAM, et la documentation du biais d'annotation NIH ne diminuent

pas la valeur du projet ; ils la renforcent en démontrant une démarche scientifique mature et digne de confiance.

L'intelligence artificielle médicale ne sera adoptée par les cliniciens que lorsqu'elle sera véritablement digne de leur confiance. Ce projet, modeste dans son périmètre mais rigoureux dans sa démarche, s'inscrit dans cette direction. La radiographie thoracique analysée par un pipeline d'IA transparent et explicable représente une opportunité réelle d'améliorer le dépistage cardiovasculaire — particulièrement dans les contextes où les ressources médicales spécialisées sont limitées, comme au Maroc et dans de nombreux pays en développement.

Vision Finale

À terme, chaque radiographie thoracique prescrite en routine clinique pourrait être accompagnée automatiquement d'un rapport de dépistage cardiovasculaire opportuniste — transparent, explicable et calibré sur la population locale. Ce n'est pas remplacer le clinicien ; c'est lui donner un outil supplémentaire pour ne manquer aucun patient à risque parmi ceux qui passent déjà entre ses mains.

Références bibliographiques

- [1] Zambrano Chaves J.M., Wentland A.L., Desai A.D. et al. *Opportunistic assessment of ischemic heart disease risk using abdominopelvic computed tomography and medical record data : a multimodal explainable artificial intelligence approach*. Sci. Rep., 2023. doi 10.1038/s41598-023-47895-y
- [2] Pickhardt P.J., Correale L. & Hassan C. *AI-based opportunistic CT screening of incidental cardiovascular disease, osteoporosis, and sarcopenia : cost-effectiveness analysis*. Abdom. Radiol., 2023. doi 10.1007/s00261-023-03800-9
- [3] Weiss J., Raghu V.K., Paruchuri K. et al. *Deep Learning to Estimate Cardiovascular Risk From Chest Radiographs : A Risk Prediction Study*. Ann. Intern. Med., 2024. doi 10.7326/M23-1898
- [4] Zeleznik R., Foldyna B., Eslami P. et al. *Deep convolutional neural networks to predict cardiovascular risk from computed tomography*. Nat. Commun., 2021. doi 10.1038/s41467-021-20966-2
- [5] Lekadir K. *A deep learning solution to detect left ventricular structural abnormalities with chest X-rays : towards trustworthy AI in cardiology*. Eur. Heart J., 2024. doi 10.1093/eurheartj/ehad775
- [6] Bhawe S., Rodriguez V., Poterucha T. et al. *Deep learning to detect left ventricular structural abnormalities in chest X-rays*. Eur. Heart J., 2024. doi 10.1093/eurheartj/ehad782
- [7] Ronneberger O., Fischer P. & Brox T. *U-Net : Convolutional Networks for Biomedical Image Segmentation*. MICCAI — LNCS, 2015. doi 10.1007/978-3-319-24574-4_28
- [8] Tan M. & Le Q.V. *EfficientNet : Rethinking Model Scaling for Convolutional Neural Networks*. ICML 2019. arXiv : 1905.11946
- [9] He K., Zhang X., Ren S. & Sun J. *Deep Residual Learning for Image Recognition*. IEEE/CVF CVPR, 2016. doi 10.1109/CVPR.2016.90
- [10] Huang G., Liu Z., Van der Maaten L. & Weinberger K.Q. *Densely Connected Convolutional Networks*. IEEE/CVF CVPR, 2017. doi 10.1109/CVPR.2017.243
- [11] Zhou Z., Rahman Siddiquee M.M., Tajbakhsh N. & Liang J. *UNet++ : A Nested U-Net Architecture for Medical Image Segmentation*. Deep Learning in Medical Image Analysis — MICCAI Workshop, 2018. doi 10.1007/978-3-030-00889-5_1
- [12] Oktay O., Schlemper J., Le Folgoc L. et al. *Attention U-Net : Learning Where*

- to Look for the Pancreas*. Medical Imaging with Deep Learning (MIDL), 2018. arXiv : 1804.03999
- [13] Selvaraju R.R., Cogswell M., Das A. et al. *Grad-CAM : Visual Explanations from Deep Networks via Gradient-based Localization*. IJCV, 2020. doi 10.1007/s11263-019-01228-7
- [14] Chattopadhyay A., Sarkar A., Howlader P. & Balasubramanian V.N. *Grad-CAM++ : Generalized Gradient-Based Visual Explanations for Deep Convolutional Networks*. IEEE Winter Conference on Applications of Computer Vision (WACV), 2018. doi 10.1109/WACV.2018.00097
- [15] Ribeiro M.T., Singh S. & Guestrin C. *Why Should I Trust You ? : Explaining the Predictions of Any Classifier*. ACM SIGKDD, 2016. doi 10.1145/2939672.2939778
- [16] Lundberg S.M. & Lee S.I. *A Unified Approach to Interpreting Model Predictions*. NeurIPS (NeurIPS), 2017. <https://proceedings.neurips.cc/paper/2017/hash/8a20a8621978632d76c43dfd28b67767-Abstract.html>
- [17] High-Level Expert Group on AI (European Commission). *Ethics Guidelines for Trustworthy AI*. Publications Office of the European Union, 2019. <https://digital-strategy.ec.europa.eu/en/library/ethics-guidelines-trustworthy-ai>
- [18] Guo C., Pleiss G., Sun Y. & Weinberger K.Q. *On Calibration of Modern Neural Networks*. ICML 2017. arXiv : 1706.04599
- [19] Wang X., Peng Y., Lu L. et al. *ChestX-ray8 : Hospital-scale Chest X-ray Database and Benchmarks*. IEEE/CVF CVPR, 2017. doi 10.1109/CVPR.2017.369
- [20] Nguyen H.Q., Lam K., Le L.T. et al. *VinDr-CXR : An open dataset of chest X-rays with radiologist annotations*. Scientific Data, 2022. doi 10.1038/s41597-022-01498-w
- [21] Shiraishi J., Katsuragawa S., Ikezoe J. et al. *Development of a digital image database for chest radiographs with and without a lung nodule*. American Journal of Roentgenology, 2000. doi 10.2214/ajr.174.1.1740071
- [22] Krizhevsky A., Sutskever I. & Hinton G.E. *ImageNet Classification with Deep Convolutional Neural Networks*. NeurIPS (NeurIPS), 2012. doi 10.1145/3065386
- [23] Deng J., Dong W., Socher R. et al. *ImageNet : A Large-Scale Hierarchical Image Database*. IEEE/CVF CVPR, 2009. doi 10.1109/CVPR.2009.5206848
- [24] Kingma D.P. & Ba J. *Adam : A Method for Stochastic Optimization*. ICLR, 2015. arXiv : 1412.6980
- [25] Ioffe S. & Szegedy C. *Batch Normalization : Accelerating Deep Network Training by Reducing Internal Covariate Shift*. ICML 2015. arXiv : 1502.03167

- [26] Srivastava N., Hinton G., Krizhevsky A. et al. *Dropout : A Simple Way to Prevent Neural Networks from Overfitting*. Journal of Mach. Learn. Research (JMLR), 2014. <https://jmlr.org/papers/v15/srivastava14a.html>
- [27] Milletari F., Navab N. & Ahmadi S.A. *V-Net : Fully Convolutional Neural Networks for Volumetric Medical Image Segmentation*. 3D Vision (3DV), 2016. doi 10.1109/3DV.2016.79
- [28] Paszke A., Gross S., Massa F. et al. *PyTorch : An Imperative Style, High-Performance Deep Learning Library*. NeurIPS (NeurIPS), 2019. arXiv : 1912.01703
- [29] Zuiderveld K. *Contrast Limited Adaptive Histogram Equalization (CLAHE)*. Graphics Gems IV — Academic Press Professional, 1994.
- [30] Danzer C.S. *The cardiothoracic ratio : an index of cardiac enlargement*. American Journal of the Medical Sciences, 1919. doi 10.1097/00000441-191908000-00004
- [31] Caruana R. & Niculescu-Mizil A. *An empirical comparison of supervised learning algorithms*. ICML 2006. doi 10.1145/1143844.1143865
- [32] Litjens G., Kooi T., Bejnordi B.E. et al. *A Survey on Deep Learning in Medical Image Analysis*. Medical Image Analysis, 2017. doi 10.1016/j.media.2017.07.005
- [33] Shen D., Wu G. & Suk H.I. *Deep Learning in Medical Image Analysis*. Annual Review of Biomedical Engineering, 2017. doi 10.1146/annurev-bioeng-071516-044442
- [34] Rajpurkar P., Irvin J., Ball R.L. et al. *Deep learning for chest radiograph diagnosis*. PLOS Medicine, 2018. doi 10.1371/journal.pmed.1002686

Annexe A

Algorithmes Formels du Pipeline

Cette annexe présente les algorithmes formels du pipeline cardiovasculaire sous forme de pseudo-code structuré, conformément aux conventions académiques standard. Chaque algorithme est auto-contenu et référencé dans le corps du rapport aux sections correspondantes. Les notations mathématiques suivent les conventions de Cormen et al. (Introduction to Algorithms, 2022).

A.1 A.1 Prétraitement de l'Image

Tableau A.1 : A.1 Prétraitement de l'Image

Algorithme 1 : Prétraitement CLAHE et Normalisation

Entrée : Image I (PNG ou DICOM), taille cible S {224, 512}

Sortie : Tenseur normalisé $\hat{T} (1 \times S \times S)$

1

* // Étape 1 : Conversion en niveaux de gris*

2

I_gray ← convertir_grayscale(I)

3

4

* // Étape 2 : Application CLAHE pour amélioration du contraste*

5

I_clahe ← CLAHE(I_gray, clip_limit=2.0, tile_grid=(8,8))

6

7

* // Étape 3 : Redimensionnement à la taille cible*

8

I_resized ← resize(I_clahe, (S, S))

9

10

* // Étape 4 : Conversion en tenseur [0,1]*

11

T_raw ← to_tensor(I_resized) // T_raw [0, 1]

12

13

* // Étape 5 : Normalisation centrage-réduction*

14

T ← (T_raw - 0.5) / 0.5 // T [-1, 1]

15

Tableau A.1 : *A.1 Prétraitement de l'Image***Algorithme 1 : Prétraitement CLAHE et Normalisation**

16 retourner T

Algorithme 1 — *Prétraitement CLAHE et normalisation $[-1, 1]$ appliqué à toutes les images d'entrée.*

A.2 A.2 Calcul du Ratio Cardio-Thoracique

Tableau A.2 : *A.2 Calcul du Ratio Cardio-Thoracique***Algorithme 2 : Calcul CTR Corrigé par Spacing Adaptatif**

Entrée : Masque binaire $M \in \{0,1\}^{(512 \times 512)}$, spacing_orig (mm/px), largeur_orig (px), position {PA, AP}

Sortie : CTR_corrigé, heart_cm, thorax_cm

```

1  * // Étape 1 : Correction du spacing selon le redimensionnement*
2  scale_factor ← largeur_orig / 512
3  spacing_corrigé ← spacing_orig × scale_factor
4
5  * // Étape 2 : Détection du plus grand contour dans le masque*
6  contours ← findContours(M, RETR_EXTERNAL, CHAIN_APPROX_SIMPLE)
7  c* ← argmax_{c ∈ contours} area(c)
8
9  * // Étape 3 : Extraction de la bounding box cardiaque*
10 (x, y, w_box, h_box) ← boundingRect(c*)
11 cx ← x + w_box / 2, cy ← y + h_box / 2
12
13 * // Étape 4 : Vérification zone anatomique cardiaque*
14 si  $0.20 \times W < cx < 0.80 \times W$  et  $0.20 \times H < cy < 0.80 \times H$  alors
15   heart_px ← w_box
16 sinon
17   heart_px ← 0 // contour hors zone anatomique rejeté

```

Tableau A.2 : *A.2 Calcul du Ratio Cardio-Thoracique***Algorithme 2** : Calcul CTR Corrigé par Spacing Adaptatif

```

18
19  * // Étape 5 : Diamètre thoracique standard*
20  thorax_px  $\leftarrow 0.75 \times W$  // standard radiologique (75% de la largeur)
21
22  * // Étape 6 : Conversion pixels  $\rightarrow$  centimètres*
23  heart_cm  $\leftarrow (\text{heart\_px} \times \text{spacing\_corrigé}) / 10$ 
24  thorax_cm  $\leftarrow (\text{thorax\_px} \times \text{spacing\_corrigé}) / 10$ 
25
26  * // Étape 7 : Calcul CTR brut*
27  CTR_brut  $\leftarrow \text{heart\_cm} / \text{thorax\_cm}$  si thorax_cm > 0 et heart_px > 0 sinon 0
28
29  * // Étape 8 : Correction biais AP vs PA*
30  si position = AP alors CTR_corrigé  $\leftarrow \text{CTR\_brut} - 0.05$ 
31  sinon CTR_corrigé  $\leftarrow \text{CTR\_brut}$ 
32
33  retourner CTR_corrigé, heart_cm, thorax_cm

```

Algorithme 2 — *Calcul du CTR en centimètres réels avec correction du spacing adaptatif et biais AP/PA.*

A.3 A.3 Segmentation par U-Net

Tableau A.3 : *A.3 Segmentation par U-Net***Algorithme 3** : Inférence U-Net — Segmentation Cardiaque ou Calcifications

Entrée : Tenseur $T \in \mathbb{R}^{1 \times 1 \times 512 \times 512}$, modèle U-Net, seuil = 0.5

Sortie : Masque binaire $M \in \{0,1\}^{512 \times 512}$

```

1  * // Encodeur — chemin contractant (4 niveaux)*
2  e1  $\leftarrow \text{double\_conv}(T, \text{in}=1, \text{out}=64)$ 
3  e2  $\leftarrow \text{double\_conv}(\text{pool}(e1), \text{in}=64, \text{out}=128)$ 

```

Tableau A.3 : *A.3 Segmentation par U-Net***Algorithme 3 : Inférence U-Net — Segmentation Cardiaque ou Calcifications**

```

4   e3 ← double_conv(pool(e2), in=128, out=256)
5   e4 ← double_conv(pool(e3), in=256, out=512)
6
7   * // Bottleneck*
8   b ← double_conv(pool(e4), in=512, out=1024)
9
10  * // Décodeur — chemin expansif avec skip connections*
11  d4 ← double_conv(cat(e4, up(b)), in=1024, out=512)
12  d3 ← double_conv(cat(e3, up(d4)), in=512, out=256)
13  d2 ← double_conv(cat(e2, up(d3)), in=256, out=128)
14  d1 ← double_conv(cat(e1, up(d2)), in=128, out=64)
15
16  * // Couche finale + activation sigmoïde*
17  S_raw ← (Conv2D_1×1(d1, out=1)) // S_raw [0,1]^(512×512)
18
19  * // Binarisation avec seuil *
20  M ← (S_raw > 0.5) // = 0.5, identique pour les deux U-Net
21
22  retourner M

```

Algorithme 3 — *Inférence U-Net à 4 niveaux avec skip **connections** pour la segmentation cardiaque ou des calcifications.*

A.4 A.4 Classification et Explicabilité Grad-CAM

Tableau A.4 : *A.4 Classification et Explicabilité Grad-CAM***Algorithme 4 : Inférence EfficientNet-B0 avec Grad-CAM**

Entrée : Tenseur $T \in \mathbb{R}^{1 \times 1 \times 224 \times 224}$, modèle CNN (EfficientNet-B0)

Sortie : Probabilités $p \in \mathbb{R}^3$, carte de chaleur CAM $[0,1]^{(224 \times 224)}$

Tableau A.4 : *A.4 Classification et Explicabilité Grad-CAM***Algorithme 4 : Inférence EfficientNet-B0 avec Grad-CAM**

```

1      * // Passe forward avec enregistrement des activations*
2      T.requires_grad ← True
3      A ← None // activations dernière couche convolutive
4      hook : features[-1] → A ← output // hook PyTorch
5
6      logits ← .backbone(T) // logits ∈ ℝ3
7      p ← softmax(logits) // p ∈ [0,1]3
8      k* ← argmax(p) // classe prédite
9
10     * // Rétropropagation pour Grad-CAM*
11     .zero_grad()
12     logits[0, k*].backward() // gradient classe prédite
13
14     * // Calcul des poids d'activation (global average pooling)*
15     pour chaque canal c de A :
16         __c ← mean(A[c]) // __c = poids du canal c
17
18     * // Combinaison linéaire pondérée*
19     CAM_raw ← Σ_c __c × A[c]
20
21     * // ReLU et normalisation*
22     CAM_relu ← max(CAM_raw, 0) // ReLU : ne retenir que l'impact positif
23     si max(CAM_relu) > 0 alors
24         CAM ← CAM_relu / max(CAM_relu) // normalisation ∈ [0, 1]
25     sinon CAM ← CAM_relu
26
27     retourner p, CAM

```

Algorithme 4 — *Classification EfficientNet-B0 avec Grad-CAM pour l'explicabilité de la décision.*

A.5 A.5 Fusion Multi-Sources — Pipeline V5

Tableau A.5 : *A.5 Fusion Multi-Sources — Pipeline V5*

Algorithme 5 : Fusion Pondérée — Pipeline V5 (Formule Optimisée)

Entrée : CTR, prob_Edema $[0,1]$, prob_Cardiomegaly $[0,1]$, s_calcif $[0,1]$, w_ctr = 0.15, w_cong = 0.40, w_calcif = 0.10, w_cardio = 0.35

Sortie : risk_global $[0, 100]$, niveau {FAIBLE, MODÉRÉ, ÉLEVÉ, INDÉTERMINÉ}

```

1  * // Étape 1 : Normalisation du CTR en score partiel s_ctr*
2  * // Zone cliniquement significative : CTR  $[0.40, 0.60]$ *
3  s_ctr  $\leftarrow$  clip( (CTR - 0.40) / 0.20, min=0, max=1 )
4
5  * // Étape 2 : Score de congestion pulmonaire*
6  s_cong  $\leftarrow$  prob_Edema // probabilité classe Edema (Module 4)
7  s_calcif  $\leftarrow$  prob_Calcification + prob_Aortic // Module 3
7b prob_cardio  $\leftarrow$  prob_Cardiomegaly // Module 4
8  * // Étape 3 : Fusion pondérée optimisée (Pipeline V5)*
9  * // Poids déterminés par recherche exhaustive sous contrainte (Étude 6)*
10 risk_global  $\leftarrow$  (0.15  $\times$  s_ctr + 0.40  $\times$  s_cong
11     + 0.10  $\times$  s_calcif + 0.35  $\times$  prob_cardio)  $\times$  100
12
13 * // Étape 4 : Catégorisation en niveaux cliniques*
14 si non ctr_valide alors niveau  $\leftarrow$  INDÉTERMINÉ
15 sinon si risk_global  $\geq$  35 alors niveau  $\leftarrow$  ÉLEVÉ
16 sinon si risk_global  $\geq$  25 alors niveau  $\leftarrow$  MODÉRÉ
16 sinon niveau  $\leftarrow$  FAIBLE
17
18 * // Étape 5 : Flags d'incertitude*
19 si CTR > 0.50 alors émettre_flag(" Cardiomégalie : CTR =" + CTR)
20 si CTR < 0.40 et s_cong > 0.50 alors émettre_flag(" Œdème sans cardiomégalie")
21
22 retourner risk_global, niveau

```

Algorithme 5 — Fusion multi-sources du Pipeline V5, formule optimisée par

recherche exhaustive sur grille (AUC = 0.8916).

Note sur la notation

Les algorithmes ci-dessus utilisent les conventions standard du pseudo-code académique : $\leftarrow$ désigne l'affectation, $\in$ l'appartenance à un ensemble, $\times$ la multiplication scalaire, $\sigma(\cdot)$ la fonction sigmoïde, $\text{softmax}(\cdot)$ la normalisation softmax, $\text{clip}(x, a, b)$ la saturation de x dans $[a, b]$, et $\text{cat}(\cdot)$ la concaténation de tenseurs. Les indices des tenseurs suivent la convention PyTorch (batch, canaux, hauteur, largeur).